分类号：TP391　　密　　级：公开

UDC：　　单位代码：10127

内蒙古科技大学

硕士学位论文

论文题目：基于内容的自适应博客推荐方法的研究

学　　号：200902136

作　　者：冯 鑫

专 业 名 称：计算机应用技术

2012 年 06 月 06 日

中国知网 https://www.cnki.net

内蒙古科技大学硕士学位论文

论文题目：基于内容的自适应博客推荐方法的研究

作者：冯鑫

指 导 教 师：高永兵 副教授 单位：内蒙古科技大学

协助指导教师：_____ 单位：_____

_____ 单位：_____

论文提交日期：2012 年 06 月 06 日

学位授予单位：内 蒙 古 科 技 大 学

中国知网 https://www.cnki.net

基于内容的自适应博客推荐方法的研究

Research on Adaptive Blog Recommendation Based on Content

研 究 生 姓 名：冯鑫

指导教师姓名：高永兵

内蒙古科技大学信息工程学院

包头 014010，中国

Candidate： Feng Xin

Supervisor： Gao Yong-bing

School of Information Engineering

Inner Mongolia University of Science and Technology

Baotou 014010，P.R.CHINA

中国知网 https://www.cnki.net

独 创 性 说 明

本人郑重声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写的研究成果，也不包含为获得内蒙古科技大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解内蒙古科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

(保密的论文在解密后应遵循此规定)

签名：_____ 导师签名：_____ 日期：_____

中国知网 https://www.cnki.net

摘　　要

自从互联网开始变革，博客也跟随慢慢崛起，并以惊人的速度发展，到目前为止，博客用户更是达到上千万人。博客已成为人们工作生活必不可少的工具，用户数量的剧增，发表的博客自然也会增多。随着博客资源逐渐丰富，用户通过博客来解决疑难问题或查阅相关信息的使用也变的更多。但目前的博客站点只能简单以阅读量排行、点击排行量推荐结果，并没有根据用户的实际需要来为用户提供相关的博客。因此为了提高用户使用博客黏贴性，需要对用户需求进行分析，了解用户的兴趣，准确的把握用户的兴趣趋向，主动学习用户兴趣趋向的变化并调整推荐，满足用户的需要。

根据博客用户兴趣的易变性，提出一种基于用户反馈的自适应推荐方法-启发式方法，首先通过分析用户发表的博客类型为用户建立用户模型，并在此基础上记录用户阅读其它博客的行为；然后分析用户的反馈记录（用户的反馈记录则是用户在阅读过程中的行为动作和导航记录），从用户行为动作中挖掘用户的心态，从用户的导航记录中分析用户阅读博客的方式，从中跟踪用户的兴趣点，同时检测推荐的结果是否是用户需要的，并适当调整推荐结果；当兴趣在用户模型中改变时使用贝叶斯修正法更新用户模型。

实验分为阈值设定法对比实验和推荐基数选择实验。在阈值设定法对比实验中推荐基数设为 5-50，随着推荐基数的增大，推荐的博客数目也会增多，覆盖用户兴趣会更全面，应该是推荐的更全面、更准确。但博客数目过大会影响用户的阅读习惯，用户不会过多关注翻页后的推荐内容，因此在前期对用户阅读有提升，随着数目过大就会逐渐降低推荐效果。推荐基数选择实验是通过不同的基数设置来寻找一个最佳推荐基数，且在不同的环境下推荐基数也是不一样的。通过实验表明，启发式推荐方法可以有效提高自适应推荐博客的质量。

关键词：基于内容；自适应；用户模型；个性化推荐；启发式

中国知网　https://www.cnki.net

Abstract

Ever since the Internet began to change, the blog also slowly rises at an alarming rate. So far, the blog users have reached millions. The blog has become an indispensable tool for people’s working and living, and the rapid increase in the number of users make the blog posting increase naturally. As blog resources are gradually richer, more and more users want to solve difficult problems and look up relevant information through blogs. But the results recommended are simply chosen by clicking rate and reading amount, and it is not according to the user actual needs to provide users with the relevant blog. Therefore, in order to improve blog-adhesive when the user using the blog, user needs need to be analyzed and user's interests have to be known and users' interests are accurately grasped. When the user's interests tend changes, recommendation needs to be adjusted actively in order to meet the user's needs.

According to the blog users changeability of interest, a method is proposed based on a user feedback adaptive recommend-heuristic. Firstly, through the analysis of the blog type that users post to establish user model, based on this the reading behavior of other users is recorded; And then analysis of user feedback records, we mine the state of mind from the user actions, and record user reading the blog analysis way from the user's navigation records, also track the user's interest points, while testing whether the results will recommend the needs of users, to adjust the recommended results; When interest in the user model change, we use a bayes correction method to update user model.

The experiment is divided into the method comparison experiment with the threshold settings and recommendation base choice experiment. The recommended base of The threshold set method is 5-50. As the increase of the recommended base, the number of blog recommended increases, and the user's interest will be more comprehensive, which also should be recommended more comprehensive and more accurate. But it will influence the number of blogs user's reading habits, so the user will not pay much attention to scroll the recommended after content. In the early stage of the user reading have ascension, along with excessive number will gradually decrease recommend effect. Recommend base is through the different choice experiment settings to look for a base best recommend base, and in different environment is not recommended base. Experiments show that the heuristic recommend method can effectively increase the adaptive recommend the quality of the blog.

Key Words: Content-base; Adaptive; User Modeling; Personalized Recommending; Heuristic

中国知网 https://www.cnki.net

目　录

摘　　要 I
Abstract II
1 绪论 1
1.1 研究背景 1
1.2 研究目的 2
1.3 国内外研究现状及发展趋势 2
1.3.1 国内外研究现状 2
1.3.2 发展趋势 4
1.4 本文主要研究内容和组织结构 4
1.4.1 本文主要研究内容 4
1.4.2 论文组织结构 5
2 基于内容推荐系统及常用算法 6
2.1 推荐系统概述 6
2.2 基于内容推荐的工作原理 8
2.3 基于内容推荐的步骤 9
2.4 基于内容的推荐算法 10
2.4.1 基于内容推荐算法分类 10
2.4.2 文本推荐方法 10
2.4.3 自适应推荐 11
2.5 自适应推荐存在的问题 11
2.6 本章小结 11
3 用户模型的学习及相关技术 12
3.1 用户建模 12
3.2 模板学习 13
3.3 阈值学习 14
3.4 长期兴趣和短期兴趣学习 14
3.5 用户模型学习相关技术 15
3.6 本章小结 16
4 基于用户行为的日志分析 17
4.1 Web 日志挖掘技术研究 17
4.1.1 日志挖掘概述 17
4.1.2 数据预处理模块 18
4.1.3 数据挖掘模块 18
4.2 可获取的用户反馈行为 19
4.3 分析日志记录 20

中国知网　https://www.cnki.net

4.3.1 基于用户的日志分析的分类 20
4.3.2 当前用户识别 21
4.4 博客页面偏好分析 21
4.5 本章小结 22
5 基于用户反馈的自适应推荐方法 23
5.1 贝叶斯信任度修正 23
5.1.1 贝叶斯信任度修正 23
5.1.2 预期的信息增益 24
5.2 用户模型 25
5.2.1 用户建模 25
5.2.2 导航记录学习策略 28
5.2.3 用户模型更新 29
5.3 启发式推荐方法 30
5.3.1 启发式推荐方法 30
5.3.2 有效链接集的形成 31
5.3.3 推荐基数调整 31
5.3.4 用户接口设计 32
5.4 本章小结 32
6 实验设计与分析 33
6.1 推荐系统实验设计 33
6.1.1 博客个性化推荐系统总体架构 33
6.1.2 博客个性化推荐系统功能模块 34
6.1.3 界面设计 34
6.1.4 用户模型模块 36
6.1.5 推荐功能模块 38
6.2 实验数据 40
6.2.1 实验数据来源 40
6.2.2 抓取程序设计 41
6.2.3 数据库设计 43
6.2.4 博客数据训练系统界面设计 45
6.3 实验分析 47
6.3.1 启发式推荐方法与阈值设置比较 47
6.3.2 推荐基数调整实验 47
6.4 本章小结 48
结　　论 49
参 考 文 献 51
在学研究成果 55
致　　谢 56

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景

博客是 Web2.0 时代的产物，它有其独特的特点和作用，吸引着用户的应用。中文“博客”一词，源于英文单词 Blog/Blogger。Blog 是 Weblog 的简称，而 Weblog 是 Web 和 Log 的组合词。从英文字典可以知道：Web 是互联网，Log 的原意则是“航海日志”，后指任何类型的流水记录。把他们合在一起，从字面上来理解，Weblog 就是在网络上的一种流水记录形成或简称“网络日志”。其实质就是一个网页，通常由简短且经常更新的文章构成。博客的内容种类很多，有随想随写，心情日记，时事评论，新闻评论，发布照片等各个方面都有。因为博客能做的事情很多，所以现在使用博客的人数也越来越多。

博客一般分为 3 种存在类型：第一种是托管式博客，只需注册一个网站账户，并申请开通博客空间，就拥有自己的空间，无须编辑网页，这种方式是最快又省事的方式；第二种是自己建立个人博客站点，有自己的空间域名和网页风格，但需要一定的技术管理条件；第三种是附属博客，将博客作为某网站的一个栏目或一个频道，如新浪网站上的博客就是这种形式。这三类之间可以演变，甚至可以兼得，但企业一般选择前两种，第三种多应用与个人博客[1]。

随着博客用户数量的持续增长，博客已成为一种新的交流方式，代表着新的生活方式和新的工作方式，更代表着新的学习方式。通过博客，让自己学到很多，让他人学到更多。目前博客的普及度很高，无论在教育层次、文化背景、年龄各个方面不同情况下都有相当高的用户群体。博客由自己做主，自主表达思想、提出观点和分享人们的经历和观点；相对于传统的站点来说，博客是由许多的人参与传播信息，也会有更多有价值的内容的出现，这些内容涵盖广泛；相对于电子邮件来说，博客具有更大的分享性，能让更多的人分享精彩的内容、分享生活、甚至分享人生；相对于即时通讯来说，博客可以更深入的探讨一个话题；相对于日记记录来说，博客可以在记录用户常用的信息外，也可以为其他用户提供有用的信息；相对于论坛来说，博客不受版块的限制，更能发挥出每个人的积极性，自由的发表自己的想法，展现每个人的特点，这样就有利于用户通过博客了解到社会形态，让整个社会培养出有责任感和文明的社会文化群体。

因此，博客是社会发展必须的，也是不可替代的，它还将在未来互联网中发挥越来越重要的作用。随着博客用户数量的快速增长，博客内容也是成几何式增长，用户在博客的海洋中寻找需要的博客信息也越来越难，此时为用户提供个性化推荐服务，可以高效的帮助用户获取有效的信息，提高用户使用度，逐渐的喜欢阅读博客、发表

中国知网 https://www.cnki.net

博客，从而更大的调动用户的积极性。使用自适应推荐服务，解决用户博客兴趣变化快的问题，且为用户自动推荐感兴趣的内容，随着用户兴趣的变化及时的调整推荐结果，适应用户的需要，为用户节约时间和精力，促进社会的多样性和多元化发展。

1.2 研究目的

博客个性化推荐系统是依据用户的基本信息以及用户的兴趣爱好（包括用户发表的文章类别）为用户建立个性化用户模型，用来表示用户的兴趣趋向。博客个性化推荐系统的目标包括：

a) 具有自动收集用户信息的功能，要收集的用户信息包括用户注册账户的基本信息、用户发表的文章信息（文章标题、文章类别、文章设定的标签或关键词等）、用户阅读的文章信息。通过这些信息的收集，就可以为用户初始化用户模型。

b) 能够分析用户信息，从收集到的用户信息中提取出用户的兴趣类型，也能通过长期的综合分析得到用户的兴趣趋向。用户所发表的博客以及对自己文章的归类往往也是用户兴趣方向的关键反映，用户在收藏其他用户博客的时候，也表明用户是非常关注该方面博客的，这些都能反映出用户的兴趣趋向。

c) 设计一个有效的推荐算法，能自适应为用户提供最佳的阅读效果。现代的互联网用户要求是越来越高，兴趣变化也是非常快，若使用传统的方法只能永远滞后于用户的兴趣变化，因此设计一个能随时适应用户的需求变化的推荐算法是必须的，这就要能分析用户最近和当时的阅读行为，分析出当前用户可能关注的方向，把用户的兴趣分为长期兴趣和短期兴趣，短期兴趣可能是用户最近临时关注的，或者用户工作需要等各种情况，长期兴趣就是用户喜好的反映，当然短期兴趣可能转换为长期兴趣，长期兴趣随着时间的推移，也会有所衰减，甚至可能消失。

博客本身就是用户对社会形态发表的一个观点或感想，当用户去阅读博客的时候，这就是用户可能产生了兴趣，或者这是爱好的一种表达，而我们提供了个性化的推荐服务后，用户就不需要自己手动去寻找与自己兴趣相同博客，我们会根据用户的兴趣点推荐相关的博客内容；通过分析用户的行为，根据用户的兴趣变化趋势实时调整推荐结果；做到不管用户处于什么状态下，都能自适应为用户提供个性化的推荐服务。

1.3 国内外研究现状及发展趋势

1.3.1 国内外研究现状

在用户模型方面，常用的用户建模技术有用户评价矩阵、向量空间模型、机器学习等技术，也有提出使用智能代理来分析用户的需求，建立用户模型，并提供推荐服

中国知网 https://www.cnki.net

务。推荐算法方面，协同过滤推荐技术，基于用户之间的相似性产生推荐结果；基于内容推荐技术是基于用户与文本间的相似性推荐；由于协同过滤技术容易出现“冷启动”问题，基于内容不容易获取信息，因此有人提出了混合推荐技术，就是结合协同过滤和基于内容技术，利用两者的优点，充分的融合[2]。

随着研究的不断深入，学者在不断的提高用户模型，有使用奇异值分解技术减少特征向量空间的位数，提高最近邻居的搜索效率；也有对用户最近邻居和项目采用不同的权重方法来提高推荐质量；由于近几年互联网标签技术不断的提升，信息内容都会以不同的标签来标示，因此也有学者在研究基于标签的推荐技术，在显示收集用户的信息或评分的时候，往往无法获取到真实的信息或影响用户的使用效果，因此研究中提出通过 web 挖掘技术隐式获取用户的信息或评分，由此，各种数据挖掘技术也开始应用到推荐系统中。目前使用较多的如神经网络技术、遗传 L-means 算法等，他们都是都是通过分析用户的行为来获取用户的偏好，还有使用其他的挖掘技术如关联挖掘、聚类挖掘等都被应用于 web 日志分析中，用来提高推荐的精度。

推荐系统的应用方面，推荐系统也是信息检索和信息过滤领域的研究热点，有许多研究机构和学者做出了很大的贡献，社会上也出现了一些研究性的实例：

FAB[3]：它是斯坦福大学数字图书馆项目组开发的混合型推荐系统（基于内容和协同过滤），主要用于 web 页面的推荐。其特点是把协同过滤和基于内容推荐的优点综合起来使用。它主要包括收集页面、个人推荐和中心路由器三个部分。页面收集主要是从 Web 上收集具有特定主题的页面，个性化推荐是从特定主题中选择用户感兴趣的页面，然后推荐给用户。个性化推荐会根据文档内容建立用户文档，然后根据用户文档间的相似性搜索用户的最近邻居。推荐结果可以从基于用户文档产生的，也可以从用户最近邻居评价信息中产生。

ACF[4]（Active Collaborative Filtering）：ACF 系统是 Cannegie—Mellon 大学开发的主动协同过滤推荐系统，用于电子文档推荐。该系统是使用指针的方法，指针包含了三部分内容：指向电子文档的链接、文档的相关信息及用户的相关评论。用户可以主动的将自己创建的索引推荐给其他感兴趣的用户，也可以将创建的索引保存在系统中让其他用户查看。ACF 系统只适用于用户数量较小的场合。

还有 GroupLens[5]、MovieLens 等推荐系统对研究推荐都有很大的帮助。除了研究型推荐系统之外，随着推荐系统理论和技术的成熟，推荐系统在电子商务[6]得到广泛的应用。推荐系统的应用领域包括电子产品、旅游、书本、电影、金融、新闻、音乐等许多其他产品和服务。如 Jester 的笑话推荐系统[7]、Phoaks 的 www 信息推荐系统[8]、Amazonde 的书籍推荐系统[9]以及现在的当当网，淘宝网都在使用推荐技术挖掘用户的兴趣，并主动推荐产品，通过数据表明推荐技术的使用大大提高了用户的购买力。

中国知网 https://www.cnki.net

在上述的成熟推荐算法中，自适应是通过设定一个阈值来最大程度的区分和用户模型相关与否。然而随着互联网的发展，内容也变得更加丰富，用户的兴趣也跟着变化加快，如何动态的把握用户的兴趣，及时更新用户模型，做到准确的、高效的推荐才是重要的。在博客的推荐[10]中，目前研究的还不是很多，部分是研究了博客推荐的体系结构，或基于主题、标签等的推荐，没有对用户的兴趣动态把握提出一个合适的方法来对用户模型的学习和及时的更新，因此在博客推荐中有需多值得研究的地方。

1.3.2 发展趋势

随着推荐系统在电子商务领域的成功应用，各个领域都在进行个性化推荐的研究，在新闻领域也在研究新闻推荐，为用户寻找最方便的路径找到可能要关注的新闻；在搜索引擎方面也在研究为用户提供个性化服务，满足用户的要求。而在新兴的博客领域也不甘落后，国外早已开始了博客推荐的研究，而在国内的研究还只是初级阶段，因此在博客的热潮中，会越来越多的研究个性化博客推荐，可归纳为以下几个方向[11]：

用户兴趣和行为的表达：由于用户兴趣是多方面的、动态变化的，而且用户行为也是复杂多变的。因此，跟踪学习用户的行为和挖掘用户的兴趣是一个最基本和比较难解决的问题。

隐私和安全：个性化推荐系统主动收集用户的行为、动作，这些信息中还包含着用户的基本信息，通过分析这些信息就能发现用户的一些特点或者用户的兴趣爱好，保护这些信息的安全也是很重要，然而现在大部分的个性化推荐系统忽略了保护用户的隐私问题，因此需要一个有效的保护机制保证用户信息安全，让用户放心的使用个性化推荐系统。

自适应：用户的兴趣变化会受到各种因素的影响，如何做到每时每刻的把握用户的兴趣重点，给用户推荐的内容每时每刻会随着兴趣重点的转移而变化，就需要做到自适应的学习用户模型[12]。

1.4 本文主要研究内容和组织结构

1.4.1 本文主要研究内容

虽然推荐系统已能基本准确为用户提供个性化的信息，也提出了一些自适应的方法来适应用户兴趣变化，但是这些方法并不能有效的解决问题，推荐的结果也不稳定。因此，本文提出了一些改进的策略来适应用户的需求变化。本文的主要工作有：

(1) 从理论上研究基于内容推荐算法的工作原理、实现步骤、常用算法分类，并简单的对几种常用算法进行详细阐述，同时也提供了基于内容推荐方法存在的问题。

(2) 对用户模型的学习进行详细的说明，解释了用户建模的过程，对几种用户模

中国知网 https://www.cnki.net

型的学习方法进行了说明，并介绍了学习中用到的相关技术。

(3) 对用户的行为进行了分析，总结了可获取到的用户行为，然后对收集到的用户行为保存为日志形式，分析了日志记录的分类，也介绍了 Web 日志挖掘技术，对用户的博客页面偏好分析也做了分析。

(4) 研究了基于用户反馈的自适应推荐方法，在学习过程中提出了一些新的学习策略，适应用户模型的更新，提出使用长短期兴趣表示方法来解决用户兴趣的变化，然后再使用启发式方法进行推荐。

1.4.2 论文组织结构

本文的篇章结构如下：

第一章，对博客的产生和发展做了，又介绍了中国博客发展现状和存在的问题及个性化服务的发展，并指出提高博客个性化推荐的重要性。

第二章，对推荐系统进行概述，然后介绍了基于内容推荐算法的工作原理、工作步骤，然后对几个内容推荐算法中常用到的几种技术进行了分析，最后指出自适应推荐中主要问题。

第三章，首先介绍了用户建模的过程，从数据收集和模型表示进行分析，模型表示中对每种表示方法，基于向量空间模型表示、基于神经网络表示、基于本体论表达方法的基本思想，及各个方法的优缺点做了分析，然后阐述用户模型的学习常用的学习方法，模板学习方法、阈值设置方法、长短期兴趣表示方法做了分析，最后对学习过程涉及到的相关技术进行解释。

第四章，分析了用户的行为动作，并对用户的行为做了分类，哪些动作是可以被收集到，并能影响用户的需求和兴趣；然后对日志分析的分类和识别用户的身份做了研究；然后分析用户的博客页面偏好，在博客自身具备的特点下，用户在阅读博客的时候的反应是如何影响用户的博客喜好；最后对日志挖掘技术做了研究，对挖掘中要经过的步骤，及在挖掘分析中要完成的任务都做了解释。

第五章，用贝叶斯信任度修正用户模型，对用户的反馈信息做了详细的分析，设计用户模型的表示方法，如何自适应学习用户模型，最后对本文提出的启发式推荐方法，其中要对链接集的形成、推荐基数的设定、用户接口的设计、推荐方法做了研究。

第六章，首先对实验系统的总体架构和实现的功能模块进行分析，然后对实验数据的来源，实验数据如何抓取，实验数据的训练过程做了分析，最后做了阈值设定对比试验和推荐基数调整实验。

中国知网 https://www.cnki.net

2 基于内容推荐系统及常用算法

2.1 推荐系统概述

推荐系统[13]是一种智能代理系统[14,15]，它是用来解决互联网上的信息过载问题，它能根据用户的兴趣爱好提供相关的或相似的信息。推荐系统可分为一般推荐系统和个性化推荐系统。一般推荐系统向所有用户提供的推荐内容是相同的，如热门排行、点击量排行、评论排行等。个性化推荐系统则为每个用户提供的内容是不同的，它是根据用户的不同需求提供不同的推荐内容。由于个性化推荐能深入挖掘用户的需求，因此在产品销售、电影、新闻等方面得到了非常广泛的应用。目前最流行的各类个性化推荐系统主要包括基于内容推荐系统[16~18]、基于协同过滤推荐系统[19,20]、基于知识推荐系统[21,22]、基于 Web 使用挖掘推荐系统[23,24]和混合型的个性化推荐系统。一般地，推荐系统需要经过三个阶段来完成推荐，依次为用户建模、项目匹配和推荐输出。用户建模是根据收集到的用户信息分析得到用户兴趣，并用一定的结构化语言来描述该兴趣。项目匹配阶段是使用推荐技术找到与用户兴趣相关的项目，然后通过 Top-N 方法、预测值方法或者其他方法推荐给用户[25]。

由此可见，推荐项目的准确与否与用户兴趣的把握关系很密切，因此，对用户建模的研究是至关重要。推荐系统结构如图 2.1 所示。

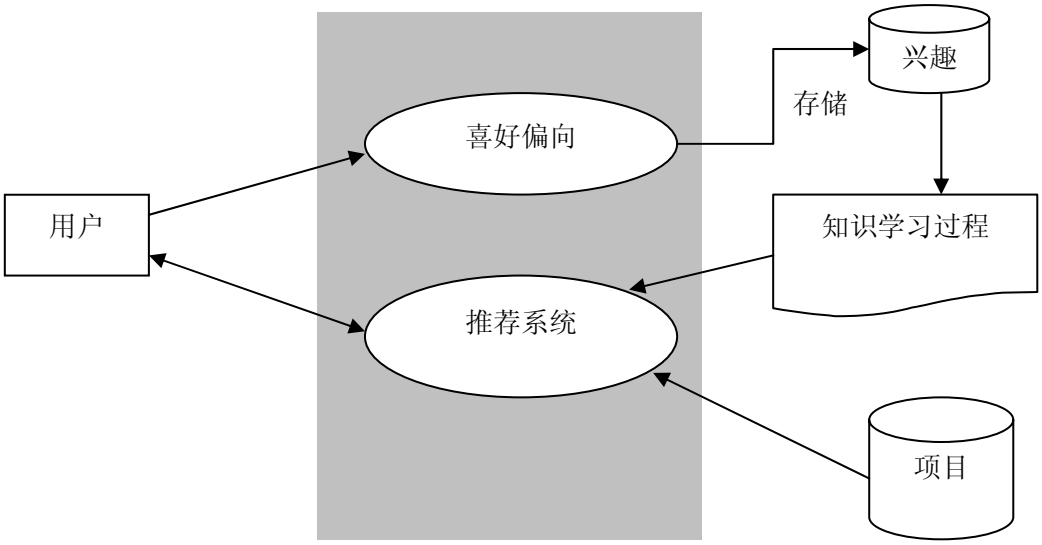

图 2.1　推荐系统结构图

推荐也是一种信息过滤，因此好的信息系统应该要解决以下几个问题：通过什么途径来获取用户信息和以什么方式表示用户的需求；如何判断过滤后的信息符合用户的需求；如何实现用户需求模型的学习和更新。下面来看看信息过滤领域是采用什么方法解决以上问题的。

中国知网 https://www.cnki.net

(1) 用户需求的描述

获取并描述用户的需求是构建信息过滤系统一项重要任务，也是非常艰巨的任务。由于不同用户的需求是不相同的，因此一份文档很难恰当的体现出用户的需求，因此人们针对这一问题做了许多研究和实验，其中最具代表性的方法有两种：一是通过文档集来表示，文档集指的是用户从整体文章中选择最具代表性的过滤子集，这种方法可以扩大用户需求表达的空间，但有限的文档无法覆盖用户的全部需求；二是通过关键词表示，是把用户的需求用关键词集合来表示。

目前常用的表示用户模型的方法有基于向量空间模型的表示法、基于神经网络的表示法、基于用户-项目评价矩阵表示法、基于案例的表示法以及基于本体论的表示法。

(2) 相关性判定

相关性判定也是信息过滤系统的核心问题之一，它主要包括基于改造的分类模型和基于扩展的检索模型。扩展检索模型的主要思想是使用信息检索技术对文档流中的文档和用户模板进行相似性计算，然后根据阈值进行判定，是否是相关的文档。扩展检索模型中，是通过反馈来改进用户模型的准确度，从而提高相似度计算的准确性。同时，阈值设定也是很重要的地方，它关系到相似文档的过滤。改造的分类模型，是把相关性判断看做一个分类问题（相关/不相关）。在该理论基础上，文本分类的主要方法也能应用到文本过滤中，如 K 近邻法(KNN)、支持向量机法、Bayes 分类[26~28]方法、人工神经网络[27]等。

(3) 用户模型自学习及阈值优化

用户模型的学习是通过用户的反馈信息的学习，然后对用户模型或阈值进行修正。目前阈值设置的用户学习模型是 Rocchio 模型[29~32]。

阈值优化是自适应过滤中一个重要且难解决的问题，设置一个能反映用户的真实需求，又能适应文档流变化而自动的调整的阈值，将会大大提供系统的性能。自适应阈值设定的方法有很多，目前较成熟的方法有直接效用优化法(direct utility optimization)和间接效用优化法(indirect utility optimization)两种。

(4) 用户模型更新

用户模型更新是根据用户对推荐的显示或隐式反馈信息来修正用户模型。目前主要采用的用户模型更新技术主要有三类：

a) 信息增补技术

它又分为直接信息增补和权重调整的信息增补。前者是将获取的用户反馈信息中抽取出的信息直接添加到用户模型中，例如 GroupLens、Ringo 等都使用的信息增补技术。这种更新方法只是简单的添加了信息，并没有进行考虑是否需要添加进来，因此该种方法不能达到效果。

中国知网 https://www.cnki.net

b) 遗传算法

遗传算法是一种基于自然选择和遗传机理的迭代搜索优化技术，它由适应度函数染色体种群以及选择、交叉和变异三个主要操作算子组成。它通常把用户模型编码成一个染色体并随即产生其他染色体作为初始种群。当初始种群进化迭代到满足终止条件时，解码适应度最高的染色体来取代系统目前的用户模型即可实现更新[33]。

c) 神经网络技术

神经网络技术是一种自适应更新技术。当用户的兴趣发生变化时，神经网络将自动调整网络连接权重，更新网络输出的识别结果。由于前期的神经网络学习是神经网络更新的主要依据，因此只有以神经网络作为学习技术的系统才会使用它作为更新技术[33]。

通过以上的分析，在大多数情况下，推荐的好坏决定于用户兴趣掌握的程度。对用户的兴趣变化趋势分析的越准确，就能抓住用户的需求，推荐的效果就会越好；同时能对用户的兴趣主次分析透彻，不同时期有不同的侧重点，推荐的结果就越接近用户的想法。

2.2 基于内容推荐的工作原理

在基于内容的推荐系统中，推荐的项目在内容上是与用户之前访问过的项目相似的，如图 2.2 所示，用户访问了 IT 类的文章，则系统推荐的项目为互联网、科技类的文章。项目是否是用户感兴趣的，这是通过项目内容的相似性来计算的，例如，在一个新闻推荐系统中，为了给用户 u 推荐其感兴趣的新闻，基于内容推荐系统会分析用户之前访问过的新闻页面，在文本内容上具有共同点（新闻的关键词、标题、人物、事件等），然后把这些与用户已访问过的在内容上相似的项目推荐给该用户。

基于内容的推荐方法最初是来源于信息过滤[34]和信息检索[35]两个方面的研究。由于信息检索和信息过滤在处理基于文本领域中取得很大的进展，如今基于内容的推荐系统在许多地方使用的很成功。例如，论文推荐、Web 页面推荐、新闻推荐、笑话推荐、电影推荐等。推荐系统是在传统的信息检索方法上改进了用户的描述文件，使用户描述文件包含更多用户个性化的信息（用户的性别、年龄、职业、兴趣、性格等）。这些信息都是通过显式或隐式的方式收集用户反馈，然后根据用户反馈的内容进行分析和挖掘，从中发现用户的兴趣点，并更新用户描述文件，从而达到把握用户的兴趣趋向。随着推荐系统的发展，项目文件也有了描述文件，一般是项目的一些特征和属性，这些特征是从项目内容中抽取出一个特征集合，通过这些项目特征判断该项目是否符合推荐用户的需求。例如在电影推荐中，基于内容首先要分析用户已看过的打分较高的电影在演员、关键词、风格等特征上的共性，再推荐与这些特性相似的用户未看过的电影给用户。

中国知网 https://www.cnki.net

基于内容的推荐只使用了用户和项目文件描述，因此克服了协同过滤中的新项目和冷启动问题；实际系统中用户对项目的打分信息是非常少的，然而基于内容推荐是不受打分稀疏性问题影响；它直接通过推荐项目的特征与用户兴趣的匹配，就推荐出相关内容。但是，由于基于内容的推荐系统对项目特性依赖性高，也出现了一些问题，例如：它只能处理具有可分析内容的项目，而对音乐、电影中的内容是无法进行推荐；基于内容推荐对项目文件相似性的计算，在项目数据巨大的情况下，推荐的效率或明显降低。

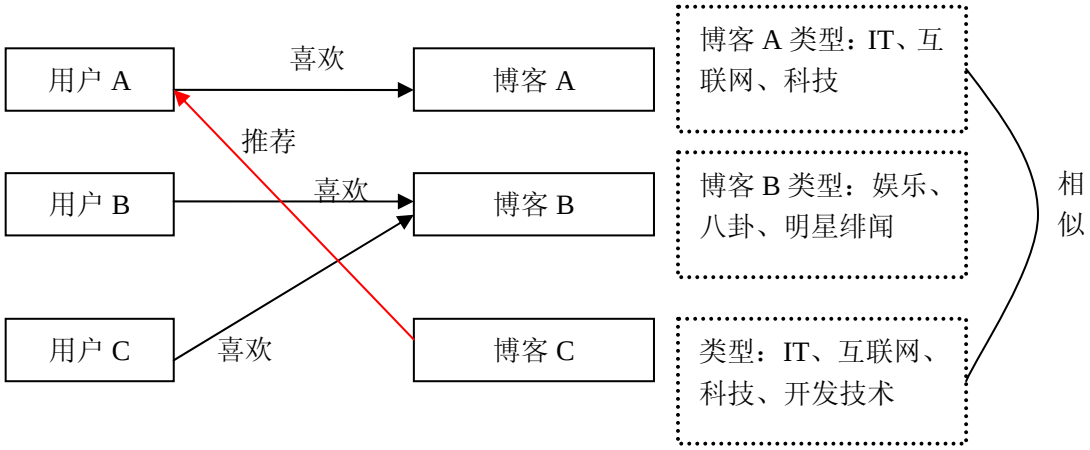

图 2.2　基于内容推荐基本原理

2.3 基于内容推荐的步骤

基于内容推荐是给每个用户建立一个兴趣模型，通过这个模型的数据结构来描述其喜好，对项目的内容进行特征提取，获得特征向量，当对用户进行推荐时，把该用户所建立的每个兴趣模型同所有项目形成的特征矩阵进行比较，寻找相似体，系统通过确定相似度来推荐用户可能感兴趣的文档[36]。因此推荐中要经过三个步骤：用户兴趣的描述；项目的特征提取与表示；用户兴趣与项目的相似度计算。

1) 用户兴趣的描述。这个步骤是收集有关用户的偏好信息，如用户的浏览行为、购买行为等。通过对原始数据进行转换、分析和录入，最终形成一个表示用户喜好的数据描述结构，在该结构中用特征向量来表示用户的喜欢程度。

2) 项目的特征提取与表示。每个项目中都包含了很多的信息内容，如何从中抽取出能代表该项目的关键词（在新闻文章中，要抽取出时间、地点、任务、事件等各要素的信息，才能表达清楚该新闻的主旨意思），因此从项目中提取出有用的关键词，并要一一分析是否能代表该项目，这是关键。

3) 用户兴趣与项目的相似度计算。在为用户推荐的时候，可以计算用户兴趣与项目的相似度；也可以计算项目与项目间的相似度，然后通过用户使用过的项目来推荐相似的项目。有使用奇异值分解方法、余弦相似度计算等方法。

中国知网 https://www.cnki.net

2.4 基于内容的推荐算法

2.4.1 基于内容推荐算法分类

上一小节已讲了基于内容的原理，它主要是通过项目信息的获取，然后用一种数据结构方法来表示项目特征和用户兴趣。因此，基于内容推荐中常用的方法有文本推荐方法、基于语义分析推荐方法、自适应推荐方法等。其中文本推荐方法是最基本的，就是利用历史信息构造用户兴趣模型，经计算推荐项目与用户兴趣稳定的相似度，将最相似的项目推荐给用户；潜在语义分析是通过对项或文档的奇异值分解方法把高维的向量模型表示中的文档映射到低维的潜在语义空间中，在低维的空间中灵活计算各文档间、文档与词之间的相似度。

2.4.2 文本推荐方法

文本推荐方法中的用户兴趣文档和推荐项目都采用关键字表示特征，然后采用 TF-IDF 方法为各个特征确定权重。

TF-IDF 方法基本思想是：某一个给定的词语在文中出现的频率越高，表示它对该文档就越关键；若给定的词语在不同的文档中出现的次数阅读，则该词语的贡献者就越小。对于在某个特定文件中的词语 t_i,它的重要性可表示为：

$$TF_{ij} = \frac{f_{ij}}{\sum_k n_{kj}} \qquad \text{（式 2.1）}$$

其中 f_{ij} 表示 t_i 在文档中出现的次数，而 n_{kj} 表示 k 关键词在第 j 个文档中出现的次数。逆频 IDF_i 定义为：

$$IDF_i = \log \frac{|D|}{|\{j : t_i \in D_j\}|} \qquad \text{（式 2.2）}$$

其中$|D|$表示文件的总数，$|\{j:t_i \in D_j\}|$表示在 D_j 中包含词语 t_i 的文件数目。

2.4.3 自适应推荐

自适应推荐就是根据用户的需求自动的调整适应，且具备自主学习的能力，不断提高适应能力，动态调整更新用户模型。为了提高推荐效率，使用阈值法设定一个阈值，只有相似度高于该值的时候才能更新用户兴趣，把高于阈值的相似度高的推荐给用户；还可以使用把用户兴趣分为长期兴趣和短期兴趣，通过长期兴趣和短期兴趣的转换来调整用户的兴趣侧重点，并更新用户模型，短期兴趣是用户当前最感兴趣的，

中国知网 https://www.cnki.net

要优先推荐，其次是长期兴趣的推荐。

2.5 自适应推荐存在的问题

基于内容推荐方法虽然可以处理新用户和新产品问题，也不受打分稀疏性影响，在使用自适应推荐后可以提高推荐的质量，把握用户兴趣更准确，但是自适应推荐要对用户兴趣的把握要求高，能实时了解用户的兴趣趋向是自适应推荐的重点，虽然在阈值设定来最大区分用户的兴趣，在选择合适的阈值是困难的，且不能动态变化。用户的动作最能反映用户的兴趣，如何收集用户的行为动作及导航记录，从中分析用户兴趣是需要解决的问题。

2.6 本章小结

本章从基于内容推荐的实现原理和步骤出发，介绍了基于内容的分类和常用算法，也给出了自适应推荐存在的问题。基于内容推荐方法虽然能解决协同过滤中会出现的“冷启动”问题，但是受到信息获取技术的约束，并在自适应方面还需要很大的改进，才能达到好的推荐效果。

中国知网 https://www.cnki.net

3 用户模型的学习及相关技术

用户模型的自适应能力也是用户模型的自主学习能力。学习是人类具有的一种特殊智能行为，让计算机具有学习的能力，能自动的推荐新的知识，适应变化环境。用户模型学习过程如图 3.1 所示，在系统初始化时候，只能得到简单的用户需求描述，此时的推荐效果肯定不能满足用户的需要，随着收集到用户的信息不断地完善，从而完善兴趣模型。在完善过程中用户的兴趣也是在不断的变化，怎么做到实时动态把握用户的兴趣趋势是关键。因此自适应学习成为关键，在自适应学习方面，已经取得众多成果，例如，模板学习法、阈值学习法和长期兴趣和短期兴趣表示法。

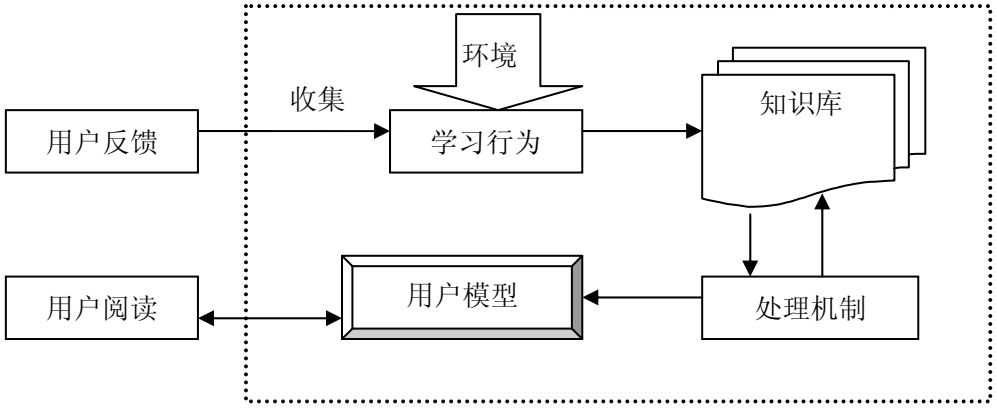

图 3.1　用户模型学习过程图

3.1 用户建模

用户模型不仅是对用户兴趣的描述，它作为计算机能识别的一种格式。因此，在个性化推荐系统中用户模型是具有特定数据结构的形式化描述[37]，分别以关键词、主题、关键词向量表示[38,39]。

一般在个性化信息服务中有 3 种建模技术：手工定制建模，由用户输入或选择的建模方法，完全依赖于用户并且无法准确反映用户真实兴趣；实例模型，是由用户提供与兴趣相关或无关的实例来建立模型，此方法需要用户在浏览过程中标注哪些是感兴趣的；自动模型，根据用户浏览行为，自动进行学习分析建立用户模型，不会影响用户的正常阅读[40,41]。

其中前两个都是显式建模技术，然而在使用显式建模技术收集用户的相关信息的时候，一方面用户输入的信息真实性有待判断，另一方面影响用户的使用效果。因此，现在越来越多的采用隐式建模技术，这样能在很大程度上提高系统的适用性，通过后台方法收集用户的行为动作来完成用户的信息收集。在建模的过程中包括数据的收集

中国知网 https://www.cnki.net

和用户模型表示[42]。

数据收集是获取用户相关信息的过程，在这个过程中为用户模型的建立提供必需的数据，通常采用显式或隐式方法实现。显式方法要求有友好录入界面，让用户填写各种信息，从中获取信息；隐式是通过后台收集用户的一些信息，不需要人工参与。目前大部分是采用显隐式相结合的方式。

模型表示，用户模型的表示提供一种结构化的模型存储形式，常用的用户模型表示技术主要包括以下几类[43,44]:

l) 基于向量空间模型的表示

该方法是将用户模型表示成一个 n 维向量($\{(t_1,w_1),(t_2,w_2),\ldots,(t_n,w_n)\}$)，向量的每一维都是由一组关键词及其相应的权重组成。权重大小表示用户对关键词的兴趣度[33]。因此，该模型反映了不同的关键词在用户模型中的重要程度。大部分系统都采用了这种表示方法，如 MovieLens、Web Watch[45]、WebCobra[46]、Fab 等。

2) 基于用户-项目评价矩阵表示

该表示方法是用一个$H_{i\times j}$矩阵来表示用户模型(i 为用户的数量，j 为项目的数量)，矩阵中的每个元素代表用户对项目的评价，若是评价范围为 1-5 的实数，若矩阵中某个元素值越大，则表示用户对该项目的喜好程度越高。采用这种方法表示，用户模型看起来简单、直观，但缺乏对用户兴趣变化的适应能力，难以更新用户的最新兴趣[33]。

3) 基于神经网络表示

该方法是用网络状态来表示用户模型，而网络状态是由两个各部分组成，包括网络的输入、输出状态和输入与输出间的连接状态。其中网络输入状态用来表示用户的偏好兴趣，网络输出状态是用来表示从输入中抽取出适合用户的模式类，这些模式类有时直接用来表述用户的兴趣与输入状态两者间的关联，被标记为感兴趣、不感兴趣；有时仅表示普通的分类，将这些类与其他一些准则关联起来，然后判别每个类与用户兴趣的关联[33,47]。

4) 基于本体论

基于本体论是用一个本体来表示用户的兴趣，通常采用层次概念树，树的每一个节点代表用户的一个兴趣类别，层与层之间也存在各种关系[47]。如 QulcksteP[48]系统是使用一个学术研究主题本体来表示用户的感兴趣的内容。

3.2 模板学习

对于模板学习，目前已经有很多学习算法，其中使用较广泛有 EG 方法、Rocchio 方法和 Boosting 方法。下面简单介绍下 Rocchio 方法。

Rocchio 方法主要适用于向量空间模型，基本思想是：让按照用户模型进行排序的相关文档的平均得分与不相关的差值尽可能的大点。Rocchio 把这样的查询称为最

中国知网 https://www.cnki.net

优查询。在这样的定义下 Rocchio 认为相关文档与不相关文档的质心向量的差就是最优查询向量[49,50]。如公式所示：

$$\vec{Q}_{opt} = \frac{1}{R}\sum_{d \in R_c}\vec{d} - \frac{1}{N-R}\sum_{d \notin Rc}\vec{d} \qquad \text{（式 3.1）}$$

式 3.1 中 $\vec{Q}_{opt}$ 是最优查询；R 是文档集中相关文档的数量；N 是文档集中文档的数量；R_c 表示相关的文档集合；$\vec{d}$ 则是文档向量表示。

3.3 阈值学习

阈值优化是推荐系统中使用较多的一种方法，同时也是比较难的方法，它分为直接效用优化法和间接效用优化法[50]。它是在用户的配置文件中建立一些问题集，系统利用已有的数据与用户配置文件相似度的概率分布确定一个最佳阈值，使得系统可以最大程度地区分与用户的配置文件相关和不相关的项目，只有与用户配置文件相似度大于最佳阈值的项目才能影响到用户配置文件的更新。

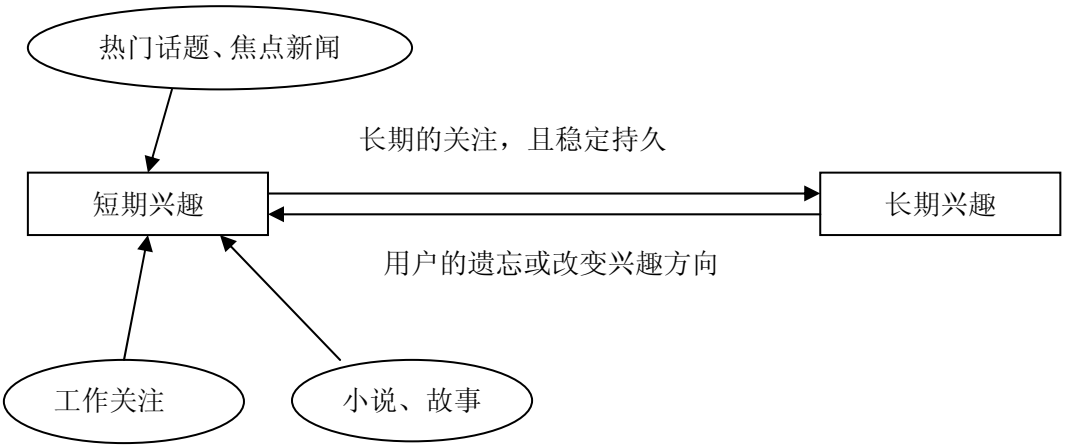

图 3.2　长期兴趣和短期兴趣转换图

3.4 长期兴趣和短期兴趣学习

把用户兴趣分为长期兴趣和短期兴趣，通过这样的分类就可以区分用户当前的兴趣侧重方向。用长期兴趣来表示用户较稳定的兴趣类型，每个人的性格决定了每个人有些兴趣是持久的，有可能是伴随一生，还有就是受工作的影响，从事的工作不管是不是兴趣，用户只要从事这份工作就会关注这方面的信息；短期兴趣是发现用户新的兴趣，进行跟踪，看能维持多长时间，分析因何关注这方面的信息，短期兴趣也可能是当前社会热门话题、焦点新闻等，这些在旁人的影响下，网络的头版新闻都会吸引用户的关注，并且有大部分不会持久很长时间的报道，因此短期兴趣来存储用户当前

中国知网 https://www.cnki.net

较短时期内可能关注的兴趣类型或用户新关注的兴趣类型。当然短期兴趣中有部分兴趣用户会慢慢的喜欢上，经过长时间的关注会转换为用户的长期兴趣。在长期兴趣中也有部分兴趣会随着用户的兴趣方向的形成，该部分兴趣会被用户渐渐的遗忘，这将会慢慢从长期兴趣中消逝。通过改变长期兴趣和短期兴趣的转换来学习用户的兴趣，也能做到自适应的学习用户模型。长期兴趣和短期兴趣转换如图 3.2 所示。

3.5 用户模型学习相关技术

用户模型学习是对收集的用户相关信息进行挖掘，筛选出有效信息，从中分析出用户的兴趣或用户的真实需求，并以结构化的方式添加到用户模型中。常用的用户模型学习有决策树归纳、TF-IDF、神经网络和聚类[51]。

(1) 决策树归纳

决策树归纳是通过建立决策树来标记或者将实例划分到一个已知类集中。一棵决策树通过一个测试序列得到它的一般性决策，由表示类的叶节点和表示分类条件的内部节点组成。分类过程从一个根节点开始，每个节点对应一个属性值的测试，不断产生分支，在分支上标记可能的测试纸，之大破产生叶节点位置，完成自上而下沟槽的决策树的学习过程。在模板学习中在每个节点是一系列的问题，用户被引导从根节点开始回答一系列的问题，在到叶节点后，就能得到对用户偏好的描述[33]。

(2) TF-IDF 技术

该技术是信息检索领域使用最广泛的文本学习技术，它是把在一篇文章中出现的频率 TF 高的，并且在其它文章中很少出现的某个词或短语抽出，它认为这些词或短语具有很好的类别区分能力，适合用来分类[52]。

(3) 神经网络技术

神经网络技术是把用户建模过程看做一个分类过程，运用神经学习算法对用户输入的信息进行学习，然后调整网络连接权重，直到网络中所有节点达到稳定状态。它是一类具有很强的组织信息的能力和自适应能力的信息处理技术。

(4) 聚类技术

聚类是通过数据之间的相关性和差异性建立一些规则，然后根据这些规则将数据进行类别的划分。聚类关键在于确定数据之间的相似程度和差异性计算概率，与分类不同，聚类是不要求有先验的知识，而是完全地依据数据本身的特性的差异进行处理的，最终的结果是把数据划分到不同的组中，组之间的差别尽可能的大，组内的差别尽可能的小。聚类技术就是建立用户簇的综合模型，如 WebPersonalizer[53]系统先将用户会话和页面请求聚类，然后用每个聚类来获取每个用户子集行为的综合特征，最后再构成用户簇的综合模型，聚类技术处理过程如图 3.3 中所示。

中国知网 https://www.cnki.net

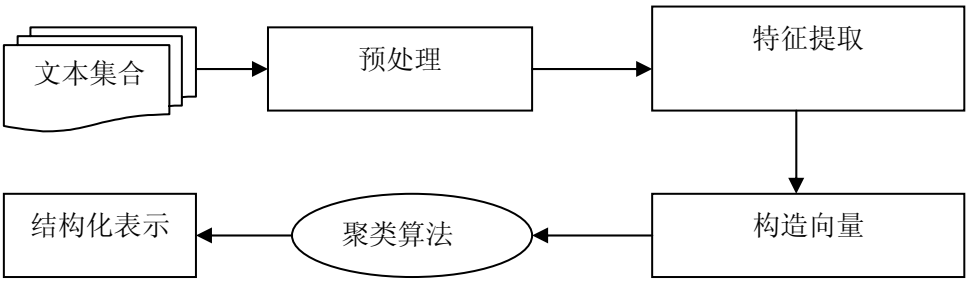

图 3.3　聚类技术模板学习图

3.6 本章小结

本章介绍了各种用户模板学习方法，这些都是自适应过程中会应用到的，做到自适应就需要用户模型具备自学习能力，并能挖掘出用户的兴趣变化。最后针对模板学习中涉及到的相关技术进行了详细阐述，对每种技术的特点做了说明。

中国知网　https://www.cnki.net

4 基于用户行为的日志分析

4.1 Web 日志挖掘技术研究

4.1.1 日志挖掘概述

Web 挖掘就是针对记录用户使用网络的交互信息，从中发现有效的、可理解、可用的知识过程[54]。Web 挖掘由数据挖掘发展而来，但也有不同之处：Web 挖掘处理异构的网络数据，Web 页面在逻辑上是由文档节点和超链接构成的，而数据挖掘的对象是数据库中的结构化数据。其方法通常可以分为两类：一类是建立在统计学基础之上，采用分类、聚类、决策树等方法；另一类是以机器学习为主的人工智能模型，采用的方法有神经网络、遗传算法等。从数据源角度来讲，Web 挖掘可以分为：Web 内容挖掘(Web Content Mining)、Web 结构挖掘(Web Structure Mining)、Web 日志挖掘(Web Log Mining)[55]，如图 4.1 所示。

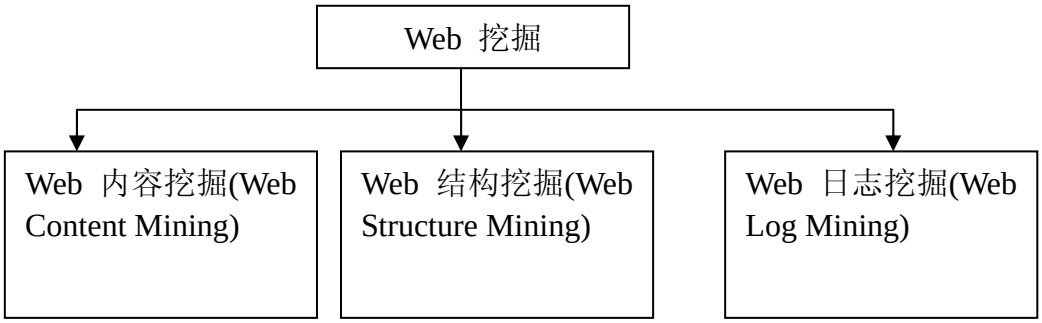

图 4.1　Web 挖掘分类图

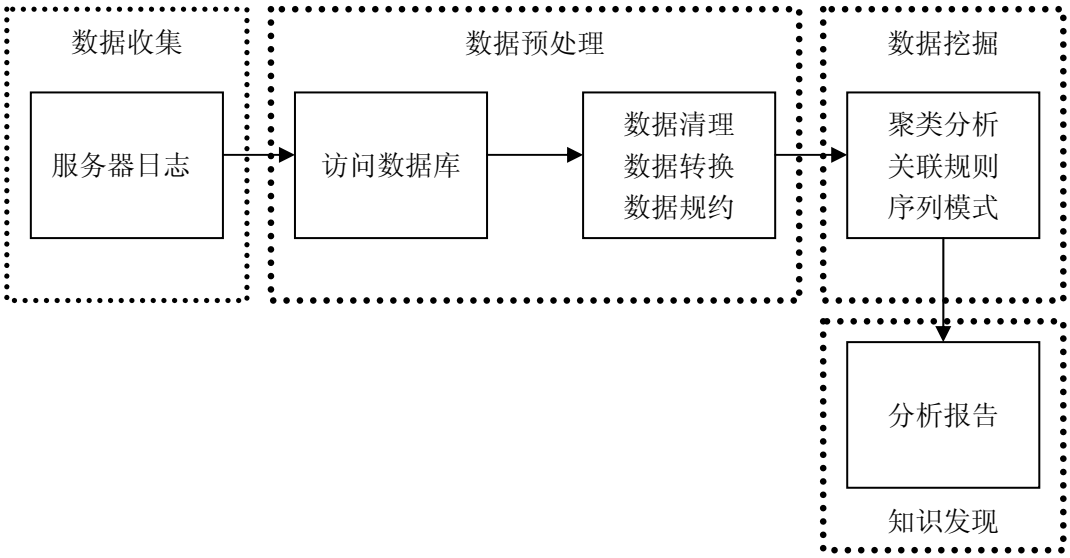

图 4.2　Web 挖掘处理图

中国知网 https://www.cnki.net

Web 日志挖[56,57]掘主要通过分析用户在访问 Web 页面的记录，从中了解用户的使用习惯和兴趣，然后进行预测。目前 Web 日志挖掘主要用来提供用户为个性化服务，改善系统结构，提供系统的性能等。挖掘过程可分为数据的收集、数据的预处理、模式挖掘以及模式分析 4 个环节，处理流程如图 4.2 所示。

4.1.2 数据预处理模块

Web 服务器日志记录了用户访问本站点的信息，包括 IP 地址、请求时间、方法、被请求文件的 URL、返回码、传输字节数、引用页的 URL 和代理信息等。这些信息有些对挖掘过程不起作用，因此，在进行模式发现前要对数据进行预处理。数据预处理模块[58,59]主要对收集到的用户访问信息、用户基本信息、内容信息和结构信息等进行再加工或者重构形成模式挖掘需要的数据对象。在该环节中需要经过几个步骤来完成，依次为：数据清理、数据集成、数据变换、数据规律。数据预处理的好坏直接影响着日志挖掘的质量。

1) 数据清理。其任务是把日志中的垃圾数据（脏数据）删除，排除噪声数据，去除重复数据，缺值得数据进行补充或去除等操作。

2) 数据集成。其任务是统一化数据，规范化数据。这个过程并非是简单地数据合并操作。

3) 数据转换。其任务是把数据转换为合适的数据格式，以便后面的分析使用方便。

4) 数据规约。其任务是根据挖掘的需要，对数据信息进行相关的操作，比如可以有效的减少数据存储空间，提供挖掘效率。

4.1.3 数据挖掘模块

数据挖掘模块是日志挖掘过程中的重要环节，其主要目的是描述和预测，描述是用容易理解的方式表达数据中包含的相关信息（属性和特征信息）；预测是根据特征信息发现其内部规律，从而预测用户潜在的兴趣变化趋势。

日志挖掘所实现的任务有以下几个：

1) 特征抽取，是从数据源中提取一些能代表该数据的特征词。

2) 关联分析，是发现一些相互独立的数据记录间的关联关系。

3) 属性分类，是通过分类函数将各类数据映射到不同的类别内。

4) 聚类分析，是通过对一组数据的属性进行比较和分析后，将数据聚集成不同的类簇，为了能尽可能的区分开，要使簇与簇间的属性相似度尽量的小，簇内部则尽可能的大。

中国知网 https://www.cnki.net

4.2 可获取的用户反馈行为

在一个系统中，对用户信息的收集方式分为两种：显示反馈和隐式反馈。给用户提供友好界面（比如注册、评论等），系统通过这些途径收集到用户的信息，叫做显示反馈；隐式反馈是不必须通过友好界面输入信息，系统会在后台通过收集用户的行为动作来分析用户的反馈。尽管显式反馈可操作性强，也容易获取信息，但是在大多数应用中，用户是不想给系统提供真实的信息，或者直接不填写，这样就不能对收集用户的信息起到良好的作用，还会降低整个系统的可用性。而隐式方法不影响用户的正常工作，还能收集到用户的真实行为，这在对用户兴趣模型的处理方面会显式反馈更好。

有人把用户隐式反馈的行为分类[59]，例如阅读、购买、滚动、评论、收藏、标记、查询、打印、保存等。用户在打开一个页面后，先进行阅读，阅读的时间长短也可能会是用户兴趣的参考，但时间的长短因人而异，不同人阅读速度快慢都不一样，因此这个不容易界定。在阅读过程中，用户会滚动滑块，也会影响用户的兴趣，当然这些都只能作为兴趣的辅助参考，主要的还是用户的阅读、评论、收藏、标记、导航记录等，具体详细信息如表 4.1 所示。这是用户直接动作最能体现出用户兴趣所在，系统通过后台运行收集用户的这些动作保存为日志格式，保存的格式如表 4.2 所示。

表 4.1　用户反馈行为描述

行为动作	行为内容描述
阅读	点击进入一篇信息内容进行查看
评论	发表自己对阅读的信息的看法
收藏	喜欢该网页，或者希望过段时间后再次阅读
标记	对查看的信息或产品利用自己认为的关键词标注
滚动	阅读过程中反复的查看信息的前因后果

表 4.2　用户反馈保存格式

代号	描述
ID	博客编号
Do	发生的动作（评论、收藏等）
Time	发生的时间
Uid	用户编号

用户的历史行为[60]都是用户心理上的反映，记录这些行为对分析用户的兴趣非常的重要。

中国知网 https://www.cnki.net

4.3 分析日志记录

互联网的各种应用系统大都具备日志功能，并且若是该站点想挖掘用户的数据，会从全方位记录用户的行为。因此只要充分利用这些日志信息，可以从中挖掘出用户的行为规律或兴趣导向。

Web 服务工作机制是客户通过浏览器向 Web 服务器发出请求，服务器在接受请求的同时会记录下用户发送的请求地址、请求内容以及请求时间等详细的信息。这些信息是用户阅读的真实行为，因此对于分析用户的兴趣是很重要的数据来源。

由于日志记录了用户的所有操作且信息量较大，一般都需要进行预处理操作，把一些输入错误或无效的网址，或者输入网址已经不存在等一些无效信息需要排除掉。比如我们要研究一个用户阅读博客的行为，那么从日志中要提取出该用户的阅读记录，及在阅读中进行的评论、收藏等操作。在此基础上对数据进行分类操作，按照标准对用户的会话数据分为不同的操作类型，这样就能全面了解用户的行为，还能了解到用户的使用习惯。在对页面内容进行分类可以使用聚类的方法，把内容相似度接近的分为一组。这样通过页面内容分类后根据不同的操作类型就可以分析出用户的关注信息面，用户喜欢收藏、评论的文章是哪些方面的。

4.3.1 基于用户的日志分析的分类

针对用户日志分析主要分为两类：

1) 基于个体用户。旨在发现单个用户的兴趣空间，使用互联网规律，用以提供个性化服务。

2) 基于用户群。通过用户聚类，分析用户群体的使用习惯，相似用户的兴趣方向是否相同，把相似的用户组成群体，总结整体规律，然后用户智能推荐。

日志的分析，挖掘用户的规律，对发现用户的兴趣空间非常的关键。

表 4.3　用户识别机制分类表

方法	描述	优点	缺点
IP 地址和代理	假设每个 IP 地址对应一个用户	容易实现	由于 IP 地址会变化，无法有效识别用户
注册信息	用户拥有唯一 ID	实现容易，且能准确识别用户	用户体验差
会话	嵌入用户 HTTP 请求中的唯一标识	实现容易，大多数服务器都支持	同一用户可能会使用不同的会话
Cookie	客户端的唯一标识	可以识别用户的访问情况	客户端功能服务器无法控制

中国知网 https://www.cnki.net

4.3.2 当前用户识别

用户访问站点的方式有很多，因此在产生的日志中也会有各种用户的登录信息，识别用户的登录方式辨明身份后才能对用户的访问记录进行分析。为了统一一个标准，我们使用 W3C 提出的网络数据项标准[61]。用户在不提供认证信息的情况下，很难进行身份识别。因此对目前的用户识别机制可分为如表 4.3 所示。

4.4 博客页面偏好分析

博客都是由博主通过发布系统发布到互联网上，在每篇博客页面中，都由很多部分组成，其中包括博主空间的名称，博客信息，正文部分，以及评论部分，还有其他相关博客栏目和推荐博文栏目，都可能会吸引用户继续阅读。其中博文中一般会有：标题、标签、分类、发表时间、正文、阅读次数、评论次数、收藏次数、转载次数以及评论内容等。这些都可能反映该篇博客是否受欢迎（例如：阅读次数大，说明用户关注的多，评论次数多说明许多用户对此产生了共鸣，收藏次数多，说明用户喜欢的多；转载的多，说明用户喜欢引用的多）。

用户在列表页面通过博客标题判断该博客的主题意思，然后决定是否进入详细阅读，若用户点击进入，这表明用户是有关注的意思，若不点击则表明用户的意思不很明确，可能出现的情况太多，无法摸清用户的心理。在进入博客页面后，用户的动作最能表明用户的心理。由于博客一般是阐述一个观点（无论对时政热点、焦点新闻、社会情况等），需要用自己的一些论证来说明自己的观点，因此要想完全的理解博主发表该文的意图就需要深入的阅读完整篇文章，用户在阅读的时候，系统记录用户的行为就很关键，用户是没有发生任何动作还是反复的滚动阅读，并进行评论，若有系列报道，用户是否进行系列的阅读了。

因此用户对一篇文章的心态只有两种：阅读和没有阅读。阅读可以明确用户的心理情况，没有阅读无法判断用户的心态。用 C_{ij} 表示用户 i 对博客 j 的心态如表 4.4 所示。

表 4.4　用户阅读心态标识图

状态	标识
阅读	1
未阅读	0

由于不同用户的阅读能力是不同的，他们的阅读速度也是不一样，但每人的阅读速度应该是稳中有升，只要对用户掌握足够多的数据是可以计算出用户的阅读速度。

中国知网 https://www.cnki.net

在用户日志文件中有记载用户阅读每篇文字的阅读时间的，每篇文章的长度也可以得到的，因此根据历史记录就可以计算出用户的平均阅读速度 S：

$$S = L/T \qquad \text{（式 4.1）}$$

其中 L 为所有阅读新闻的总长度，T 为阅读的总时间。

掌握了用户的阅读速度后，就可以掌握用户的阅读节奏。当然这其中也会有很多的噪音影响，有的时候可能用户已离开，没有关闭页面；有的时候用户打开页面并没有阅读等等。这些噪音只能通过设定界限值来判定用户是否还在阅读。这致使用户动作中的一小部分行为，要想准确的掌握用户的偏好，还要知道用户的是否收藏，是否进行了评论，用户是否有进一步深入的动作，这些都要用用户的导航记录来分析。

若想根据用户的导航记录来分析用户的兴趣趋向，这也是要分析用户的日志记录来判定的，具体的判定方法会在下面章节详细讲述。

4.5 本章小结

本章阐述了用户隐式反馈的行为动作有哪些，及这些动作的收集方法。然后对用户日志的分析方法进行阐述，又对日志挖掘进行了解释，说明了挖掘的分类，挖掘的步骤及挖掘的方法。

中国知网 https://www.cnki.net

5 基于用户反馈的自适应推荐方法

5.1 贝叶斯信任度修正

站点从用户的配置属性中给用户提供个性化的服务，一个配置文件（用户模型）相当于预设的属性（或属性集），例如性别、年龄、职业、教育情况等。每个配置属性值代表用户可能接受的值，也可能是与其他配置相关联的值。因此，每个属性值代表用户可能喜欢的程度，配置属性代表用户可能感兴趣的内容或类，每个链接可能会属于多个类。

提供集是一个博客链接的集合，而提供集的信息价值是基于用户选择的链接预期信息增益结果。当面对该提供集的时候，信息增益是一个属性跟以前的属性值比较得出的不同。有时一个配置值超出一个临界值的概率时，就应该做出适时调整；在预期信息增益已没有重大意义时应停止修正。当然，只要用户一直在该站点，站点就应该继续修正用户的配置文件，本文采用贝叶斯信任度修正[62]的方法修正用户配置文件。

5.1.1 贝叶斯信任度修正

站点在用户浏览每个页面的时候给提供一组链接，当用户每次固定点击一个链接的时候，站点会根据情况修正用户配置文件关于该类的信任度。初始化让 $a_i(i=1,\cdots,m)$ 属性值表示关系属性 A 的值。在任何有意义的交互过程中，配置文件获取用户的每个 i 值可能属于类 a_i，我们用 LH 表示用户历史链接，这里的历史链接是链接集中用户到目前已点击过的链接集合（当用户刚到该站内还没有导航时 LH 是为空）。若用户从当前的提供集 O_f 中点击一个新链接 l_j，站点需要修正用户的配置文件，因此，要计算 $P(a_i|LH,l_j)$的每个值。

两个概率参数集是每个链接必须的。首先浏览者对每个页面的配置文件信息，$P(a_i|l_j)$称为链接的配置属性值，链接配置属性与浏览者的配置属性是有关联的。第二个参数是用户点击一个链接的概率（或浏览关联页面的概率）$P(l_j)$，称作链接的受欢迎度。先说明一个用户对历史链接 LH 当点击链接 lj 时怎么修正信任度，给出链接概率值。用贝叶斯定律，配置属性表示为：

$$P(a_i \mid LH, l_j) = (1/k) \cdot P(LH, l_j, a_i) P(a_i)$$
$$\text{其中} k = \sum_{a_i \in A} P(LH, l_j, a_i) P(a_i) \qquad \text{（式 5.1）}$$

式 5.1 中 $P(a_i)$是站点预先分配的配置属性，k 是一个归一化因子。假设条件 k 是独立的，式 5.1 能写成：

中国知网 https://www.cnki.net

$$P(a_i \mid LH, l_j) = (1/k) \cdot P(LH \mid a_i) P(l_j \mid a_i) P(a_i)$$
$$\text{其中k} = \sum_{a_i \in A} P(LH, l_j, a_i) P(l_j \mid a_i) P(a_i) \qquad \text{（式 5.2）}$$

根据式 5.2 应用贝叶斯倒置出 $P(LH|a_i)$：

$$P(a_i LH, l_j) = (1/k) \cdot \frac{P(a_i LH) P(LH) P(l_j \mid a_i) P(a_i)}{P(a_i)}$$
$$\text{其中k} = \sum_{a_i \in A} \frac{P(a_i \mid LH) P(LH) P(l_j \mid a_i) P(a_i)}{P(a_i)} \qquad \text{（式 5.3）}$$

代数简化之后，我们得到下面式子：

$$P(a_i \mid LH, l_j) = (1/k) \cdot P(l_j \mid a_i) P(a_i \mid LH)$$
$$\text{条件k} = \sum P(l_j \mid a_i) P(a_i \mid LH) \qquad \text{（式 5.4）}$$

这里，$P(a_i|LH)$是基于历史记录下的 a_i 类的值。$P(l_j|a_i)$是类 a_i 成员将点击在提供集 O_f 一个链接 l_j 的值。这个概率用贝叶斯定律能估算单个链接与链接集在提供集 O_f 关系如下：

$$P(l_j \mid a_i) = \frac{P(a_i \mid l_j) P(l_j)}{\sum_{l_j \in O_f} P(a_i \mid l_j) P(l_j)} \qquad \text{（式 5.5）}$$

5.1.2 预期的信息增益

首先评估每个链接的信息值用来计算预期信息增益。如果链接被用户选中，首先要评估每个链接的信息值，用来计算预期的信息增益。因此，预期的信息增益 $I(A|LH,l_j)$ 给出一个链接 l_j 是被从提供集 O_f 中选中。

$$I(A \mid LH, l_j) = H(A \mid LH) - H(A \mid LH, l_j) \qquad \text{（式 5.6）}$$

式 5.6 中 $H(A|LH)$是先前配置属性中用户点击一个有效提供集中的链接的熵。$H(A|LH,l_j)$是配置分配剩下的链接 l_j 在提供集中被选中的熵。之前的熵计算为：

$$H(A \mid LH) = \sum_{a_i \in A} P(a_i \mid LH) \log_2 P(a_i \mid LH) \qquad \text{（式 5.7）}$$

中国知网 https://www.cnki.net

第二个嫡是如果用户点击一个链接 l_j 被获取是基于信任度修正作为式 5.1 时写为：

$$H(A|LH,l_j)=\sum_{a_i\in A}P(a_i|LH,l_j)\log_2 P(a_i|LH,l_j) \quad \text{（式 5.8）}$$

下一步，我们需要评估一个用户通过用历史链接 LH 点击已给出的提供集 O_f 中的链接 l_j。各个概率是通过用期望概率计算出来的：

$$P(l_j|LH)=\sum_{a_i\in A}P(l_j|a_i,LH)P(a_i|LH) \quad \text{（式 5.9）}$$

基于条件独立假设，这个表达式简化为：

$$P(l_j|LH)=\sum_{a_i\in A}P(l_j|a_i)\log_2 P(a_i|LH) \quad \text{（式 5.10）}$$

最后这个提供集 O_f 预期信息增益是通过使用预期信息增益说服所有提供集中的链接，例如：

$$EI(A|LH)=\sum_{l_j\in O_f}P(l_j|LH)I(A|LH,l_j) \quad \text{（式 5.11）}$$

5.2 用户模型

5.2.1 用户建模

1) 建模系统流程

每个用户的数据主要包括：用户自身的基本信息（出生年月日，性别，籍贯等注册信息），还有用户发表的博文分类，以及用户自己设置的喜欢的标签，还有用户在阅读其他博客的行为记录和阅读记录等。在用户建模中分为用户模型的建立和用户模型的更新。在初始化阶段（用户刚刚进入该博客站点的时候，是没有任何关于该用户的信息，因此需要在用户注册成功根据初始数据给用户建立模型），随着用户使用站点的时间越来越长，掌握用户的历史数据越来越多，分析用户兴趣趋向会越来越全面，对用户的兴趣把握越来越准确，此时更新用户模型就比较准确。具体步骤如下：

第一步，给用户提供注册接口，收集用户的基本信息（出生年月、性别、爱好、职业等），对用户发表的博客文章进行跟踪，收集用户发表博文的分类，以及喜欢的关键词、标签等，这些都能反映用户的兴趣。

第二步，兴趣提取。根据用户的注册信息可以判断用户的一些基本特性（例如，根据用户的职业，可以判断用户可能关注的博客类别；根据用户的年龄，也可以发现用户是关注娱乐多还是时政新闻多），然后再根据用户发表博客的特点分析用户的初始兴趣；同时对用户阅读的博文的记录分析，发现用户可能关注的博客类别。通过这

中国知网 https://www.cnki.net

些方面的分析就可以提取出用户的兴趣。

第三步，用户建模。根据提取出的用户兴趣生成用户的兴趣模型，包括用户的长期兴趣和短期兴趣。长期兴趣反映了用户比较稳定的兴趣爱好，而短期则是用户在某一段时间内关注的兴趣。由于用户的兴趣也会不断变化的，用户在成长的过程中会对不同领域的关心程度也会发生变化，这些都可以通过用户发表的文章上和阅读的博文中反映出来。

第四步，模型更新，在用户兴趣模型形成后，会对用户的兴趣分为长期兴趣和短期兴趣，这些都会遵循人类记忆的自然遗忘规律，随着时间的推移部分兴趣热度会不断的衰减，也会有新的用户感兴趣的内容添加进来。因此，要不断的检测与分析用户模型和用户反馈记录，及时发现用户兴趣的变化，调整用户的长期兴趣与短期兴趣之间的转换，更新用户模型，做到能实时跟用户的兴趣保持一致。

2) 用户模型系统功能模块介绍

在个性化建模系统中的功能有：信息收集、兴趣提取、日志记录、日志分析、模型更新。

信息收集功能：有关用户的各种信息的收集（例如用户的注册信息，用户发表博客信息，用户收藏博客信息，用户阅读博客信息），收集到用户的各方面信息有助于分析用户的兴趣准确性，收集用户的各种操作信息越全面对用户兴趣提取帮助就越大。信息收集是关键的一部分。

兴趣提取：对收集到的用户信息中提取用户的兴趣，例如用户注册时填写的喜欢的标签，用户收藏的博客类别，用户发表的博客属于的类别，用户经常阅读的博客类别。

日志记录：日志记录中有总体站点的访问日志和每个用户各自的访问日志。用户在站点阅读博客的过程中，系统会记录用户的行为，以及用户阅读的博客内容，阅读的时间。这些记录也会对分析用户的兴趣很有帮助。

日志分析：对整个站点的日志分析，可以统计出每篇博客的访问量（受欢迎度），对每个用户的日志分析，可以分析出用户的行为对系统推荐的效果反映情况。

模型更新：综合日志分析，以及用户信息收集后的兴趣提取，对用户的兴趣进行更新，更新时要分为用户的长期兴趣和短期兴趣来更新，这样就能把握用户最近的兴趣点和长期稳定关注的博客类别。

3) 用户模型表示

用户模型的表示也关系到系统的推荐效率。本文采用向量空间模型来表示，其中包括长期兴趣和短期兴趣的表示。向量空间模型是将用户模型表示成一个二维特征向量$\{(c_1,, w_1),(c_2, w_2),\cdots,(c_n, w_n)\}$，每一维表示一个兴趣类型及其兴趣值。本文的用户模型在逻辑上形成一个以用户为根结点的树形，如图 5.1 所示。

中国知网 https://www.cnki.net

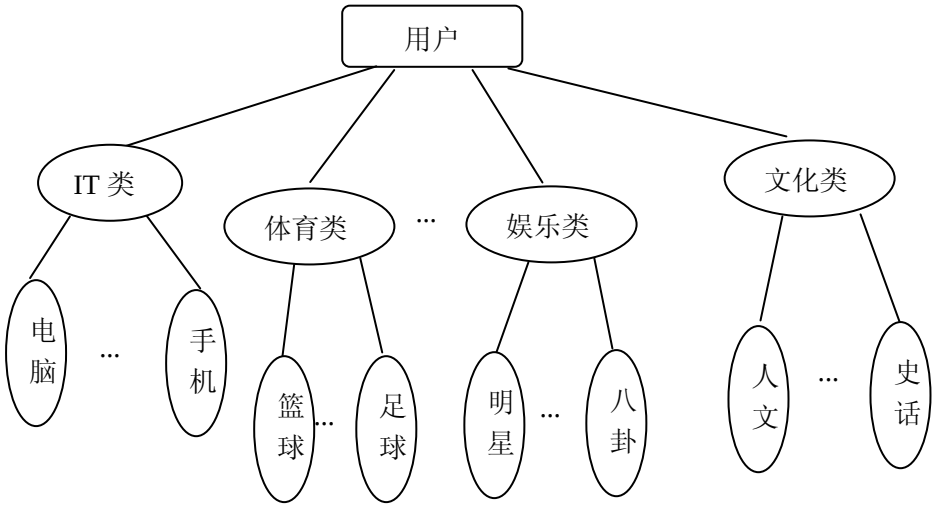

图 5.1　用户模型表示图

由于用户的兴趣是在不断变化的，因此需要跟踪用户的兴趣变化趋势，就在用户的兴趣上建立时间戳，这样就能跟踪用户兴趣的变化时间，从而能从中总结出用户的兴趣变化规律，能预测到兴趣的变化趋势，加时间戳的用户模型如图 5.2 所示。

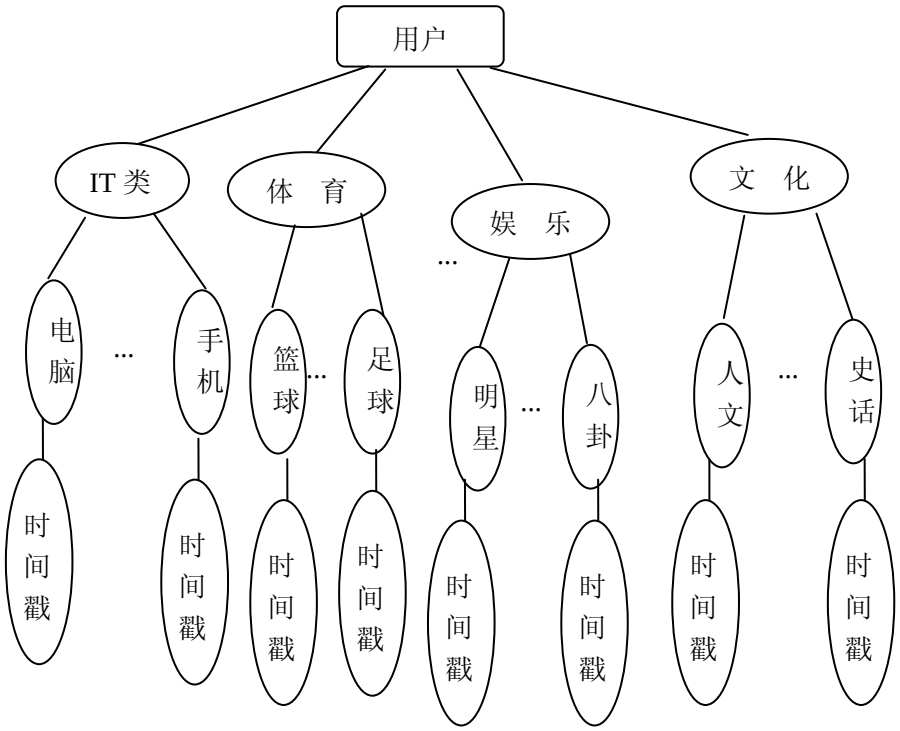

图 5.2　用户模型加时间戳表示图

5.2.2 导航记录学习策略

学习用户的行为包括有一般学习用户点击链接的行为，在该页面停留的时间，用户关注该页面的哪个部分，用户是否进行分享、收藏或评论等。站点在每次用户的交

中国知网　https://www.cnki.net

互过程中从用户的导航记录和行为中学习和修改配置属性（在有效的链接上点击）。在用户浏览网页时所发生的动作，包括浏览时点击鼠标，拖动滚动条，收藏，前进，后退等，这些都能反映用户对某个页面感兴趣的程度。简单的说，用户仅仅浏览了几秒的网页，我们可能认为用户对它是不感兴趣的，而如果用户加入了收藏夹的网页，用户很可能是会感兴趣的，这些动作都需要在客户端的浏览器上完成，因此我们要监控用户的动作，异步交互的保存用户的动作行为。

用户的行为会以文件的方式被服务器记录下来，下面我们就通过反馈的记录学习用户的行为，从中了解用户的兴趣变化。从导航记录中，我们可以学习到用户阅读过哪些博文，分析出用户阅读的方式。

定义 1：如果用户阅读的是系统推荐的博客，又继续阅读系统推荐的相关博客，则推荐的博客符合用户的需求，可以保持推荐效果。

定义 2：如果用户阅读的是系统未推荐的博客，又继续阅读的还是系统未推荐的博客，则建立跟踪点。

定义 2 的方式说明该类可能是用户的临时兴趣或用户的新兴趣或者其它可能，因此要建立跟踪点，把该兴趣作为临时兴趣，通过一段时间的跟踪，发现用户若没有继续关注该类博客，则可以取消跟踪，不做用户模型变化，并从临时兴趣中删除；若用户关注该类的博客次数在不断增加，则表用户是感兴趣的，可以考虑加入用户模型中，经过计算赋予一定兴趣值。

定义 3：如果用户阅读的是系统推荐的博客，继续阅读的是系统未推荐的博客，则建立跟踪点，并加强分析反馈记录。

定义 3 方式可能是用户在推荐的基础上，看到该博主的其他相关的博文也很感兴趣，说明用户对该博主的其他方面是非常有兴趣的，建立跟踪点，需要加强分析反馈记录，更新用户模型。

一般在系统中每个栏目都有系统推荐的博客标题和未推荐的，或者用户通过搜索找到系统没有给推荐的博客，在博客页面的侧栏也会有系统推荐的和未推荐的博客，这些栏目的设定就是要让用户发生行为后，分析他们的行为来知道推荐的结果是否达到效果。

用户的日记记录里会记录用户阅读时间、博客来源、是否是推荐的博客、博客编号、博客类型等相关信息。通过阅读时间来判断是否是同一时间段内内阅读的博客；通过博客来源查看是否是从同一个站点阅读的；查看是否是推荐的博客，来判断用户阅读的途径。这样通过上下条数据的比对，来分析临近阅读的博客是否有关联。

5.2.3 用户模型更新

用户的兴趣是通过阅读文章反映出来的，一旦兴趣产生后，并非一成不变的，往

中国知网 https://www.cnki.net

往大多数的人们都会关注一些社会焦点事件或个人原因引起的在短期内兴趣的重点转移，比如，田思嘉事件等，这个用自己的生命献身国家消防事业的年轻小伙子，在最近一周被受关注，各大电视台报道，各大视频网站转载，以及 SNS 社区也在传扬他的精神，在此时我们是很感动的，听到此事都会去看看这是一个什么样的英雄事迹。但一个月后，一年后那，这样的短暂的事件对整个社会来说，可能大多数人都会遗忘掉曾经关注过的事情，因为社会中发生的大事件太多，这些都是在短期内对用户的情感或心理产生了共鸣。因此，对于这样的关注，就应该是短期兴趣的，过了一段时期后或事件结束后，用户对这些兴趣的兴趣度下降，我们也将降低或删除该兴趣。当然有些短期兴趣可能会随着用户的关注变成用户的长期兴趣。例如，一些 IT 类的博客，用户通过博客逐渐熟悉掌握一门技术后，用户就会时常的关注该技术的发展，也会发表自己的使用心得等，这些会跟自己真正的兴趣或所从事的工作有关，这些都会成为长期兴趣。

因此，在用户模型系统中要掌握短期兴趣的变化，就要辨别哪些是属于短期兴趣，要在用户模型中建立一个反应用户较短时间内关注的兴趣状态跟踪器。具体实现为，设定时间最小值和最大值，以及阅读文章数目的最小值和最大值。若用户在时间段内阅读的该类型文章数目已达到跟踪兴趣的值，则取用户在时间段内为短期兴趣；若用户在某一时间段内发表的某类型的博客数目达到跟踪兴趣值，则也要转换为短期兴趣。在加入短期兴趣后，要继续跟进该兴趣用户的变化，若用户越来越少的关注该类型的博客的时候，该兴趣就要慢慢的降低兴趣值了；若用户维持一定量的阅读，并且会发表一些该方面的博客，则该兴趣需要考虑进入长期兴趣中。由于短期兴趣的变化很多，我们需要使用一个衰减算法来判定是否需要改变兴趣或兴趣状态。

通过兴趣衰减把兴趣集合中的时间戳转换成衰减指数，通过公式 5.12 所示。

$$C = 1 \Big/ e^{D/K} \qquad \text{（式 5.12）}$$

其中 D 为日期差值，D 越大表明阅读时间越早，C 就越小，反之 C 就越大。对于当天的取 D=0。K 为选择的常数，其值是大于 1，K 值越大，衰减速度就越小。

短期兴趣是用户最近关注的兴趣为主，它变化也快，不稳定。但短期兴趣中有些会随着用户的不断深入了解，也会转变为长期兴趣。因此长期兴趣是在短期的基础上构造的，长期兴趣存储了用户较稳定的、主要的兴趣。这样就可以更好的描述用户的兴趣特征，这是用户兴趣的主线。

短期兴趣以用户当前的兴趣为主，兴趣趋向变化较快，但短期兴趣也会转变为用户的长期兴趣，比如用户喜欢上一个明星后，成为他的粉丝，可能以后就会关注的越来越多，逐渐的成为用户长期的兴趣。

中国知网 https://www.cnki.net

5.3 启发式推荐方法

5.3.1 启发式推荐方法

在目前大多数站点中页面数量是巨大的，组合的提供集数量也是巨大的，去评估这些提供集是个很大的工程。查找最佳提供集是很困难的。因此，我们要识别一些链接的特性使他们包含在合适的提供集中，这些特性用来研究一个启发式方法。该方法是在构造提供集时利用链接属性概率和链接受欢迎度来寻找最佳链接集。

算法：

输入：把链接集合中的博客根据条件筛选出有效的链接组成候选链接集，提供集的基数为 n，类预设值 $P(a_i)$，用户模型中的兴趣分类值。

(1) 根据用户的兴趣分类，对相应每个属性类，找出链接属性值 $P(a_i|l_j)$大于类预设值 $P(a_i)$的链接，把这些链接按照类的属性值降序排序。

(2) if：没有链接在最优链接集中：

(a) 把排列在前面的链接直接添加到最优链接集中。

else：有链接在链接集中：

(b) 在每个属性类，计算链接受欢迎程度 $P(l_j)$在最优链接集的和。

(c) 判断类中链接受欢迎度最小的。

(d) 把类排序列表前面的链接添加到最优链接集中。

end if

(3) 移出已从类排序列表添加到最优链接集的链接。如果一个链接在多个列表出现，就把他从所有含有这个链接的列表中删除。

(4) 重复第 2 步和第三步直到 n 个链接被选中。

(5) 用户阅读博客，按照学习机制判断用户的阅读方式：

if：定义 1，则对该用户推荐保持不变；

else if：定义 2，建立跟踪点，并添加到临时兴趣中；

else if：定义 3，建立跟踪点，并添加到临时兴趣中；

end if

(6) 分析用户反馈记录，若有跟踪点，则对跟踪点进行判断是否是用户持续关注的。

if：用户持续关注，则添加到用户短期兴趣中；

else：用户关注很少，则可以放弃跟踪，从临时兴趣中删除；

end if

(7) 根据分析结果对用户模型更新，可以是用户长期兴趣和短期兴趣的转换，并更新相应的兴趣值。

中国知网 https://www.cnki.net

(8) 重新进行推荐。

该链接是每个类的排序列表的前面的高属性值链接。一些链接，如果用户点击，将很可能增加用户属于该类的概率。因为一个用户很可能点击一个链接喜欢相同类的其它链接，这个方法允许自适应学习用户的配置属性。在每次交互中，这个算法添加到提供集中的链接都有最大的配置属性，也要保证链接的概率增强每个类被点击尽可能的平衡。

在候选链接集合形成过程中的判断条件有很多，例如发布一段时间访问量极低的博客，博客分类值低于预设值的博客等。当然新发布的博客文章是没有受欢迎度的，这在系统中会考虑在一段时间内发布的博客都会进入候选集合中。

推荐基数的选择是根据不同的页面调整的，因为在不同页面布局下面，用户关注的内容是有限的，要把最优的展现给用户。因此调整基数数目是必须的。

推荐结果展现给用户后，用户在做出使用什么样的阅读方式进行阅读，这需要根据阅读策略来判定对用户的影响，用户发生的行为通过反馈处理机制来学习分析用户的需求变化。

5.3.2 有效链接集的形成

为了提高推荐的效率，需要把无效的链接根据条件去除，组成一个有效的链接集合。条件的设定是关键，例如我们设定每类博客的分类值最低为 0.1，受欢迎度最低为 0.1 等，当然在新发布的博客文章是没有受欢迎度的，这在系统中会考虑在一周内发布的博客都会进入候选集合中。无用的链接包括用户已删除的博客，但标题还存在；发布一段时间访问量极低的博客；博客分类值低于预设值的博客等。在候选博客集中除了大于预设值的博客，还需要包括当前热门话题的有关博客。有效链接集形成过程如图 5.3 所示。

5.3.3 推荐基数调整

推荐的数目也由用户来定，用户设定推荐的数目后，系统就会根据设定的个数推荐出该数目的博客链接。推荐博客的数目不同也关系到推荐结果是否全面，在实验中我们实验了不同的推荐数目下的推荐结果，收集用户的反馈情况，发现在不同的页面下推荐数目也是需要调整的。比如，在首页系统要展示的栏目有很多，页面的大小是有限的，因此只需要把用户最感兴趣的推荐出来就可以；若在用户阅读某篇博客中，在侧栏中的推荐就是要跟该篇博客有关联的，推荐的结果就会稍微多一点，这样如果用户感兴趣就会从中选择更多相关内容查看。

中国知网 https://www.cnki.net

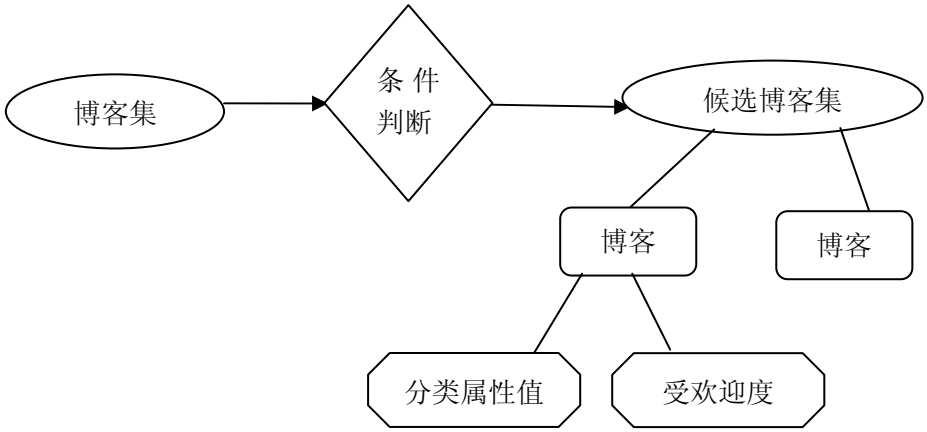

图 5.3　有效链集接形成图

5.3.4 用户接口设计

用户接口来为系统提供展示结果的，接口可以使用多种格式来展示，可以使用不同的字体或样式展现推荐结果，吸引用户的眼球。用户接口可以以多种方式展示，包括 HTML 列表格式，XML 格式等。

5.4 本章小结

本章对提出的启发式推荐方法进行详细的分析，先对使用到的贝叶斯信任度修正法进行分析如何修正用户模型的，然后对用户反馈分析方法中的用户模型建模过程和用户模型的表示以及如何自适应的学习用户模型，在学习用户模型的过程中把用户的兴趣分为长期兴趣和短期兴趣更新到用户模型中。最后对启发式推荐算法进行深入分析，对启发式方法中的有效链接形成过程、推荐基数的设计和用户接口的设计进行详细阐述。

中国知网　https://www.cnki.net

6 实验设计与分析

6.1 推荐系统实验设计

6.1.1 博客个性化推荐系统总体架构

在系统的总体框架上，博客个性化推荐系统可以分为用户个性化建模系统和个性化推荐系统和数据处理系统。其中个性化建模系统的功能是根据用户的阅读行为以及用户发表博客的习惯与趋势等情况，通过分析收集的用户信息得到用户的兴趣点，然后更新用户模型；根据用户的兴趣与博客信息匹配下推荐用户可能最感兴趣的博客；数据处理系统是对抓取的博客信息进行深加工处理，分析并挖掘博文的特点与特性，对博文进行分类，和统计博文的受欢迎度等。

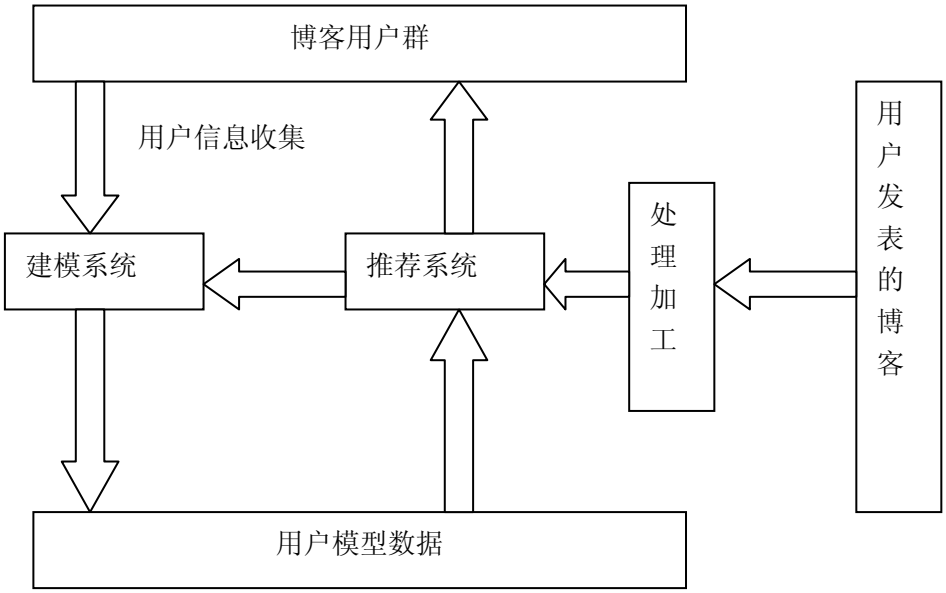

图 6.1　博客个性化服务系统的总体架构图

从图 6.1 中可以看出博客个性化推荐系统主要是依据用户的兴趣模型的建立，通过各种推荐技术寻找与用户兴趣相匹配的资源，然后推荐给用户。针对用户的各种需求要做出不同的推荐效果，因此自适应的推荐关键，在自适应的过程中把握用户的兴趣是最为关键的。

由此可见，用户模型是推荐系统中的主要知识源，用户兴趣捕捉的正确与否，用户模型建立与更新结构是否反映了用户需求的真实性，直接决定个性化推荐服务系统的质量，因此用户模型是整个系统的核心。本章以下内容主要集中介绍博客用户的个性化推荐系统的设计与实现，以及各模块中涉及到的主要功能方法。

中国知网 https://www.cnki.net

6.1.2 博客个性化推荐系统功能模块

个性化推荐系统中三个大模块下会有具体的功能模块来处理相应的问题，具体模块如图 6.2 所示：

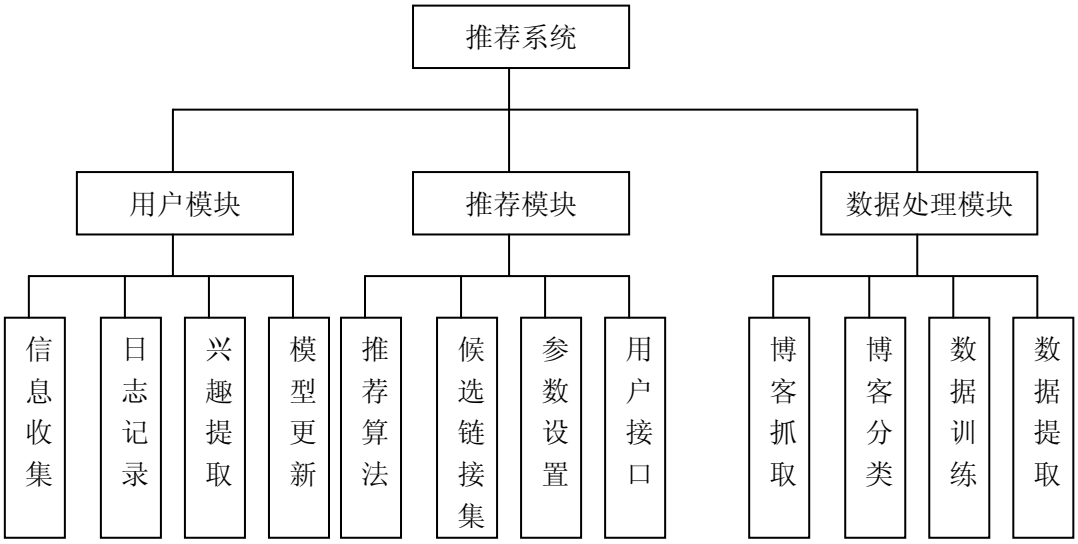

图 6.2　博客个性化推荐模块图

建模系统需要收集用户的信息，要记录用户的行为及访问的记录，通过收集的信息分析要提取出用户的兴趣，分成长期和短期兴趣，最后更新相应的兴趣。

推荐模块主要是实现推荐算法，在参数设置里设置推荐的基础参数，比如候选链接集的筛选条件，推荐的博客数目。候选链接集的链接有效性关系到推荐结果的好坏，推荐算法关系到系统推荐的效率与结果的准确行，最后在用户接口中呈现给用户可以使用多种方式展现。

该模块是实现推荐算法，根据用户模型与博客数据的匹配结果，并展现给用户。在该过程中需要对博客链接集进行筛选，即根据系统设定的条件从博客链接集合中选出有效的博客组成有效候选链接集合；还要设置推荐的基数，这样在不同的页面下推荐的结果数目也不同。本文设计的推荐算法使用了每个链接的分类属性值和受欢迎度值，考虑到用户兴趣适应性，也为了照顾到各兴趣间的平衡，使用启发式的方法提供最佳提供集。

数据处理是从互联网抓取博客到本地，然后通过本地的处理方法，从抓取下来的博客的相关信息中加工出博客的分类，以及统计出博客的受欢迎度，为推荐做准备。

6.1.3 界面设计

根据推荐方案设计，在使用界面进行操作的时候，需要输入用户昵称及需要推荐

中国知网 https://www.cnki.net

的博客数量，在推荐出结果后，用户可以选择阅读一篇博客，在阅读之后可以进行收藏、评论、标记等操作，这些动作会保存到历史记录中。界面设计中有两个输出界面的文本域，第一个文本域用来保存进入推荐系统时的推荐结果，在用户阅读完一篇博客后会自动重新推荐结果，可以多次阅读博客，在阅读过程中第一个文本域会自动保存第二个文本域的推荐结果，这样就能比较两次相近的推荐结果。两个文本域中显示的信息有博客编号、博客类别、博客名称，布局的功能按钮有推荐、阅读、收藏、评论、标记按钮，界面使用流程如图 6.3 所示，界面设计如图 6.4 所示。

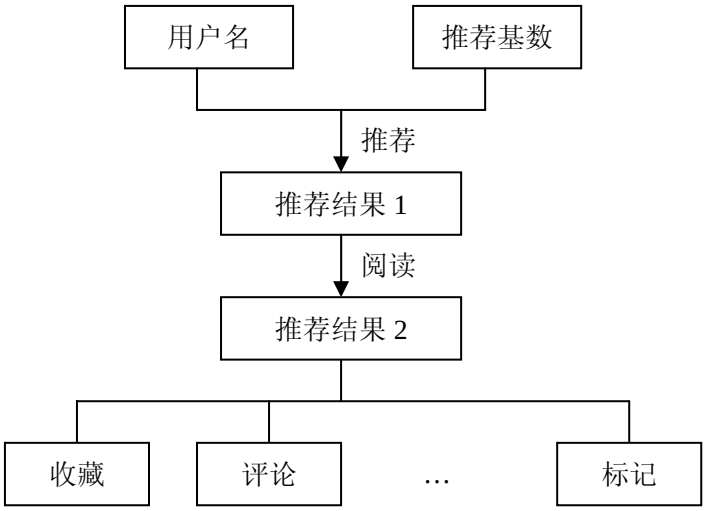

图 6.3　推荐界面使用流程图

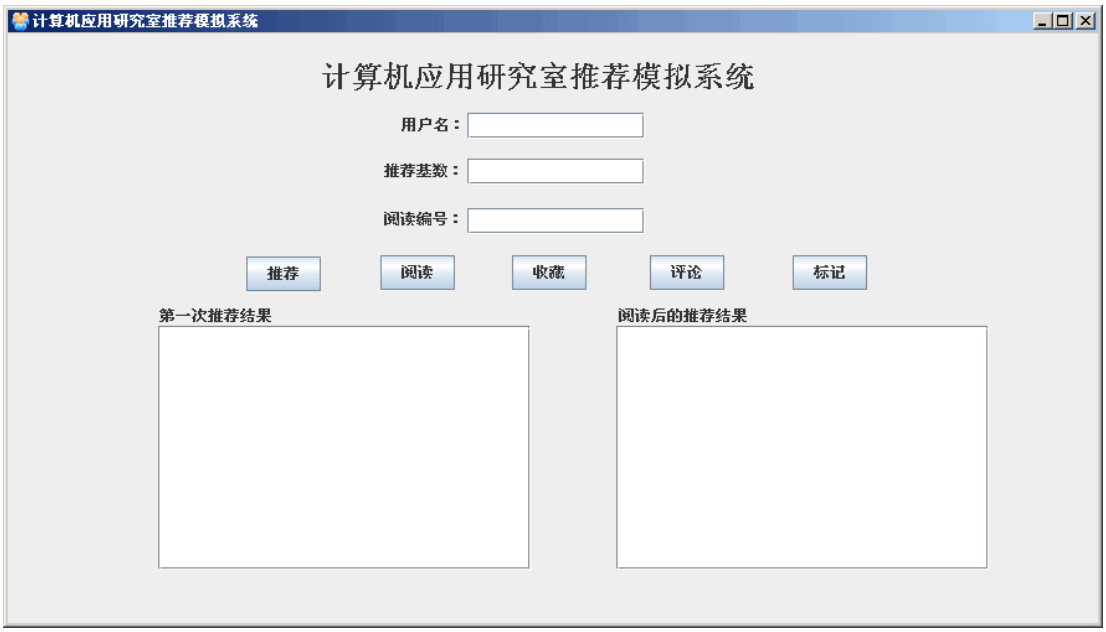

图 6.4　推荐系统界面图

中国知网　https://www.cnki.net

6.1.4 用户模型模块

用户模块中要读取用户的配置文件，同时也要更新用户的配置文件，因此涉及到文件的读写操作，文件的读方法流程图如图 6.5 所示。

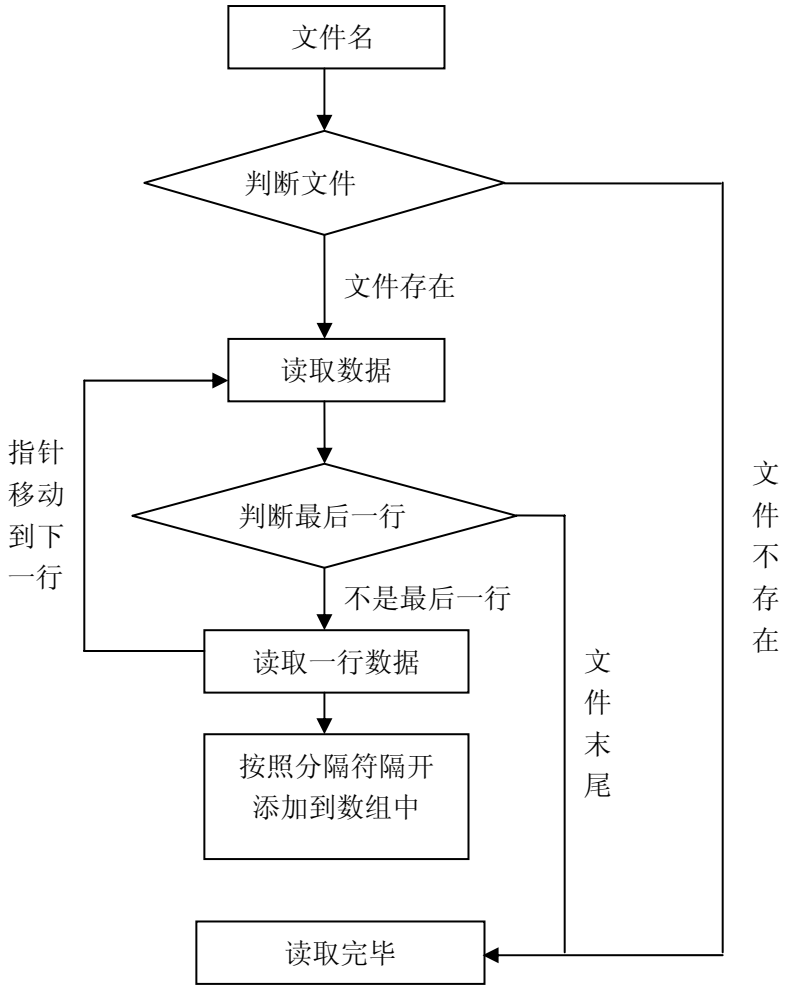

图 6.5 读取文件流程图

通过上述的读取方法可以快速的读取文本文件中的信息，并且在读取的过程中会以每行数据为一条数据来划分，在每行数据中有多个类型的数据，比如在图 6.6 中的博客数据，在读取该文本时，每行数据都有 4 类信息，包括（博客编号、博客大类编号、博客所属子类的概率、博客标题）每类信息中间用空格隔开，在博客所属子类的概率可能有多个，因此用逗号隔开，在循环的过程中使用隔开符号来判断每类属性的顺序。例如图 6.6 中的第一条数据，先根据空格隔开形成一个元素为 4 个的一维数组(设为 A)，A[0]=1,A[1]=1,A[3]=“错价门一审判决：没有胜负可言”，而 A[2]的元素中是该博客的多个属性，因此要把分类值根据逗号隔开形成一个子数组，因此 A[2]会成为一个元素为 6 个的二维数组（设为 B），其中 B[0][0]=4，B[0][1]=0.2，B[1][0]=5，

中国知网 https://www.cnki.net

B[1][1]=0.3，B[2][0]=9，B[2][1]=0.5，这样 A[2]=B,A[2]元素是个二维数组。

图 6.6　博客数据图

在用户模型中需要写文件，例如把用户反馈记录写入文件保存，用户导航记录写入文件保存，更新用户模型文件。写操作方法如图 6.7 所示。

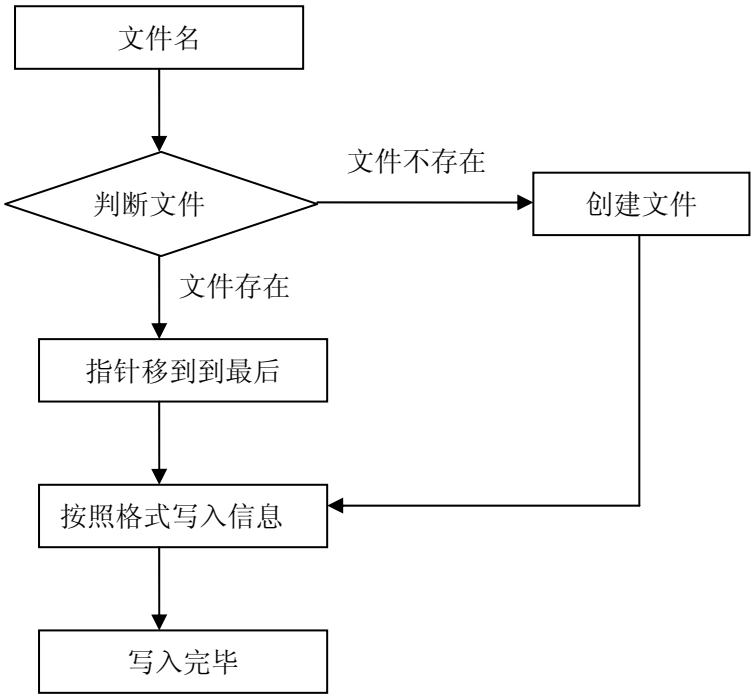

图 6.7　写入方法流程图

写入文件的时候都需要按照一定的格式写入，不同功能的文件使用的格式不一样，例如历史记录文件图如图 6.8 所示，在该文件中使用逗号来隔开每项内容，博客编号、博客类型，阅读时间，阅读用户昵称。

中国知网 https://www.cnki.net

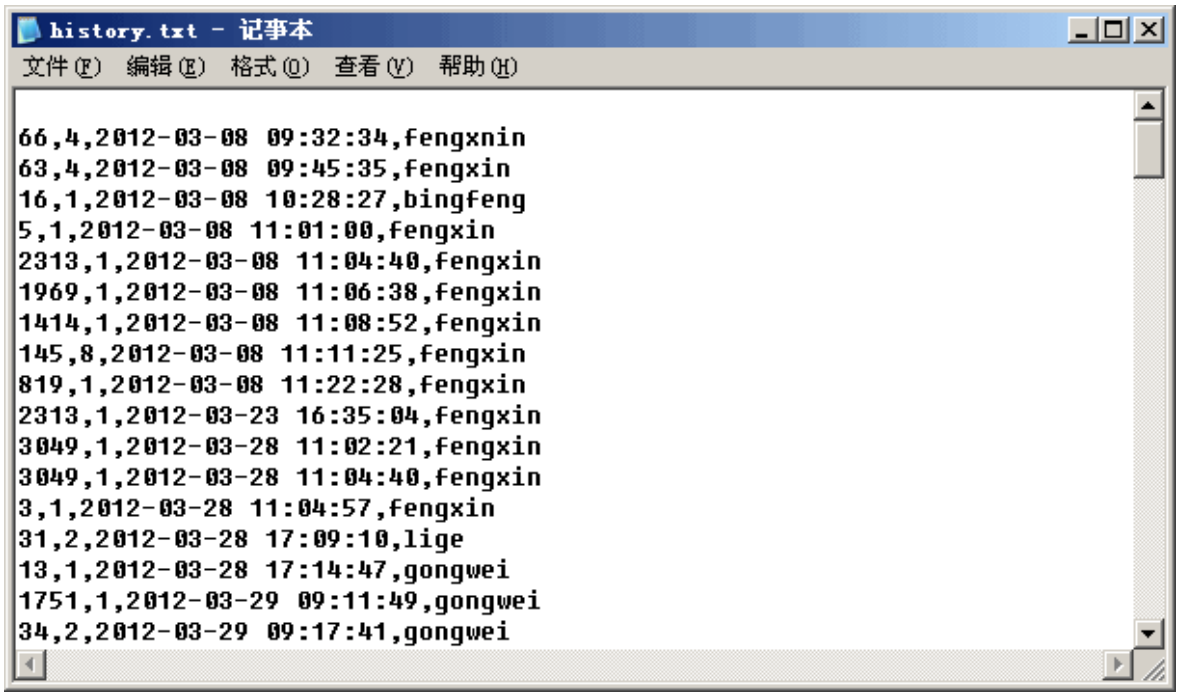

history.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
66,4,2012-03-08 09:32:34,fengxnin
63,4,2012-03-08 09:45:35,fengxin
16,1,2012-03-08 10:28:27,bingfeng
5,1,2012-03-08 11:01:00,fengxin
2313,1,2012-03-08 11:04:40,fengxin
1969,1,2012-03-08 11:06:38,fengxin
1414,1,2012-03-08 11:08:52,fengxin
145,8,2012-03-08 11:11:25,fengxin
819,1,2012-03-08 11:22:28,fengxin
2313,1,2012-03-23 16:35:04,fengxin
3049,1,2012-03-28 11:02:21,fengxin
3049,1,2012-03-28 11:04:40,fengxin
3,1,2012-03-28 11:04:57,fengxin
31,2,2012-03-28 17:09:10,lige
13,1,2012-03-28 17:14:47,gongwei
1751,1,2012-03-29 09:11:49,gongwei
34,2,2012-03-29 09:17:41,gongwei
```

图 6.8　历史记录图

6.1.5 推荐功能模块

推荐系统模块主要实现推荐功能，根据用户模型和筛选过的有效率链接博客集作为主要参数，然后输入推荐博客的基数，进行推荐。

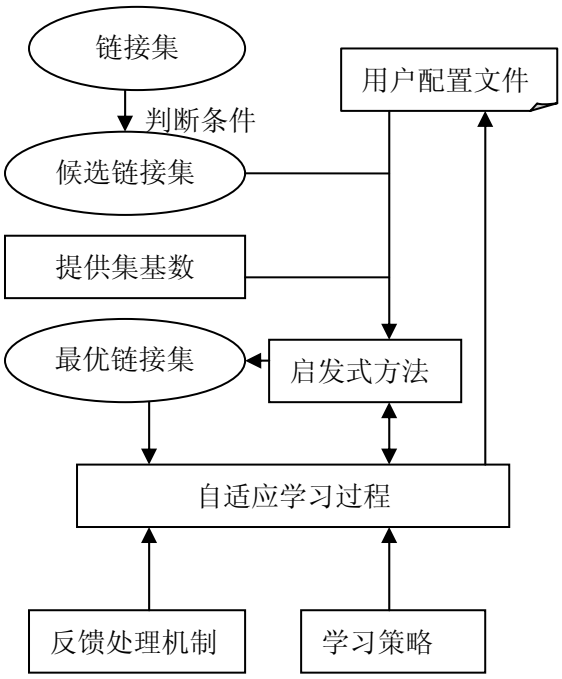

图 6.9　推荐过程流程图

中国知网 https://www.cnki.net

在图 6.9 中，我们可以看到除了上述的条件外，还需要在推荐的过程中自适应学习的过程，在该过程是使用反馈处理机制来处理用户的反馈信息，使用学习策略来判断用户的阅读方式。自适应处理过程会不断的更新用户模型的兴趣，也就是不断对用户兴趣的长期兴趣和短期兴趣进行更新，为用户推荐能及时准确的推荐。

在使用用户界面进行推荐时，需要先输入用户名和推荐基数，点击推荐后会在第一个文本域中显示显示推荐的结果，如图 6.10 所示。

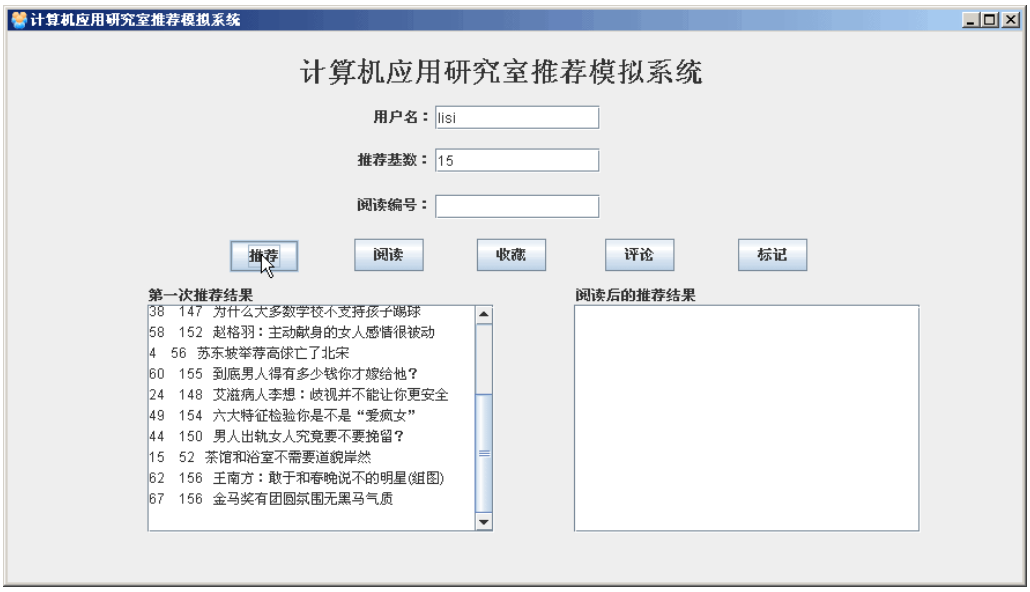

图 6.10　初次推荐结果图

在显示的推荐结果中用户 lisi 选择一篇博客进行阅读，在阅读编号文本框中输入一个编号，会显示一个阅读后的推荐结果，会推荐出相关的博客。

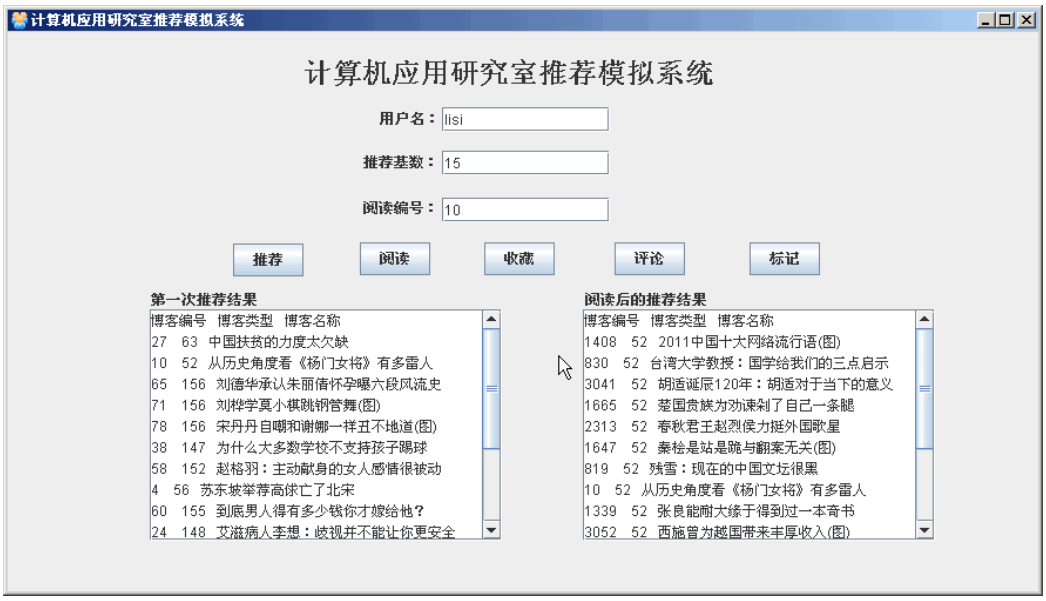

图 6.11　阅读博客推荐图

中国知网 https://www.cnki.net

6.2 实验数据

6.2.1 实验数据来源

该系统的实验数据是从互联网上抓取到本地后，经过与处理后再应用的。

数据抓取网站：新浪博客网站。

数据抓取特点：通过对新浪博客页面的结构分析，找到需要抓取部分的结构标签标识。

数据数量：21 个博客分类，抓取 3000 多篇博客。

抓取深度：1 层深度。

数据处理：从设定的 URL 链接列表中抓取新浪博客，把博客的标题、发表时间、标签、分类、正文、收藏次数、评论次数抓取下来并保存到数据库中。在存储基本信息的同时，要对每篇博客的关键词进行提取。

抓取指定的 URL 列表为，如图 6.12 所示。

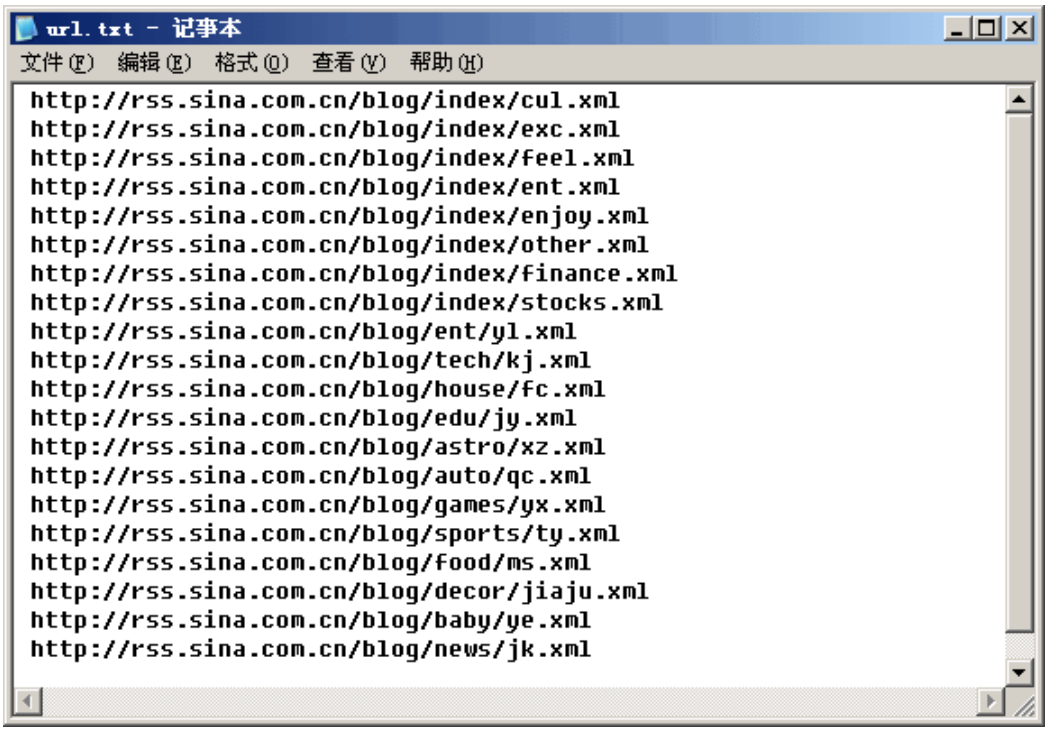

图 6.12　抓取 URL 列表图

图 6.12 中每个链接都是一组博客列表，这些都是新浪博客网站的 RSS，新浪会每天更新 RSS 列表，因此我每天都运行抓取程序，都可以从以上的 URL 中抓取下不同的博客。在关键词库中的关键词是从抓取博客的同时，会检测该博客的标签或分类是否在词库中存在，若不存在则自动添加到词库中。关键词库如图 6.13 所示。

中国知网 https://www.cnki.net

	id	typeName	parentId
1	1	文化	0
2	2	独家	0
3	3	情感	0
4	4	八卦	0
5	5	生活	0
6	6	观点	0
7	7	财经	0
8	8	股票	0
9	9	娱乐	0
10	10	女性	0
11	11	科技	0

图 6.13　关键词库图

6.2.2 抓取程序设计

在抓取程序中，要指定启动程序的输入参数为 URL 的文本文件，然后程序会把文件中的 URL 列表读取到内存中，程序再依次通过读取每个 URL 链接，在 URL 链接的 XML 中会有博客列表，如图 6.14 所示，程序再依次读取每个博客信息及博客的原始地址，程序会先判断该博客在数据库中是否存在，若存在则读取下一条博客信息；若不存在，则程序找到博客原始地址后，跳转到原始地址并打开读取该页面内容。我们知道每个页面都是由 HTML 标签组成的，我们分析了新浪博客的结构，从结构中找到我们想要摘取内容的标签，然后读取其中的内容保存到临时变量中。这样把整篇博客的信息都提取完毕后，就把所有信息保存到数据库。在 URL 列表读取完毕后，抓取程序结果。具体流程图如图 6.15 所示。

图 6.14　新浪博客列表

中国知网 https://www.cnki.net

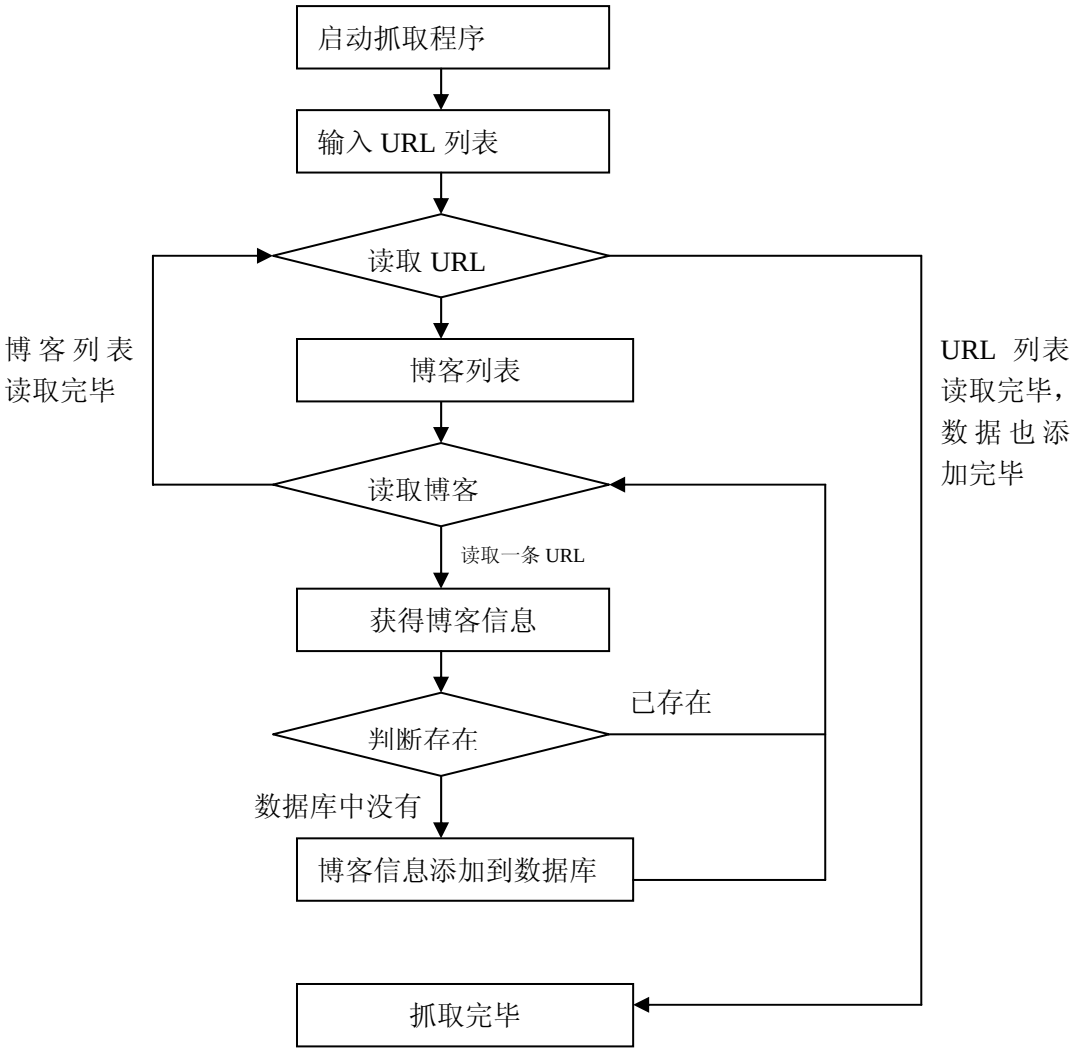

图 6.15　博客抓取流程图

从博客页面抽取出来的信息都保存到数据库中，抓取的博客结果如图 6.16 所示。

	id	title	blogTypeId	pubDate	author	link
1	1	谁在守护博物馆里的中国国宝	1	2011-12-01 13:21:06	雷新	http://blog.sina.com.cn/s/blog_4955e13
2	2	日本人的自杀和离婚都很认真	1	2011-12-01 12:32:19	陈希我	http://blog.sina.com.cn/s/blog_537a0507
3	3	秦可卿死于王熙凤的羞辱与假药	1	2011-12-01 10:24:05	汪宏华	http://blog.sina.com.cn/s/blog_4bb2fcdf
4	4	苏东坡举荐高俅亡了北宋	1	2011-12-01 09:03:31	关捷	http://blog.sina.com.cn/s/blog_7229194
5	5	宋太宗出身武将为何长期高薪聘人编书	1	2011-12-01 08:21:26	叶之秋	http://blog.sina.com.cn/s/blog_471bbc8
6	6	历史上从人妻到皇后的超强女人奋斗史	1	2011-12-01 00:30:03	端宏斌	http://blog.sina.com.cn/s/blog_5513b1c
7	7	民国大师轶事：蔡元培要和学生决斗	1	2011-12-01 00:12:06	路卫兵	http://blog.sina.com.cn/s/blog_5cdf43bf
8	8	梁启超如何巧施美人计	1	2011-11-30 20:31:10	刘继兴	http://blog.sina.com.cn/s/blog_48d1c5ff
9	9	春秋时期四次推让王位的圣贤(图)	1	2011-11-30 19:46:02	刘宴斌	http://blog.sina.com.cn/s/blog_6344cc0
10	10	从历史角度看《杨门女将》有多雷人	1	2011-11-30 19:43:50	凤致自己	http://blog.sina.com.cn/s/blog_49fd49bd
11	11	我的《行星撞毁说》入选地理教案	1	2011-11-30 18:12:51	陈清贫	http://blog.sina.com.cn/s/blog_57ebc67
12	12	谁是三国时期的大忽悠	1	2011-11-30 14:54:53	李治亚	http://blog.sina.com.cn/s/blog_635c86d

图 6.16　博客信息图

新浪博客的布局如图 6.17 所示，页面被分成几部分后，每部分都是一个块，每个块都有一个编号(id)来区分，因此在解析页面的时候就能通过块编号找到需要的内容。

中国知网　https://www.cnki.net

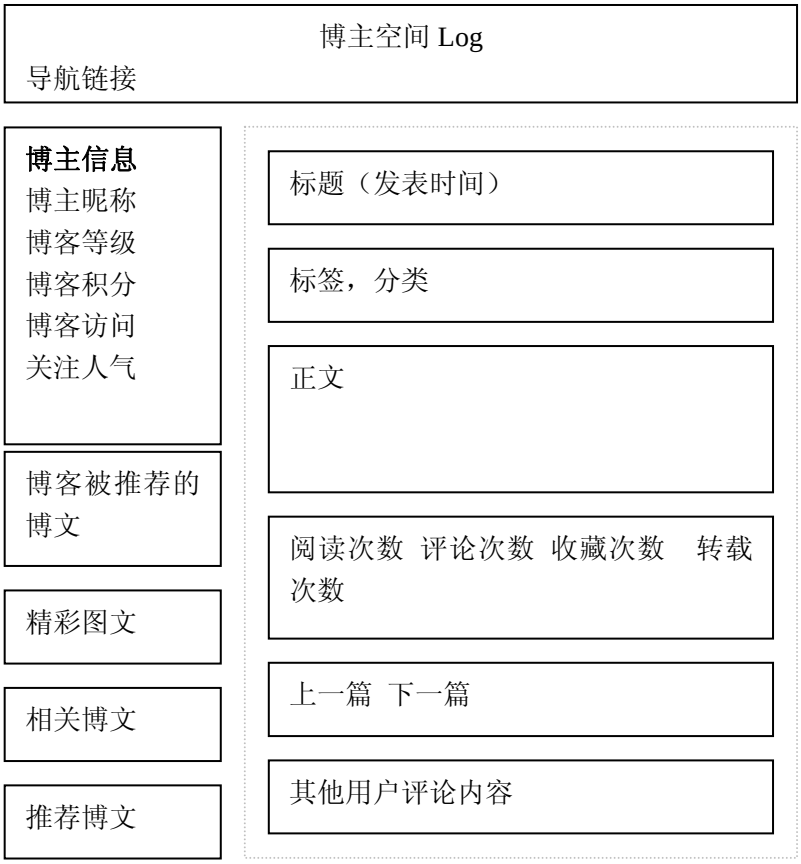

图 6.17　新浪博客页面布局

6.2.3 数据库设计

实验数据训练系统需要建立的表如下：博客信息表(blogInfo)、博客分类表(blogType)、博客用户表、博客阅读日志表(blogReadLog)、博客分类选择日志表(blogkeyWordLog)。各表间的关系如图 6.18 所示。

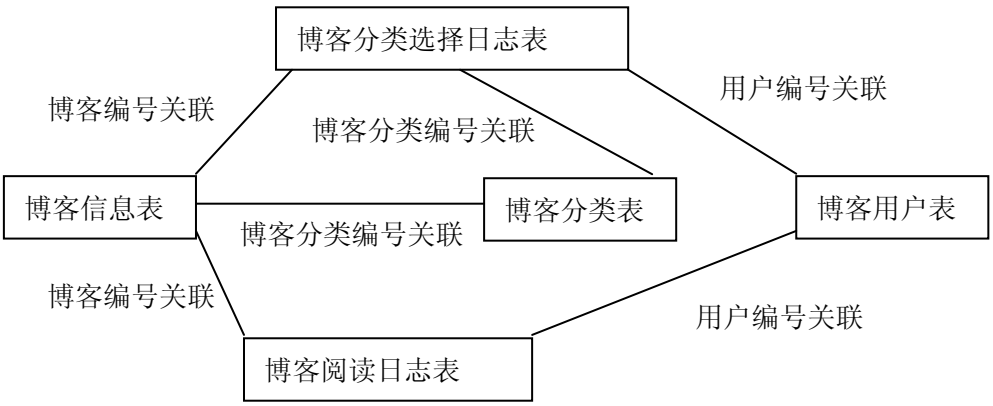

图 6.18 表关系图

博客分类表是在抓取博客的同时，系统会检测该博客所属分类是否已添加到博客分类中，若没有添加，则会相应的添加到博客分类表中；若在博客分类表中已存在，

中国知网 https://www.cnki.net

则不添加。博客分类表如表 6.1 所示。

表 6.1　博客分类表

字段名	字段类型	字段描述
id	int	编号
typeName	varchar(128)	类型名称
parented	int	父类编号

博客信息表是存储抓取的博客的基本信息，包括博客标题、博客作者、博客发表时间、博客内容、博客类别、博客原始 URL、博客作者添加的关键词。数据表如表 6.2 所示。

表 6.2　博客信息表

字段名	字段类型	字段描述
id	int	博客编号（主键）
title	nvarchar(255)	博客标题
blogTypeId	int	博客大类编号
pubDate	nvarchar(50)	博客发表日期
author	nvarchar(128)	博客作者
link	text	博客 URL
keywords	nvarchar(256)	博客作者设定的关键词
content	text	博客内容（不含标签）
mainContent	text	博客内容（含抓取标签）
readCount	int	博客阅读次数
blogValueStr	varchar(512)	博客子类属性值字符串

博客用户表是管理注册用户信息，为了系统的测试准确性，提供了注册功能，这样方便辨别每个用户的阅读记录。如表 6.3 所示。

表 6.3　博客用户表

字段名	字段类型	字段描述
id	int	编号（主键）
uid	varchar(128)	用户名
upwd	varchar(128)	用户密码
uGender	char(10)	用户性别

博客阅读日志表是记录用户阅读记录，如表 6.4 所示。

中国知网　https://www.cnki.net

表 6.4　博客阅读日志表

字段	字段类型	字段描述
blogId	int	博客编号
readDate	varchar(32)	阅读时间
uid	varchar(128)	阅读用户

博客分类选择日志表是记录用户在阅读博客后对博客分类的一个选择，系统通过收集用户的选择后，可以方便统计用户对博客的所属分类的一个统计，如表 6.5 所示。

表 6.5　博客分类日志表

字段	字段类型	字段描述
id	int	编号（主键）
blogId	int	博客编号
keywordName	varchar(128)	博客关键词名称
addDate	varchar(32)	添加的日期
uid	varchar(128)	用户

6.2.4 博客数据训练系统界面设计

博客信息保存到数据库后，需要对其进行训练，由于训练过程比较繁琐，因此建立一个训练系统，通过招募的训练人员使用系统对博客数据进行训练。训练过程主要是对每篇博客关键词的统计，以及系统为每篇博客设定的关键词是否符合用户的口味的测试，还要收集用户访问每篇博客的记录，还有用户对每篇博客的关键词的选择记录，还有用户在使用后的感受反馈，我会随即的采访他们，收集他们的感受。博客系统的登录首页如图 6.19 所示。

在系统中提供了两种方式进行测试，一种是注册登录；一种是匿名登录。前一种可以更好的明确访问用户的信息，可以准确的定位用户，了解到用户的基本信息；后一种就无法知道访问的是否是同一个用户，是否是用户的正常阅读或恶意操作。进入首页后的列表如图 6.20 所示。

这也是搜索页面，可以选择博客分类选择自己感兴趣的一类博客进行访问，你可以搜索别的用户访问过的博客，可以通过导航按钮选择上一页、下一页、首页、末页。进入博客页面后就会看到博客的所有信息，可以对博客关键词进行选择评价。关键词提交页面如图 6.21 所示。

在经过几个月的数据训练后，就可以把博客的分类属性值和受欢迎度统计出来，也要对用户的访问记录做分析，可以对用户建立初始的用户模型。这些数据都是要在

中国知网　https://www.cnki.net

推荐系统中使用的。

图 6.19　博客训练系统登录界面

图 6.20　博客列表页面

图 6.21　关键词提交页面

中国知网　https://www.cnki.net

6.3 实验分析

6.3.1 启发式推荐方法与阈值设置比较

使用提炼出的实验数据，利用 3000 多篇博客数据，启发式推荐方法（简称 AHL）与阈值设定法（简称 TSM）的准确度比较结果如图所示。其中阈值设定的相似度计算使用余弦相似性。

$$precision = \frac{\text{推荐并被阅读的博客数}}{\text{所有推荐的博客数}} \quad \text{（式 6.1）}$$

在试验中，分别采用了推荐的基数为 5、10、15、20、25、30、35、40、45、50 的博客数目，在预设链接属性值的最小过滤值为 0.1。实验结果如图 6.22 所示。

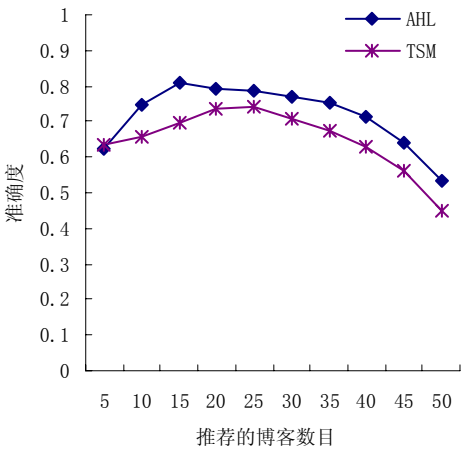

图 6.22　准确度比较

实验结果表示，在准确度中两种算法都有一个上升和下降的趋势，可见都会有一个合适的值时会出现最佳的推荐效果。在 1-15 的推荐基数下推荐的准确度是在上升，说明该推荐基数下的博客符合用户的兴趣趋势，但是在超过 15 推荐基数后由于推荐数目的增加，推荐的内容增多，推荐误差就会增大，推荐效果就越来越差。

6.3.2 推荐基数调整实验

试验中通过收集用户的在不同的基数下推荐的博客反应情况发现，开始阶段由于用户的兴趣还没有完全把握，只能推荐出较小部分的博客，但随着用户的使用，用户的兴趣情况也基本掌握的时候，推荐的博客就能满足用户的需要，当提供集的基数越来越大时，应该是更能满足用户的全面兴趣，但由于用户的视觉疲劳，一般不会翻很多页去查看后面的博客，因此基数过大的时候，推荐的效果就会减弱。图 6.23 是在

中国知网 https://www.cnki.net

假设用户兴趣已基本掌握的情况。

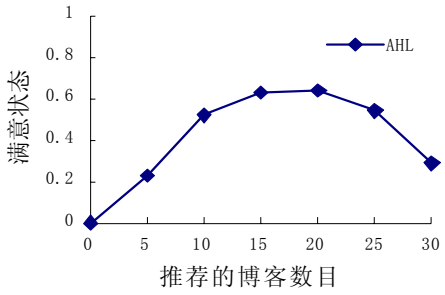

图 6.23　推荐基数调整结果图

6.4 本章小结

本章详细说明了数据的抓取和处理步骤，又设计了推荐系统的各个模块以及推荐模拟系统的界面，最后通过实验对比来验证提出方法的有效性，启发式推荐方法与阈值设定法进行对比，发现启发式推荐方法可以提高推荐的质量，最后是对基数调整的实验，这是为了适应不同页面、不同布局下对用户推荐博客的个数的最佳值设置实验。

中国知网　https://www.cnki.net

结　论

博客的发展是非常迅速的，博客市场也是很大的。目前，博客应用挖掘的还不够深，没有调用用户的积极性。现在的博客个性哈服务还不是很成熟，是的用户的整体满意度很低。本文研究目的就是根据博客所体现出的用户的个性化特点，为博客用户建立个性化的兴趣模型，并且要自适应用户的兴趣变化特点，在此基础上为不同的博客用户提供具有针对性的个性化服务。

本文首先对个性化服务中的关键技术—推荐技术、用户建模技术、日志分析技术进行了研究和探讨。系统通过收集用户隐式反馈的信息，来为用户建立用户模型。日志分析技术使用了 Web 数据挖掘，Web 数据挖掘包括 Web 内容挖掘、Web 结构挖掘和 Web 使用挖掘，本文使用 Web 内容挖掘和 Web 使用挖掘来分析用户日志，同时也提出了一种学习用户反馈的机制，按照用户的导航记录来判断用户的阅读的是否是推荐的博客。本文提出了启发式方法推荐博客，该算法中首先要形成一个有效的博客链接集，把集合的博客按照类别的分类值排序，然后根据用户的兴趣从集合中从大到小寻找，该方法能保证用户兴趣间的平衡，并能快速的推荐出一定基数的博客。

然后本文介绍了博客自适应推荐系统的总体架构，主要分为用户建模系统、推荐系统和数据处理系统。本文主要对用户建模的步骤进行详细的说明，以及在系统中的建模系统所具有的功能有信息收集、兴趣提取、日志记录、日志分析、模型更新。信息收集主要通过隐式反馈技术来收集，用户使用站点的日志记录都会以某种格式保存到服务器上，使用日志分析技术进行挖掘，发现用户的兴趣点，更新到用户模型。在本文设计的系统中使用长期兴趣和短期兴趣来自适应用户的兴趣变化，并详细的说明长期兴趣和短期兴趣间的转换关系和转换条件。然后对启发式推荐算法进行讲解，并对算法中涉及到的相关问题也做了分析，比如，有效链接集的形成，要把低于预设值得、无人访问的、已删除的等博客排除，还有推荐基数的调整，通过实验证明，不同的推荐基数对推荐的效果也是有影响的，因此在不同的地方选择合适的推荐基数也是很重要的，最后对用户接口做了分析，展现推荐结果可以有多种方式，为了提供多样化的展现方式，系统设计了不同的表示方法。

最后对系统进行了实验，首先是实验数据的抓取与处理工作，本实验采用抓取新浪博客，抓取了 21 个分类下的 3000 多篇博客，抓取的数据保存在数据库中，通过自主开发的博客数据训练系统进行数据训练，经过长达几个月的训练后，由人工处理把训练的数据进行整理，最后把数据导入系统中，进行实验，实验进行了与阈值设定的比较实验；进行了推荐基数调整实验。

博客的个性化服务的发展空间还很大，为了给用户提供更加人性化的服务，需要对用户的兴趣模型学习进行更加全面的分析，需要考虑的影响用户兴趣的因素有很

中国知网 https://www.cnki.net

多，需要更加智能化的分析用户当时的心情状态，为用户提供准确的推荐。

具体还需要改进的地方有：

1) 博客文章的考虑的参数

本文中使用博客文章的分类值和受欢迎度作为博客的属性考虑的因素还不足以能完全表示该博客，因此需要对博客的收藏数、转载次数、评论次数、评价次数等综合分析出该博客是否受欢迎。这样就可以准确把握该篇博客的特点。

2) 用户聚类

虽然是个性化推荐，但是许多用户也会有共同的爱好，对用户聚类后，可以通过大量用户的兴趣分析发现这些用户的共同特点，可以帮助分析其他用户的潜在兴趣。

3) 实验数据集

在试验中我只抓取了 3000 多篇博客作为数据集，但这对于一个大型的推荐系统，这是个很小的数据，因此需要大批量的数据验证才能证明算法的适用性，在下一步工作中需要抓取更多的博客作为数据集进一步的检验启发式推荐方法的适用性。

4) 用户反馈记录分析技术

用户反馈记录的分析是用户模型更新的关键，因此能挖掘出反馈记录中反映用户的行为以及用户的心理是必须的，目前的分析技术还不够智能化，只能从简单的几个方面入手，因此需要收集用户更加全面的反馈信息，消除用户的无效行为信息，才能准确的分析出用户的当前需求。

5) 隐私安全

这是推荐系统一直存在的问题，系统通过隐式的方式收集用户的信息，用户的信息保存在服务器中，如果被人泄露，也会造成一些侵犯用户隐私的事情，因此需要对收集的信息进行加密，但加密后势必会降低系统分析信息的效率，其中的平衡需要适当的权衡。

中国知网 https://www.cnki.net

参 考 文 献

[1] 朱美虹．企业博客商务价值及应用策略研究[J]．商情·科学教育家，2008．

[2] 刘建国，周涛，汪秉宏．个性化推荐系统的研究进展[J]．自然科学进展，2009，19（1）：1-15．

[3] M.Balabanovic, Y.Shoham. Fab: Content-based, collaborative recommendation [J]. Communications of the ACM, 1997, 40(3):66-72.

[4] C.Boutilier, R.S.Zemel, B.Marlin. Active Collaborative Filtering. Uncertainty in Artifucial Intelligence, 2003, 98-106.

[5] J.A.Konstan, B.N.Miller, D.Maltz, et al. GroupLens:applying collaborative filtering to Usenet news [J]. Communications of the ACM, 1997, 40(3):77-87.

[6] J.B.Schafer, J.A.Konstan, J.Riedl. E-Commerce Recommendation Applications [C].Data Mining and Knowledge Discovery, 2001, 5(1-2):115-153.

[7] K.Goldberg, T.Roeder, D.Gupta, et al. Eigentaste: A constant time collaborative filtering algorithm [J]. Information Retrieval, 2001, 4(2):133-151.

[8] L.G.Terveen, W.C.Hill, B.Amento, et al. PHOAKS:a system for sharing recommendations [J]. Communications of the ACM, 1997, 40(3):59-62.

[9] G.Linden, H.B.Smit, J.York. Amazon.com recommendations: Item-to-item collaborative filtering [J]. IEEE Internet Computing, 2003, 7(1):76-80.

[10] Li Hua Li, Fu Ming Lee, and Shang-Chi Chan. The Blog-article Recommendation System(BARS) [C]. In: Hong Kong Proceedings of the International Multi Conference of Engineers and Computer Scientists, 2008.

[11] 杨杰．个性化推荐系统应用及研究[D]．合肥：中国科学技术大学，2009．

[12] A.M.Rashid, I.Albert, D.Cosley, et al. Getting to know you: Learning new user preferences in recommender systems [C]. In: Intelligent User Interfaces (IUI), NewYork: ACM, 2002, 127-134.

[13] A.Ansari, S.Essegaier, R.Kohli. Internet recommendations systems [J]. Journal of Marketing Research, 2000, 37(3):363-375.

[14] BD.Kim, SO.Kim. A new recommender system to combine content-based and collaborative filtering systems [J]. Journal of Database Marketing, 2001, 8(3):244-252.

[15] R.Mukherjee, N.Sajja, S.Sen. A Movie recommendation system-an application of voting theory in user modeling [J].User Modeling and User-adapted Interaction, 2003, 13(1-2):13-33.

中国知网 https://www.cnki.net

[16] RJ.Mooney, L.Roy. Content-based Book Recommending Using Learning for Text Categorization [C]. In: Proceedings of the fifth ACM conference on Digital Libraries (DL). New York: ACM, 2000, 195-204.

[17] AH.Tan, C.Teo. Learing User Profiles for Personalized Informnation Dissemination [C]. In: Proceedings of IEEE conference on International Symposium on Ne ural Networks (ISNN), 1998, 1(2):183-188.

[18] SE.Middleton, NR.Shadbolt，DC.Roure. Ontological User Profiling in Recommender Systems [J]. Transactions on Information Systems, 2004, 22(1):54-88.

[19] HA.Kautz, B.Selman, MA.Shan. Referral Web: Combining Social Networks and Collaborative Filtering [J]. Communication of the ACM, 1997, 40(3):63-65.

[20] WC.Hnl, L.Stead, M.Rosenstein, GW.Fumas. Recommending and Evaluating Choices in a Virtual Community of Use [C]. In: Proceedings on Computer Human Interaction (CHI). New York: ACM, 1995, 6:194-20l.

[21] B.Smyth, K.Bradley, R.Rafter. Personalized Techniques for Online Recruitment Services [J]. Communications of the ACM, 2002, 45(5):39-40.

[22] RD.Burke, KJ.Hammond, BC.Young. The FindMe Approach to Assisted Browsing [J]. IEEE Expert, 1997, 12(4):32-40.

[23] KA.Smith, N.Alan. Web page clustering using a self-organizing map of user navigation patterns [J]. Decision Support Systems, 2003, 35(2):245-256.

[24] B.Mobasher, R.Cooley, J.Srivastava. Automatic Personalization Based on Web Usage Mining [J]. Communications of the ACM, 2000, 43(8):l42-151.

[25] 张炜. 个性化推荐系统中基于本体的用户建模研究. 南京：南京理工大学，2007.

[26] M.J.Pazzani, D.Billsus. Learning and revising user profiles: The identification of interesting Web sites [J]. Machine Learning, 1997, 27(3):313-331.

[27] Xin Wan, O.Toshio. Utilizing learning process to improve recommender system for group learning support [J]. Neural Computing and Applications (NCA), 2011, 20(5):195-204.

[28] HS.Park, JO.Yoo, SB.Cho, A context-aware music recommendation system using fuzzy Bayesian networks with utility theory. Fuzzy Systems and Knowledge Discovery, 2006, 42(23):970-979.

[29] SE.Robertson, I.Soboroff. The TREC 2002 Filtering Track Report [R]. The Eleventh Text REtrieval Conference (TREC-11).NIST, 2002.

[30] T.Ault, Y.Yang. knn, Rocchio and metrics for information filtering at trec-10 [C]. In: Proceedings of TREC-10 (TREC), 2002.

中国知网 https://www.cnki.net

[31] YH.Kim, SY.Hahn, BT.Zhang. Text filtering by boosting naive Bayes classifiers [C]. In: Proceedings of the 23rd annual international retrieval (SIGIR), New Y-ork: ACM, 2002.

[32] J.Allan. Incremental relevance feedback for information filtering [C]. In: Proceedings of the 19th annual international retrieval (SIGIR), New York: ACM,1996.

[33] 吴丽华，刘鲁. 个性化推荐系统用户建模技术综述[J]. 情报学报，2006，25（1）：55-62.

[34] N.J.Belkin, W.B.Croft. Information filtering and information retrieval [J]. Communications of the ACM, 1992, 35(12):29-37.

[35] RA.Baeza-Yates, BA.Ribeiro-Neto. Modern Information Retrieval. Addison-Wesley, Wesley Press, 1999.

[36] 李冠宇. 基于混合算法的推荐系统的研究与实现[D]. 上海：同济大学，2008.

[37] I.Zukerman, DW.Albrecht. Predictive statistical models for user modeling [J]. Us er modeling and user-adapted interaction, 2001, 11(1-2):5-18.

[38] P.Langley. User modeling and adaptive interfaces [C]. In: Proceedings of the 17 th National Conference and Artificial Intelligence, 2000.

[39] T.Zhu, R.Greiner, G.Haubl. Learning a model of a Web user’s interests [C]. In: Proceedings of the 9th International Conference on User Modeling, 2003.

[40] 赵忠孟，袁薇，何世丽等. 个性化搜索引擎中用户模型智能调整算法的研究[J]. 计算机工程与应用，2005，41（24）：184-187.

[41] 张玉连，王权. 基于浏览行为和浏览内容的用户兴趣建模[J]. 现代图书情报技术，2007，6：52-55.

[42] 余铁军. Web 访问信息挖掘若干关键技术的研究[D]. 杭州：浙江大学，2006.

[43] I.Garrigos, J.Gomez, C.Cachero. Modelling Dynamie Personalization in Web Applieations [C]. In: Proeeedings of the 3th Intemational Confereneeon Web Engineering, 2003, 472-475.

[44] D.Pierrakos, G.Paliouras, C.PaPatheodorou, et al. Web Community Directories A New Approach to web Personalization [C]. In: Proeeedings of the lst European W-eb Mining Forum (EMWF), 2003, 113-129.

[45] R.Armstrong, D.Freitag, T.Joachims, T.Mitchell. WebWatcher：A Learning Apprentice for the World Wide Web [C]. In AAAI 1995 Spring Symposium on Information Gathering from Heterogeneous Distributed Environments. Stanford University, 1995, 6-l2.

[46] O.Vel, S.Nesbitt. A Collaborative Filtering Agent system for Dynamic Virtual

中国知网 https://www.cnki.net

Communities on the Web [C]. Automated Learning and Discovery, 1997.

[47] 李晓昀. 基于隐性反馈的个性化自适应电子商务推荐系统研究. 衡阳：南华大学，2007.

[48] S.E.Middleton, N.R.Shadbolt, D.C.Roure. Ontological User Profiling in Recommender Systems [J]. ACM Transactions on Information Systems, 2004, 22(1):54-88.

[49] 刘艺恒. 基于集体智慧的个性化 RSS 聚合技术研究[D]. 广东：华南理工大学，2009.

[50] 原新成. 基于向量空间模型的自适应文本过滤研究[D]. 哈尔滨：哈尔滨工业大学，2006.

[51] G.I.Webb, M.J.Pazzani, D.Billsus. Machine Learning for User Modeling [J].User Modeling and User-Adapted Interaction, 2001, 11(1-2):19-29.

[52] 赵梦. 博客用户的个性化建模研究与实现[D]. 杭州：浙江大学，2007.

[53] K.A.Smith, N.Alan. Web page clustering using a self-organizing map of user navigation patterns [J]. Decision Support Systems, 2003, 35(2):245-256.

[54] 王继成，潘金贵，张福炎. Web 文本挖掘技术研究[J]. 计算机研究与发展，2000，37（5）：513-520.

[55] J.Han, M.Kamber. Data Mining: Concepts and Techniques [C]. In: Proeeedings of Morgan Kaufman, 2000.

[56] 王实，高文，段立鹃. Internet 上的文本挖掘[J]. 计算机科学，2000，27（4）：32-36.

[57] 陈新中，李岩，杨炳如. Web 日志挖掘日数进展[J]. 系统工程与电子技术，2003，25（3）：492-496.

[58] 赵伟，何丕廉，陈霞. Web 日志挖掘中的数据预处理技术研究[J]. 计算机应用，2003，23（5）：62-66.

[59] 孙铁利，杨凤芹. 根据用户隐式反馈建立和维护用户兴趣模型[J]. 东北师大学报. 自然科学版，2003，35（3）：99-104.

[60] 钟冬，朱怡安，王云岚. 基于历史行为的服务发现技术[J]. 计算机工程，2009，35（10）：60-65.

[61] 陈浩然. 基于日志分析的信息检索技术研究与实现[D]. 北京：电子科技大学，2009.

[62] S.K.M.Wong, C.J.Butz. A Bayesian Approach to User Profiling in Information Retrieval [J]. Technology Letters, 2000, 4(1):50-56.

中国知网 https://www.cnki.net

在学研究成果

一、 在学期间发表的论文

高永兵，冯鑫，郝斌，王建斌. 基于用户反馈的自适应博客推荐模型[J]. 计算机应用与软件，2012.

中国知网 https://www.cnki.net

致　　谢

一分耕耘一分收获！在我即将要毕业之时感慨颇多，那些身边的人和事会成为一生美好的回忆，心中充满了感激之情。

首先，特别的感谢我的导师高永兵老师，三年来高老师在本课题的研究上给予了非常认真的指导、督促及修改；在为人处事方面，高老师教会我如何海纳百川。在他的精心指导下，使我不仅学到了科研的方法，也学到了如何去解决一个大的问题，而且让我明白了一些人生哲理，这对我今后走向社会是一笔巨大的财富，也让我树立了正确的人生观。

同时还要感谢张晓琳、胡文江、谭跃生、柏建普、邢东旭等各位老师的帮助，他们不止一次对我的研究课题提出了一些很有建设性的意见，让我在研究的道路上少走弯路，也让我对研究的课题充满了信心。

此外，也要感谢实验室的同学们，他们无论是学习还是生活都给予无私的帮助，并在最苦难的时候给我极大的鼓舞，帮助我找问题、思考问题并解决问题。

最后要感谢我的家人，正因为他们的支持，我的学业才能到今天，我祝福他们身体健康、开心每一天。

中国知网　https://www.cnki.net