分类号：TP391　　密　　级：公开

ＵＤＣ：　　单位代码：１０１２７

内蒙古科技大学

硕士学位论文

论文题目：基于相似性博客推荐技术的研究与应用

学　　号：200902151

作　　者：王建彬

专 业 名 称：计算机应用技术

2012 年 6 月 6 日

中国知网 https://www.cnki.net

内蒙古科技大学硕士学位论文

论文题目：基于相似性博客推荐技术的研究与应用

作者：王建彬

指 导 教 师： 胡文江 教授 **单位：** 内蒙古科技大学

协助指导教师： 高永兵 副教授 **单位：** 内蒙古科技大学

郝斌 助教 **单位：** 内蒙古科技大学

论文提交日期：2012 年 6 月 6 日

学位授予单位：内 蒙 古 科 技 大 学

中国知网 https://www.cnki.net

基于相似性博客推荐技术的研究与应用

Research and Application of Blog Recommendation Technology Based on Similarity

研 究 生 姓 名：王建彬

指导教师姓名：胡文江

内蒙古科技大学信息工程学院

包头 014010，中国

Candidate： Wang Jian-bin

Supervisor： Hu Wen-jiang

School of Information Engineering

Inner Mongolia University of Science and Technology

Baotou 014010，P.R.CHINA

中国知网 https://www.cnki.net

独 创 性 说 明

本人郑重声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写的研究成果，也不包含为获得内蒙古科技大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解内蒙古科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：_____ 导师签名：_____ 日期：_____

中国知网 https://www.cnki.net

摘　　要

随着 Web 2.0 的应用，博客的传播速度得到了前所未有的发展，使其拥有巨大的信息资源。在数目如此庞大的博客系统中，用户想要找到自己最感兴趣的博客或博文，同时博主也想使自己的博客得到更高的访问量，就显得非常困难。博客搜索引擎的问世在一定程度上解决了这个问题，但是由于技术上以及对用户要求上的原因，不能真正满足用户的需求。

本文研究了目前常用的推荐算法，并对博主的社会信息和博文信息进行分析，基于现有的技术设计了一种基于相似性的博客推荐算法，从博客的博文和博主的社会信息两方面的相似性来计算研究博客的相似度。本文在算法设计之前先介绍了博客的博文相似性和博主社会信息相似性的概念，并阐述了采用相似性方法的优点。构造了博主社会信息相似度和博文信息相似度的计算公式，并把二者进行了综合来计算总的相似度，对相似性权重值的确定采用线性结合法，并结合参考文献的内容确定其大小。实验部分采用开源爬虫工具(Heritrix)从新浪网上抓取相关的博客作为实验性数据，并对抓取回来的数据进行处理，然后将相关的数据信息存储到数据库中。

对于改进的算法通过两种评价标准进行评估：一种是和文本算法对比准确率，这种方法适合于计算机进行自动测评；另一种是通过人工参与的方法，对推荐的博客与目标博客相似与否进行判定。通过对实验结果进行对比与分析，证明了改进算法的有效性，为博客推荐提供了技术支持。

关键词：博客搜索引擎；相似性；博客；推荐系统

中国知网　https://www.cnki.net

Abstract

With applications of Web 2.0, the propagation speed of the blog has obtained an unprecedented development, which has a huge information resource. In such a large number of blog system, it becomes very difficult for the user to find the most interested blogs or blog articles and bloggers to make their own blog to gain a higher number of visits. The problem is solved due to the advent of the blog search engines, but it cannot really meet the needs of users because of technology and requirements reasons

The common recommendation algorithm has been studied and social information of bloggers and blog articles have been analyzed. A blog recommendation algorithm based on the similarity has been designed on existing technology, similarity of blog has been researched from the aspects of the social information of the bloggers and blog articles. the concepts of the blog article similarity of blogs and bloggers social information similarity are introduced before the algorithm design, and the advantages of the similarity algorithm is described. The similarity weight value is determined using the linear combination method, and the contents of the references are combined to determine its size. The experimental part uses the open source crawler tools (Heritrix) to grab the related blogs contents on Sina website as the experimental data, and crawl back to the data processing, and then the data stored in the database. Data crawled back from the website are processed and then stored in database.

Two criteria are used to evaluate the improved algorithm: One method is used to compare the accuracy with the text algorithm, which is suitable for automatic evaluation for computer; Another method is to judge the similarities between the recommended blog and target blog through human intervention. the comparison and analysis of experimental results prove the effectiveness of the improved algorithm which provide technical support for the blog recommendation.

Key words：Blog Search Engine；Similarity；Blog；Recommendation System

中国知网 https://www.cnki.net

目　　录

摘　　要 I
Abstract II
引　　言 1
1 绪论 2
1.1 研究背景 2
1.2 研究目的 3
1.3 国内外研究现状 4
1.4 课题主要工作与论文组织结构 5
1.4.1 课题主要工作 5
1.4.2 论文组织结构 6
2 博客与标签介绍 7
2.1 博客介绍 7
2.1.1 博客含义及特征 7
2.1.2 博客发展历程 8
2.1.3 博客应用 9
2.1.4 博客发展趋势 10
2.2 Tag 介绍 12
2.2.1 Tag 概念 12
2.2.2 Tag 特点 13
2.2.3 Tag 在博客中的应用 14
2.3 小结 14
3 博客搜索引擎研究 15
3.1 概况 15
3.2 博客搜索引擎关键技术 16
3.2.1 博文相似性计算 16
3.2.2 搜索结果排序 16
3.3 博客搜索引擎的不足 19
3.4 小结 19
4 推荐算法研究 20
4.1 基于内容推荐算法 20
4.2 协同过滤推荐算法 21
4.2.1 余弦相似性 22
4.2.2 修正的余弦相似性 22
4.2.3 相关相似性 23
4.3 混合推荐算法 23
4.4 小结 24
5 基于相似性博客推荐算法研究 25
5.1 相关概念 25
5.2 博主社会信息相似度计算 26
5.3 余弦相似性计算博客的博文相似度 28

中国知网　https://www.cnki.net

5.4 博客相似度计算 29
5.5 小结 31
6 实验设计与分析 32
6.1 数据的抓取及处理 32
6.1.1 数据抓取 32
6.1.2 数据处理 37
6.2 实验系统 41
6.2.1 实验环境 41
6.2.2 系统概述 41
6.2.3 实验过程 42
6.2.4 结果分析 46
6.3 算法比较 46
6.4 小结 48
结　　论 49
参 考 文 献 50
在学研究成果 54
致　　谢 55

中国知网 https://www.cnki.net

引　言

博客数目的日益增加使得人们想要迅速的找到感兴趣的博客成为梦想，如何能够让人们方便、准确的找到想要的博客成为近几年的研究热点之一。博客搜索引擎的问世在一定程度上缓解了这个问题，但是由于其在技术上主要是采用通用搜索引擎的技术，只是在存放数据的时候进行改进，所以导致存在一些问题，比如主题漂移、轻视新博客及语意相关等。同时博客搜索引擎对用户也有一定的要求，如如何定义搜索词、相关经验等，所以博客搜索引擎很难满足用户的需求。

目前电子商务网站中的推荐系统极大的方便了用户寻找到相关的商品信息，而且也使得商品的销量增加。推荐系统中的推荐方法有基于内容的推荐方法、基于协同过滤推荐方法及混合推荐方法，这三种推荐方法各有各的应用领域及优缺点。如果能够把这项推荐技术应用到博客系统中，那么一定能够方便用户准确的找到感兴趣的博客，而且有时候可能会有意想不到的收获。

由于博文及博主的信息特点和电子商务中的信息特点有很大的不同，上面介绍的三种技术对应用的领域都有相关的要求，而博客不满足，所以不能够把这种技术直接应用到博客系统，必须对其进行改进。目前的博客推荐方法主要有基于文本和基于链接两种方法，但是各有各的缺点。因此本课题在分析了这些特点及技术的基础上提出了一种基于相似性的博客推荐算法，这里的相似性包括博客的博文相似性和博主的社会信息相似性，从这两个方面去挖掘博客的相似性。

实验部分采用 Heritrix 从新浪网上抓取回来的博客作为实验数据，通过对新浪博客数据的分析，我们从中提取用户的社会信息及博文信息，并对博文信息进行分类，把整理好以后的数据放到 SqlSever 数据库中。在 Eclipse 环境下用 Java 语言编写了一个验证系统，通过实验对算法进行验证。

中国知网　https://www.cnki.net

1 绪论

1.1 研究背景

博客是一种新型的个人互联网出版工具，用户可以很方便地用影音、图片、文字、链接建立起个性化的网络世界。它一般应包含三个要素：由经常更新和个人性的网页主体内容组成；它们按照时间倒序方式排列，也就是说最新的帖子放在最上面，旧的在下面；内容可以是各种各样的主题，外观布局也各式各样，文章的内容以‘超链接’作为主要的表达方式[1]。

现在无论是对哪个国家、哪个年龄段的人来说，博客都不是陌生的，它已经成为我们生活和交往的一部分。具统计，从 2002 年到目前为止，无论是博客的数量还是不同年龄段的比重，都有明显的变化[2]，如图 1.1 和图 1.2 所示，从图中可以看出不但博客数量大幅度增加，而且各个年龄段的差距也逐渐缩小。

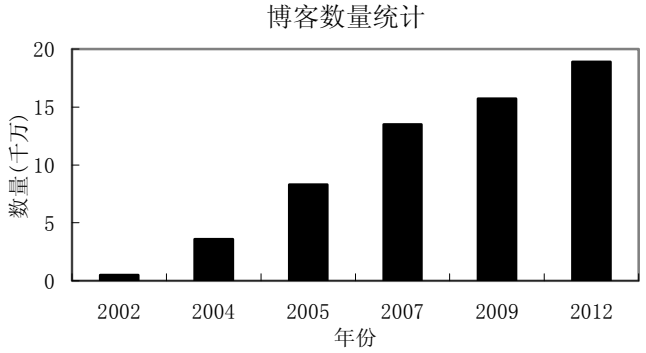

图 1.1　博客数量统计

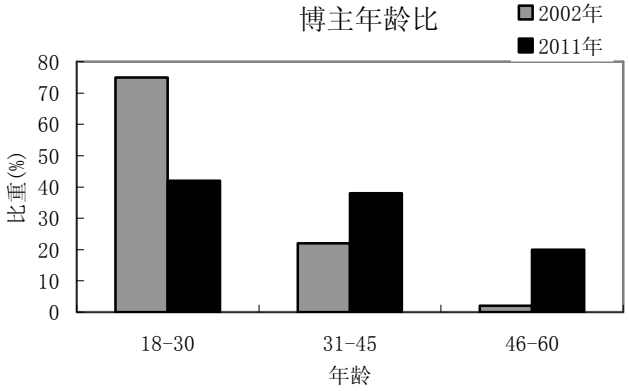

图 1.2　博主年龄比重

博客(Blog)从它出现的时候起，就给整个互联网世界的交流方式带来了一场新的

中国知网　https://www.cnki.net

变革，吸引了来自学术界和工业界的极大关注，成为近年的研究热点之一。认为博客是互联网赋予个人力量的一种新工具，使得每个人都可以成为赛博空间中的自主主体，而且与互联网建立了全面的交流沟通。近几年，博客的影响逐步扩大，产生了一批很有影响力的博客网站。人们对博客的关注使得博客的应用越来越广泛，博客的用户是人，人有想找到和自己同兴趣人的心里，以便能够了解更多的兴趣内容，而博客数目巨大，进行查找是比较困难的，而博客搜索引擎又具有一定的缺点，因此本文就是在这样的背景下，对博客推荐算法进行的研究。

1.2 研究目的

根据经验，如果将某一博客或者博文放在推荐区中，将会获得比平时高很多的关注度和访问量，有着更强的社会影响。而目前的博客推荐方法往往是管理者根据访问量的积累或者名人效应来进行推荐，还有的是后台管理人员根据当前的热点话题进行推荐，其网站首页的内容为当日推荐的博文组成，如图 1.3 所示。

图 1.3　新浪博客首页

这种推荐具有一定的主观性和不可靠性，而且随着博客数量的增加，博文发表变的更加频繁，简单的人工实现博客推荐工作将变得很困难，也给博客管理工作人员带来了很大的挑战，推荐的质量就更难以保证，而且容易遗漏很多好的博文。因此，设计一种客观的推荐方法并将其个性化、自动化，对于推荐‘好’的博客将是非常必要的。有了一个“客观”的推荐系统，用户登陆博客以后，在一个固定的区域内就能够显示根据用户不同信息及特点进行个性化推荐的博客，那么用户就能够很容易的看到

中国知网 https://www.cnki.net

他最想要的博客，甚至有时候可能会有意想不到收获[3,4]。

本课题是在原有推荐方法的基础之上改进的基于相似性的推荐方法，这里的相似性是结合博主的社会信息相似性和博客的博文相似性，本方法能够克服在现有的技术中存在的主观性问题，而且减少了计算的复杂度，应用在博客推荐中应该能够方便、准确的给用户推荐他最想要的博客，在以后的工作中还可以尝试把这种方法应用到其它的领域，属于应用性研究。

1.3 国内外研究现状

目前的博客搜索引擎主要有百度博客搜索引擎、有道博客搜引擎等，其原理和通用的搜索引擎是一样的，利用关键字和标签进行搜索，然后计算博客的相似性，根据相似性的大小对博客进行排序，把排序以后的博客按照相似性大小返回给用户。用户在搜索界面上也可以根据自己的要求进行相关的高极搜索。虽然博客搜索引擎能够在一定程度上满足用户的需求，也提供基于关键字和标签的搜索，但是关键字搜索不能进行语意的扩展，容易漏掉语意相关的博客，而标签的定义又相当灵活，因此其搜索也是不准确的。而且博客的数目越来越大，返回给用户的结果太多，一般的用户最关心的只是排在搜索结果前面的博客，有时候排在后面的博客可能也是用户很想要的，但是由于博客数目太多，使得用户在众多的返回页中很难快速的找到有用的信息。

博客搜索引擎技术上的缺点有搜索内容限制、主题漂移、轻视专业博客等，除此之外，对用户的知识也有一定的要求，例如如何定义搜索关键字、搜索经验等，这些都在很大程度上限制了博客搜索引擎，也就很难满足用户的要求，因此设计一种个性化的博客推荐系统是必需的。

目前的推荐系统大多是应用在电子商务领域中的，主要代表有亚马逊、当当网等商业网站，其推荐的内容有的是根据用户的浏览记录，有的是根据当前的销量。推荐算法也是比较成熟的，主要有以下三种算法[5,19]：

(1) 基于内容的推荐方法：根据用户浏览的内容进行推荐。

(2) 协同过滤的推荐方法：基于以前与该用户有类似兴趣的用户群喜爱的项目进行推荐。

(3) 混合的推荐方法：将两种方法进行结合。

电子商务网站中的推荐算法主要是根据用户浏览的内容进行推荐，内容名称的定义由网站的管理人员统一进行定义和管理，而在博客系统中，每人都有自己的定义方法，而且博文的内容丰富多彩，不能够根据某个标准去定义。协同过滤推荐算法中需要计算不同的用户的相似性，在计算相似性的时候，需要不同的用户有相同的评分项目，我们知道在博客系统中这是不可能的。

中国知网 https://www.cnki.net

对于推荐系统在博客应用方面，往往只是在门户网站的首页显示推荐结果，如新浪博客、搜狐博客等，这个结果是管理者根据访问量的积累或者名人效应来进行推荐，或者是推荐当前的热点话题，具有一定的主观性和不可靠性，而且对所有的人，它的显示结果是一样的，不能够根据每个人不同的特性来进行推荐，往往推荐的结果不一定是用户想要的，而且随着博客数量的增加，博文发表变的更加频繁，简单的人工实现博客推荐工作将变得很困难。在这种情况下，而对于一个用户来说，想要找到自己感兴趣的博客或博文是相当困难的，如果能设计一种根据用户的不同信息进行个性化的推荐，那结果将是不言而论的。

在博客推荐算法研究方面，主要是采用基于文本和链接的方法。基于文本方面，主要有两种方法计算两篇文档的相似度，一种是由 Mizuki 等人提出的机械式的，根据提取的词频计算两篇文档的相似度；另一种是信息提取法[60]。基于链接的方法主要是由 E.Adar 等人提出的，他认为有链接的博客要比没有链接的博客相似度高，链接越多说明感兴趣的话题越多[60]。

我们知道博文的类型多种多样，所以机械式的提取关键词是比较困难的，对于信息提取方法，虽然效果比较好，但是它要求自然语言理解和机器语言学习的知识，是比较困难的。对于基于链接的方法，我们知道有时候博主链接一篇博文可能是出于好奇或链接的是当前的一个热点，而且在博客中还会有广告的链接，所以链接也不一定代表着兴趣程度。

从前面的介绍中我们看出，无论是电子商务网站中的推荐算法还是目前博客系统中的推荐算法都不能恰当、准确的应用在博客推荐系统中，因此我们必需设计一种针对博客的推荐算法。

1.4 课题主要工作与论文组织结构

1.4.1 课题主要工作

虽然目前有博客搜索引擎，但是这只能满足用户的简单要求，无论是从技术上，还是从对用户的要求，都有一定的限制，而且对于用户找到最想要的博客还是比较困难的。对于门户网站上的首页推荐，只是推荐当前的热点话题或是名人的博文，不能够进行个性化的推荐，本课题根据这些问题设计了一种个性化的基于相似性的博客推荐算法，主要工作如下：

一、对博客和标签进行研究。对博客及标签的特征了解有助于我们分析博客，对博文进行更好的分类。

二、对博客搜索引擎进行研究。通过对博客搜索引擎的研究，使我们知道搜索引

中国知网 https://www.cnki.net

擎的工作原理及不足，在做推荐系统的时候可以吸取这方面的经验和教训，弥补其中的不足。

三、对推荐算法进行研究。通过对目前常用的推荐算法进行研究，使我们了解推荐系统的工作原理及流程，也能够更好的对算法进行改进。

四、算法设计。通过对上面理论的研究，根据博客自身的特点，设计一种基于相似性的博客推荐算法。

五、对实验数据的抓取及分析。通过对新浪网上的博客数据进行抓取和分析，为实验提供数据。

六、实验验证。通过实验验证我们的算法。

1.4.2 论文组织结构

本论文的组织结构如下：

第一章对本课题研究背景、目的做了介绍，并详细介绍了国内外的一些研究现状，提出了研究本课题的重要性。

第二章对博客和标签进行介绍，介绍了博客的概念、特征及发展历程，详细介绍了博客的应用以及发展趋势；对标签知识进行了介绍，对以后的数据处理有很大的帮助。

第三章对博客搜索引擎进行详细介绍，从博客搜索引擎的概况到不足，其中对相关技术进行了更为详细的介绍。

第四章对推荐算法进行介绍，分别介绍了目前常用的三种推荐算法，包括基于内容的推荐算法、协同过滤推荐算法及混合推荐算法，分别指出了其应用领域以及应用在博客推荐系统中的不足。

第五章设计了一种基于相似性的博客推荐算法，在经过前几章的学习，对博客特点及推荐算法进行综合，提出了基于相似性的算法，这里的相似性包括博主的相似性和博客的博文相似性。

第六章进行实验验证及分析，通过对新浪博客数据的抓取及分析，用来验证我们的算法。

最后对文章进行总结，并说明完成课题的意义。

中国知网 https://www.cnki.net

2 博客与标签介绍

2.1 博客介绍

2.1.1 博客含义及特征

Blog 是 Weblog 的缩写，1og 本意是指“航海日志”，后来用来泛指任何类型的流水记录，Web 指互联网，可以说 Blog 实际上就是“网络日志”。一个 Blog 其实就是一个网页，它通常是由简短且时常更新的帖子组成的，这些帖子都是以时间为索引的组织方式在网上发表。

“Blog”中文名字“博客”是由两位中国的互联网专家王俊秀和方兴东于 2002 年 8 月隆重推出的“博客中国网”传播开始兴起的。对于“Blog”，孙坚华这样界定：相对比较完整的博客概念，应该包括三个方面：一是内容主要是表达个人的想法；二是以日记体方式并且更新频繁；三是要充分利用链接，开拓文章内容、范围以及和其它博客的联系。

根据文献[6]，可以得出博客具有以下的特征：

链接性：与传统媒体相比，网络媒体最大的优势就是有“超链接”技术。超链接技术就是从一个链接点跳到另一个目标，这个目标文件可以是不同的网页，还可以是在这个网页上的不同位置，甚至可以是一个图片或其它各种内容[6]。通过这项技术，一个网页中的链接就成了连接网络世界中大量资源的桥梁。在博客中，通过使用超链接技术可以提高网络资源的利用率（如博客中的音乐、图片等，如果是通过本地网络上传到博客中会占用自己一部分的网页内存，但是利用超链接就可以方便的利用网络上已有的资源，从而就节省了内存），对于文字类博客同样也可以利用超链接技术指向网络上已有作品的网址[6]。

开放性：开放性指的是博客的一种“零门槛进入”，通过网络发表内容的一种方式，它对所有的网民都是无偿开放的[6]。博客把信息传播的各个环节中的用户集于一身，可以充分地发表各种意见与观点。当用户们把博客作为一种有效的信息交流工具，而不只是一种个人信息交流方式的时候，这就表示博客已经发展成了公共领域中的一部分，就意味着传统上的公共与个人间的门槛已经消失。

个人性：博客它和传统媒体（报纸、电视等）不同，它不是社会某个组织或者政府所有，总是代表着团体或政府的利益，但博客是一个私人的网站，或者是一个浏览器，人们在上面可以自由发言，是一种真正的个人媒体[6]。在这个平台上任何人都可以表达自己的经历、意见等各人看法，还可以通过转载相关的博文以表达自己的观点立场。从这些来说，博客是一种真正的个人信息传播工具。

中国知网 https://www.cnki.net

交互性：与传统单向媒体不同的是，博客具有交互性。博客实现了颠覆传统的“点对面”传播方式的概念，而是以“面对面”的传播理念为主，真正实现了读者与作者之间的实时互动，使两者变成了对话者[6]。

共享性：通过超链接，每个博客都可以连接其它的博客，与此同时，而每一位读者可以评论博客发表的内容并且可以对有兴趣的内容进行转载，从而实现了网络上的知识以及思想的共享。这里的链接不只是一种形式，而是本身的内容，它是博客的一个重要组成部分。没有超链接的博客，内容是狭隘的、没有生命的，超链接能够真正实现资源的共享[6]。

2.1.2 博客发展历程

1、博客在国外的发展

博客的发源地是美国，但其从产生到发展，最后到真正意义的走入百姓生活，它是和几件轰动世界的事件相关的[1,2]。

1998 年的 1 月 17 日是一个历史性的关键时刻。在这一天，德拉吉按下了一个键，发表了一条使世人震惊的消息。“但就是在最后一分钟，各大新闻周刊还想扼杀了这条重大新闻。这条重大新闻将会动摇华盛顿的根本：一位白宫的女实习生与美国总统克林顿有染。”新闻的大标题是：“世界独家新闻”。德拉吉发布了这条消息之后，其它媒体才开始做相应的跟进和报道。使德拉吉成了世界上首个报道美国总统和女实习生绯闻的人，博客首次向传统的媒体发出了挑战，也使世人第一次感受到了博客的传播力度[1,2]。

2001 年的 9 月 11 日：恐怖分子袭击了美国的世贸大楼，灾难中的人们通过博客发布重要的信息和亲身体验。在当时，对“9·11”恐怖事件最真实的描述不是在各大媒体之间，而是在那些幸存者的博客中；对这个恐怖袭击事件最深刻的讨论和反思，不是来自哪位有名的记者，而是在大量的博客里。博客可以与传统主流的媒体相较量，被人们称为“博客发展的分界线”。从此以后，博客就真正的走进入了主流社会。

2003 年的美国——伊拉克战争爆发后，众多的随军记者，向关注战事的人们及时报道了最新情况。虽然媒体进行了大量的报道，但是人们对战事知道得反而很少。传统媒体被批评加入了大量“爱国主义”的感情色彩在报道里[1,2]。在这种情况下，一个名为 SalamPax 的神秘博客开始受到网民们的关注，他几乎每天都在网上发布关于巴格达如何应付美军的轰炸，以及人们日常生活的消息。他是站在老百姓的立场上，向世人描述了这场战争最真实的一面，记载了战火之下的巴格达人们最真实的生活状况。他的感受以及鲜活报道是他从巴格达家中发出的，因此是最真实的。一向被传统媒体指责为“不严谨、不专业”的博客，却在这场战争中，比其它的广大主流媒体更

中国知网 https://www.cnki.net

加公正和中立。同时，人们在对和平的渴望和战争的厌恶当中，使人们可以在博客中有效交流和倾诉。伊拉克战争使博客发展到更为繁荣的阶段。

此外，2002 年在美国参议院多洛特发表的演说中无意露出种族主义，被所有主流媒体所忽略，但却被博客用户们查觉和快速的传播，使其成了新闻界所有记者们关注的焦点，最后使其被迫辞职。在 2004 年，CBS“60 分钟”节目的主持人拉瑟也因一个错误的材料引用，无意的爆出了“拉瑟门”事件，使拉瑟不得不提前退休[1,2]。这些成就使人们又一次看到了博客的力量。

2、博客在我国的发展

博客在中国发展经历了以下三个阶段[6]：

第一阶段(2002 初年到 2003 年)：萌芽阶段

在这一阶段中，中国诞生了博客的概念并得到初步的发展，在 2002 年 8 月由方兴东和王俊秀创办了博客中国，并且给博客命名，这个阶段博客的发展主要是由梦想主义和理想主义者们推动发展的阶段，在这个阶段中，主要是由精英欢呼、精英驱动和精英写作[6]。中国网民仅仅是尝试博客，其数量也是非常少的，但这个阶段为以后的发展打下了基础，是非常重要的一个时期。

第二个阶段(2003 年——2005 年初)：初步发展阶段

这一个阶段主要是由实用主义人士驱动的，这是一大众写作的阶段，本阶段的首要功能和应用还是表达和写作，中国网民的数量有了很大的提高，数目过亿，博客的数量也非常庞大，这个阶段是博客发展最快的时期。博客在这个阶段中经历了两个大的里程碑事件：其中一个是王吉鹏在 2003 年的时候，发起的互联网“反黄事件”，这促使博客的知名度迅速提高，博客一词洗卷全国；另一个是传统的门户网站在 2005 年的时候推出的博客服务，尤其是新浪推出名人博客以后，凭借着名人博客的吸引力度，使得一时内 Blog 成为热门词汇，并开始广泛的普及应用[6]。

第三阶段(2006 年——)：深入发展及应用阶段

这个阶段主要是由保守主义的人们驱动的，这时候全民博客、全民互动，中国的网民人数持续更高的增长。此时写作已经不在是第一应用，也不再是博客最主要的需求，而更广泛的互动和交流活动才是大家共同所想。随着 Blog 概念普及的深入及规模的不断壮大，博客的商业价值链初步形成。对于博客在商业中的研究成为当时讨论的热点。

2.1.3 博客应用

博客除了具有其它的网络传播工具所有的共性以外，还具有自身的一些特点，所以现在博客已被广泛的应用到了很多领域当中，例如博客运用到教育领域、图书馆工

中国知网 https://www.cnki.net

作领域、商业领域等。当然，博客应用到的领域还有很多，我们不一一介绍，只就这些典型的做一下介绍[7]。

1、博客与教育

文献[7]指出博客之所以能够运用到教育中，是由于它过滤信息的特点所决定的。由于互联网上的信息过多，博客可以用来进行信息过滤，这对于学习者识别有用的信息是非常重要的，教师通过博客把过滤以后的信息传递给学生，同时同学之间也可以通过博客进行重要的信息相互传递，这样可以使学生快速获取有效信息[7]。

博客还可以提供互动的功能，教师可以通过查看博客评论，清楚的看到学生在学习过程中遇到的问题，能够及时的了解学生的学习状况并进行教学改进。博客在教学过程中的应用，对于教师而言，博客过程其实就是对自己的知识体系进行整理的过程；对于学生而言，博客过程其实就是对自己的知识体系进行整理和建立的过程。在之间的互动过程中，教师和学生都不断地重新整理自己的知识体系[7]。

2、博客与图书馆服务

博客具有共享性特性，而这种特点与图书馆的知识全社会分享的精神理念完全吻合，这就说明了博客可以应用到图书馆工作中来。相关资料显示，图书馆博客网产生于 2004 年初，到 2005 年则达到一定数量，通过 Google 可以搜索到大约 70 多个图书馆博客网站，主要分布在英国、加拿大和美国，其中美国有 48 个，加拿大有 7 个，英国有 5 个。在国内，图书馆博客网站也在慢慢起步，一些高校在这方面正在进行实践[7]。如 2005 年厦门大学建立了第一个会议博客(http://libforum.xmu.edu.cn/calis/)，通过博客发布会议相关的信息，同时会务人员还可以通过博客进行交流。博客应用在图书馆工作中是切实可行的，图书馆是信息资源的中心，图书馆拥有大量的信息资源为博客应用到图书工作提供了基础与保障，网络技术的发展也为此提供了便利条件[7,38]。

3、博客与商业

博客在商业领域中的应用也是相当广泛的，一些国际上的大企业都拥有自己的企业博客，比如 IBM 和微软，一直鼓励员工写自己的博客。企业的博客细分为员工博客、新闻博客、技术与产品博客、CEO 博客、广告博客等诸多形式[7]。企业博客的优势：提高企业的知名度；提高企业利润；塑造企业的美好形象；提高内部交流。

2.1.4 博客发展趋势

1、博客发展的新闻化趋势[8]

目前，博客已经发表原始新闻并传播，成为众多传统媒体新闻来源的重要途径，与此同时，博客网站提供的内容也为专业记者提供了大量的新闻，博客报道往往继专

中国知网 https://www.cnki.net

业媒体报道之后继续追踪[8]。博客也进一步增加了传统媒体版面及节目内容的丰富性和趣味性。

博客的新闻化趋势使得传统媒体对信息垄断的梦想破灭，使新闻的来源具有多元化和丰富性，但是它也有负面的影响：第一、博客的新闻传播者没有受过专业训练，尤其是对于较为复杂的新闻事件没有即全面又准确、客观的判断能力；第二、对新闻的传播大多是一种自发的和偶然的行为，缺乏责任意识，容易出现以讹传讹和谣言四处流传的现象。因此，必须加大力度对博客新闻传播渠道进行规范。通过对博客现象的研究认为，传统的媒体开始受到以个人为中心的博客的挑战，尤为突出的是对新闻界多年以来形成的传统的观念。随着博客技术的发展，实现了每个人都能够写作和编辑自己的新闻内容并被他人阅读和评论。在历史上从来没有数目如此之多的局外人，对专业的新闻工作者发起了如此的挑战。业余的新闻工作者们通过各种途径与其它用户建立了紧密连接，并以自己独有的方式报道新闻。他们的报道带有鲜明的个性，而且注重眼见为实的内容，给受众者带来大量新的真实的内容。当然，就像传统报纸受到广播电视的冲击一样，传统媒体也会受到博客的冲击，但其出现不可能造成消亡，而是能够促使传统媒体吸收新技术并进行改进。

2、博客发展的商业化趋势

对于“博客经济”的影响已经是众所周知的了，从而 Blog 商业化的趋势已经摆在我们的眼前。要想使博客能够发展长久，必须进行商业化。博客的运行与维护需要资金，博主需要花费更多时间和精力去创作及获取更多有价值的信息来源才能使博客发展，其投入的回报是获得相应的报酬[8]。如果博客一直是免费的，总是靠其它的收入来养活它，作为一种新生的事物总是处于附属状态中，肯定不能长久。

博客的商业化发展趋势主要有两方面的表现：第一、专业的博客以及门户网站都在努力推动博客的商业化发展；第二、博客本身表现出来商业化的特性。

现在，博客的商业化发展热火朝天，除了有博客广告和博客的出版外，还有博客的无线增值等模式。例如博客作者靠发表博文一博成名，Blogger 出版博文书籍等等。根据相关的报告表明，2010 年我国博客创收达 10.5 亿元，增长率为 85.71%。这充分表明，和传统媒体一样，博客不只是在内容上面的表达，还促进财富增收。

3、博客发展的无序化趋势

随着博客评论功能的发展与完善，博客越来越呈现出无序化。博客的留言各式各样，有的甚至是与博客的内容不相关的。尤其是名人或明星们的博客评论更是各种各样，有的人发表评论只是为去抢“沙发”坐坐，而有的人则只是想表达自己对博主的崇拜或喜爱[8]。博客发展的无序化不是由博客造成的，而是一种必然的规律，更多人看来，博客和论坛没有什么本质的区别。那些根本不看博主写的是什么便随便发帖的

中国知网 https://www.cnki.net

人，只能使博客发展的无序化。

对于博客的无序化发展趋势问题，我们首先要充分利用法律法规，加强对博客的监管，确保在法律的规范下合规运行。到目前为止，我国已经颁布了几种法规去规范网络的传播，其中包括《互联网电子公告服务管理规定》、《互联网信息服务管理办法》等。虽然相关人士正在进行探讨“博客实名制”，但由于缺乏具体的法律法规，还无法确保博客市场的规范。其次是加强各个职能部门对博客的管理，并专门设立网络监管机构。加强互联网管理和工作人员的技能培训是非常重要的，建立完善的博客管理体系。最后，博客传播的“双刃剑”作用要使全社会都得到认识，共同努力打造绿色的网络环境，充分发挥其积极作用。

4、博客研究的专业化趋势

博客研究的专业化包括两方面，一是学术博客的产生，二是研究博客的文章数目激增，博客的交流方式不是正式的方式，传统的非正式的交流往往是在有着共同爱好和兴趣的人们之间产生，而且这些人之前就认识[8]。它是在学者之间有一定的了解和信任的基础上建立起来的，共同致力于相关领域的知识研究和创造。其他事先没有过交往的学者和普通兴趣的人们是无法加入的，但是在博客这个平台上，无论是专家还是学生都不需严格的认证，只需简单注册或填写用户名就能够参与到其中，并且用户并不需要对对方有一定的了解，只要对讨论的问题有兴趣就可以[8]。从全球资源共享的现状来看，博客将来带来的学术上的科研成果是令人期待的。

根据中国知网的统计，从 2002 年 2 月到 2011 年 7 月 8 日，研究博客的论文已有 6892 篇。其中包括专业研究组织和科研团队的相关调查报告等，可以说博客的研究在中国已经形成了专业化的趋势。分别从不同的学科和角度去分析和研究博客以及博客在发展过程中所遇到的问题，并探索了这一新兴媒介发展道路。随着对博客专业化的研究，将进一步促使相关研究更加深入。

2.2 Tag 介绍

2.2.1 Tag 概念

随着 Web2.0 和 3.0 的发展 Tag 才被广泛的应用，Tag（标签）是一种更灵活、更有趣的分类方式，你可以给每篇日志、每个帖子或每张图片等添加一个或者多个 Tag（标签），你可以看到网站上所有和你使用了相同的 Tag 的内容，由此可以和他人产生更多的联系[62]。Tag 体现了群体的力量，使得内容之间的关联性和用户之间的交互性大大增强[10]。

中国知网 https://www.cnki.net

比如，你在一篇日志上添加了“读书”和“小说”两个标签，就能通过这两个 Tag 看到和你有相同兴趣的用户的其他日志，同样，如果你给自己的日志贴上不同的标签，那么，在下一次寻找时，会很容易的找到自己想要的信息[62]。

那么，如果我贴了 Tag（标签），会产生什么效果呢？首先，信息将会被条理化。其次，当你的 Tag（标签）积累到一定数量的之后，你会发现自己最关心的话题。当然，你也可以看到哪些人和自己使用了同样的 Tag（标签），进而找到和你志趣相投的人[62]。

2.2.2 Tag 特点

Tag 也可以理解为一种关键词标记，应用在搜索引擎中有利于搜索查询。但是 Tag 又有不同于关键词的特点，当在使用关键词进行搜索的时候，搜索到的结果只能是文章里面提到的词，但 Tag 却可以使用文章中没有提到的关键词作为 Tag 来标记[11,62]。一个机器就没有办法提取一张照片的关键字，但人可以给它设定一个或多个 Tag。而 Tag 真正不同于关键词地方在于，你可以随意用任何的词来标记一件事物，只要你方便找到它，因此，这一标签是活跃的、个人化、无序的、相当自我的一种标记方式[62]。

当然，你也可以把一个 Tag（标签）理解为一个日志分类，但它和分类的不同之处也是很明显的：

首先，分类是在写日志前就已经定好的了，而 Tag（标签）是在你写完日志之后添加的；

其次，你可以同时给一篇日志加上好几个 Tag（标签），方便自己的查找，而原来的一篇日志只能够有一个分类；

再次，当你积累了一定数目的 Tag（标签）后，你可以在自己的博客中看到最喜欢哪些话题；

最后，当你看到其它人使用了和自己一样的 Tag（标签）之后，进而找到和自己志趣相投的 Blogger。

举一个例子，比如说：你发表了一篇到北京旅游的日志，原先你都是把这一类日志放到自己的“游记”分类中，但是有了 Tag 之后，你可以给这篇日志同时加上“旅游”、“首都”、“天安门”、“长城”、“游记”、“故宫”等几个 Tag，当浏览者点击其中任何的一个 Tag，他都可以看到你的这篇日志。同时你自己也可以通过点击这几个 Tag，看看有谁最近也去了北京旅游，也许你们还可以交流一下旅游心得，有机会成为下一次出游的伙伴呢！

中国知网 https://www.cnki.net

2.2.3 Tag 在博客中的应用

现在有很多的网站都使用了 Tag 模式，只要使用者打开了界限，可以随心所欲地给自己加标签，不被陈旧的思维局限住。简单地说，Tag（标签）是一种随心所欲的标签，当你读了一篇文章或者看了一张图片之后，想什么就写什么，不受原有的分类束缚，怎么想就怎么使用。在博客系统中，博主可以为每一篇博文加一个或多个标签，这个标签可以是以博文的内容为依据，也可以是以自己对博文的理解或当时的心情为依据，这样便于用户理解也方便用户找到自己感兴趣的博文[45]。例如上面举的例子，对一篇去北京旅游的日志加标签，如图 2.1 所示。

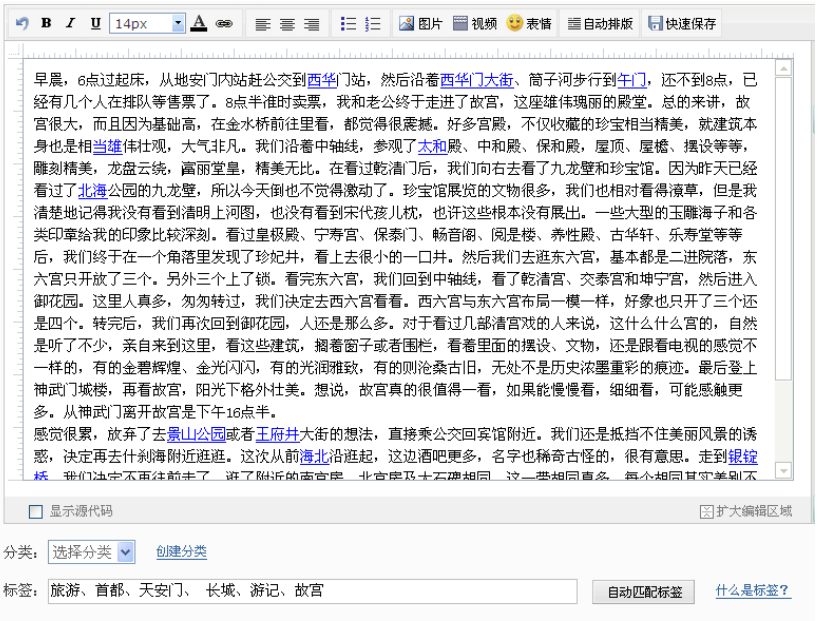

图 2.1　日志标签

2.3 小结

通过对博客基本理论的学习，我们知道了博客的特点，可以根据其特点进行博文的分析，找出博主之间的关系。现在博客的应用也是越来越广泛，加强对博客的研究可以更好的应用博客，也可以更好的掌握其发展趋势。通过对标签的学习，我们知道在博客中标签的应用很方便，我们也可以根据标签方便的进行博文的分类，

中国知网　https://www.cnki.net

3 博客搜索引擎研究

3.1 概况

搜索引擎现在已经成为人们在海量的网络数据资源中获取信息的主要途径，但是随着网络信息的日益增长，使用传统搜索引擎技术将很困难的进行准确、快速的查找到所需信息。面对每天海量递增的数据，搜索引擎难以及时地更新索引数据库，面对数目庞大的网页，通用搜索引擎不能够深入的抓取信息。搜索引擎的个性化、专业化已成为搜索引擎的发展趋势，由通用转向专为某一特定人群提供有一定价值的信息和相关服务。

随着 Blog 数目的不断增长，仅靠传统搜索引擎想要搜索到感兴趣的博客或博文已经不能满足人们的要求，因此，专业的搜索引擎应运而生，这种搜索引擎专门搜索博文。其原理基于传统的搜索引擎，也是要先在互联网上对博文进行扫描，然后对扫描的内容建立索引，最后用户可以在博客搜索引擎的界面上根据自己的兴趣进行内容查询。文献[12]博客专业搜索引擎原理与传统搜索引擎原理的区别主要有以下几个方面：

(1) 检索内容不一样：传统的搜索引擎是在整个互联网上对所有的网页进行全文检索，但是专业的博客搜索引擎搜索的是博客网页。

(2) 检索方式不一样：在传统的搜索引擎中，基本上都采用检索关键词的方法，而在博客搜索引擎中，采用的是在关键词检索的基础之上，为用户又增加了不同的个性化选择的方法，如按标签检索功能和按浏览检索功能等等。

(3) 更新时间不一样：因为传统的搜索引擎在一个周期内需要在网络上抓取亿万个网页，因此更新的周期较长。但博客的内容是天天都在更新的，则博客搜索引擎只要查看一些特殊的链接即可知道博客内容是否有更新，并且同时提供链接[12]。

国内的博客搜索引擎主要有：

(1) 百度博客搜索引擎：百度是第一家推出博客搜索功能的中文搜索引擎服务商，它的博客搜索的速度、稳定性要好于其它的个人或团体开发的博客搜索引擎。但是百度的博客搜索也有一些缺点，比如说搜索页面无特色，而且百度空间上的博客拥有优先权等。

(2) 网易有道博客搜索引擎：在博客收录的全面性、及时性以及满足用户的个性化需求上做了许多的改进，比如提供了按作者发博文的时间、长度统计信息的博客档案等。

国外最著名的博客搜索引擎要数 Technorati，其最大的特点是“博客权威度”，从

中国知网 https://www.cnki.net

算法设计上来说，其与 Google 的 PageRank 算法有相同的价值观，即根据有多少个博客链接了你的博文来衡量“博客权威度的值”。

3.2 博客搜索引擎关键技术

博客搜索引擎与通用搜索引擎一样，主要用到以下几个关键技术：内容的抓取、分词、提取特征值、建立关键词索引、计算文档的相似性、用户查询的匹配策略以及对结果的排序等。不同的是博客搜索引擎主要是指搜索博文网页，博客是指网络日志的集合，网络日志又叫做博文，大量的博文组成博客。下面介绍几个博客搜索引擎的重要技术[13]：

3.2.1 博文相似性计算

判断博文内容的相似就是看博文网页是否相似。博文网页虽然是一种特殊的网页，但现有的博客搜索引擎在计算网页相似性的时候基本上都是直接用普通网页相似性计算的方法。

目前应用最多的是基于内容和基于链接的两种方法。基于内容的方法是通过 TF-IDF(term frequency-inverse document frequency)方法提取内容的关键字，用余弦相似性方法计算两篇文章的相似性。

基于链接的方法主要是采用布隆过滤器，它实际上是一个很长的二进制向量和一系列随机映射函数，布隆过滤器可以用于检索一个元素是否在一个集合中。

基于链接方法的缺点是在某些特定的情况下可能会出现主题转移的问题，当在进行主题窄查询时，会出现主题泛化的情形，即主题扩展以后引入的主题比原来的主题更重要，但新的主题虽然重要，却可能与原始的主题无关[13]。

3.2.2 搜索结果排序

把检索的结果显示给用户是搜索引擎最后的目的，采用何种策略是非常重要的。目前著名的排序算法有 PageRank 和 IPageRank 两种算法。这两种算法都基于这样的一种认可关系：超链接代表着权威。下面以 PageRank 算法为例做详细介绍。

原理：如果一个网页被多个网页引用，或者被重要的网页引用，那么就认为这个网页的重要性比较大或权威性比较大，同时每个网页都有一个 PR 值，这个值与查询词无关，它的大小只代表页面的权威性。最后博客搜索引擎依据这个大小排序，然后

中国知网 https://www.cnki.net

把结果返回给用户。

根据例子来说明 PR 值的计算，如有向图 3.1 所示。

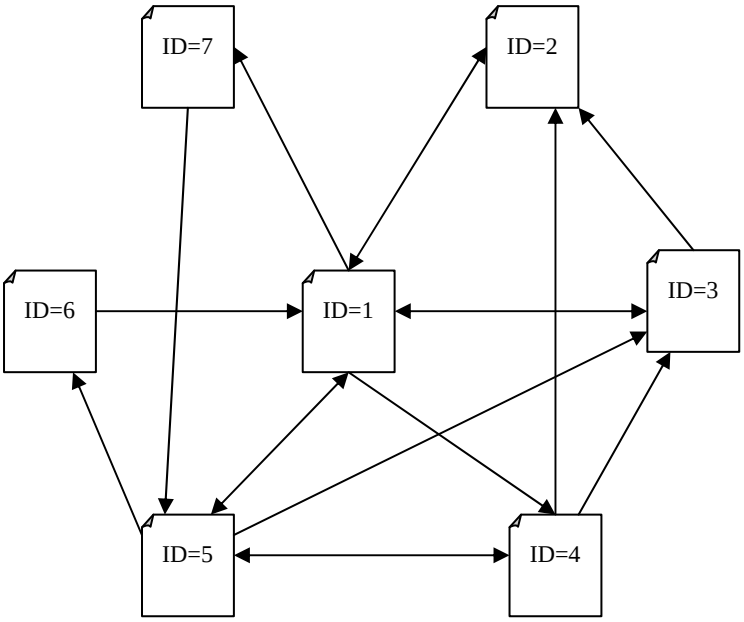

图 3.1　PageRank 示例图

首先根据这个示例图构造出文件之间的链接关系，如表 3.1 所示。

表 3.1　链接关系表

链接源 ID	链接目标 ID
1	2，3，4，5，7
2	1
3	1，2
4	2，3，5
5	1，3，4，6
6	1，5
7	5

根据这个表中的邻接关系构造一个矩阵 A，这个矩阵是一个 7×7 的方阵，如果文件之间有链接就用 1 表示，没有用 0 表示，如下公式所示：

中国知网　https://www.cnki.net

$$A=\begin{pmatrix} 0 & 1 & 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \quad \text{式 3.1}$$

把方阵 A 进行转置，然后用各个值除以该列的和，得到一个新的方阵，用 M 表示，如下公式所示：

$$M=\begin{pmatrix} 0 & 1 & 1/2 & 0 & 1/4 & 1/2 & 0 \\ 1/5 & 0 & 1/2 & 1/3 & 0 & 0 & 0 \\ 1/5 & 0 & 1/2 & 1/3 & 1/4 & 0 & 0 \\ 1/5 & 0 & 0 & 0 & 1/4 & 0 & 0 \\ 1/5 & 0 & 0 & 1/3 & 0 & 1/2 & 1 \\ 0 & 0 & 0 & 0 & 1/4 & 0 & 0 \end{pmatrix} \quad \text{式 3.2}$$

根据上面方阵计算出最终的 PR 值，如表 3.2 所示。

表 3.2　PR 值

名次	PR 值	文件 ID	发出链接 ID	被链接 ID
1	0.314	1	2，3，4，5，7	2，3，5，6
2	0.182	5	1，3，5，6	1，4，6，7
3	0.175	2	1	1，3，4
4	0.139	3	1，2	1，4，5
5	0.112	4	2，3，5	1，5
6	0.059	7	5	1
7	0.043	6	1，5	5

无论是 PageRank 算法还是 IPageRank 算法，它都有以下的缺点：

(1) 主题漂移[16]

由于 PageRank 算法是与查询关键词无关的，所以检索结果可能存在主题漂移的问题。对于这个问题，经典的改进方法是李村合提出的：结合超链接的文本信息方法。

中国知网 https://www.cnki.net

在计算 PR 值时，先用原来的方法计算，再用超链接所携带的重要信息修正 PR 值。因此改进后的 PR 值体现了网页的全局性。

(2) 偏重旧博文网页

因为 PR 值是通过网页间的链接计算来的，所以一个网页如果刚刚放到网络上，可能由于时间短，还没有许多其它的网页指向它，即便是它的内容与查询词最相关，但是 PR 值很小，在返回给用户查询结果的时候就会把它排在后面，这样可能与用户的需求正好相反。在通常的情况下，用户最想看到的是与自己检索的内容最相关的页面。对于旧的网页，在计算网页的 PR 值采用超链接时，应该把网页的日期这个权值考虑进来[17]。网页的日期权重与它的更新时间成反比，即越新的网页，那么他的网页日期的权重就越大，通过把 PR 值与日期权重相结合，就会对目前的偏重旧网页的现象有所改进。

(3) 轻视专业博客

大多数科研人员并不是从根本的排序算法上对轻视专业博客这一问题进行改进，而是改进博客搜索引擎的搜索器，例如优化地址存储列表，把同一站点的地址存放在一起，当一个站点中的所有 RR 值都较高时，那么这个站点的权威性也就高[46]。

3.3 博客搜索引擎的不足

虽然目前的博客搜索工具对于寻找到想要的博客有一定的帮助，但是仍存在一些不足之处[18]：

(1) 关键词限制：目前的博客搜索引擎需要定义好关键词，检索出来的内容只能是含有该关键词的，但是这样容易漏掉语义相关的内容，而且搜索引擎返回给用户的主要是访问度比较高的博客，容易漏掉一些访问度低的博客；

(2) 经验限制：如何定义好一个关键词受用户经验的限制，对于一个普通的网民来说这是比较困难的。

因此，博客搜索引擎远远不能满足用户的需求。

3.4 小结

博客搜索引擎虽然在一定程度上方便用户进行博客的查找，但这种查找只能是通过简单的搜索，而且容易漏掉重要的博客。博客搜索引擎的技术类似于传统搜索引擎，不是针对博客的特点设计的，因此从技术上容易出现上面我们提到的缺点，如主题漂移、偏重旧博文等，而且对用户也有一定的要求，所以不能真正满足用户的需求。

中国知网 https://www.cnki.net

4 推荐算法研究

推荐系统是网上最近几年在电子商务领域应用最为成功的经验，如淘宝网上的商品推荐、亚马逊的书目推荐等。推荐系统是推荐算法的体现，一些经典的算法也是随着系统的成功应用而诞生，这也是我们研究博客推荐系统必须先研究的内容。根据推荐系统的构成原理，推荐算法大体上可分成以下三类：基于内容的推荐、协同过滤的推荐以及混合的推荐[19-21]。

4.1 基于内容推荐算法

基于内容的推荐方法是通过该用户的历史信息构造用户的兴趣文档，计算后选队列中的项目与用户偏好文档的相似度，将最相似的项目推荐给用户，例如：一个用户浏览完一篇关于李刚的新闻报道，那么就会给这个用户推荐其它的关于李刚的新闻给这个用户。文本类信息比多媒体类信息较容易提取特征值，因此该方法在文本类推荐领域中得到了广泛的应用[22,39]。

采用关键字方法表示用户兴趣文档和推荐项目文档的特征，用 TF-IDF(term frequency-inverse document frequency)方法确定各个特征权重。该方法的基本思想是：一方面，关键字 K 在一篇文档 D 中出现的次数越多，表示 K 对这篇文档 D 越重要，越能够用该关键字表示文档 D 的语义；另一方面，关键字 K 在不同的文档中出现的次数越多，表示 K 对区别该文档的贡献就越少。综合考虑以上两方面，提出了 TF-IDF 的特征权重设置方法，设文档集包含的文档数目为 N，文档集中包含关键字 K_i 的文档数目为 N_j，f_{ij} 则表示关键字 K_i 在文档 D_j 中出现的次数，那么 K_i 在文档 D_j 中的词频 TF 定义为：

$$\mathrm{TF_{ij}} = \frac{f_{ij}}{\max_z f_{zj}} \qquad \text{(式 4.1)}$$

其中 Z 表示在文档 D_j 中出现的关键字，K_i 在文档中出现的逆频 IDF 定义为：

$$\mathrm{IDF}_i = \log \frac{N}{\mathrm{N_j}} \qquad \text{(式 4.2)}$$

采用 K 维向量 $\overrightarrow{d_i} = (w_{1i}, w_{2i}, \ldots\ldots, w_{ni})$ 和 $\overrightarrow{d_j} = (w_{1j}, w_{2j}, \ldots\ldots, w_{nj})$ 分别表示为项目文档和用户 C 的推荐文档，K 是关键词的个数，向量中各个分量的计算公式如下：

中国知网 https://www.cnki.net

$$w_{ij} = TF_{ij} \cdot IDF_{ij} = \frac{f_y}{\max_z f_{zj}} \cdot \log \frac{N}{N_j} \qquad \text{(式 4.3)}$$

最后采用夹角余弦的方法计算项目文档和配置文档的相似性：

$$sim(d_c, d_j) = \cos(\vec{d_c}, \vec{d_j}) = \frac{\sum_{i=1}^{k} w_{ic} w_{ij}}{\sqrt{\sum_{i=1}^{k} w_{ic}^2} \sqrt{\sum_{i=1}^{k} w_{ij}^2}} \qquad \text{(式 4.4)}$$

这种方法的难点在于内容的提取上面，对于文字性的博文，可以通过关键字的频率来提取，但是对于图片、音频性的博文，仅有标题几个字，从这几个字中提取出关键字是比较困难的，因此，其内容的提取也就是困难的。我们知道，博文的内容丰富多彩，不仅仅是文字，还有图片、音频等，所以说这种方法应用在博客推荐系统中是不可行的[60]。

4.2 协同过滤推荐算法

该算法是指推荐给用户的项目基于以前与该用户有类似兴趣的用户群喜爱的项目[23,33]。它与基于内容的推荐方法不同，协同过滤技术对用户的兴趣进行分析，然后在分析过的对列中找到与目标用户最为相似的用户，综合这些相似用户，形成相似用户群，对该用户的兴趣进行预测[24,40]，如图 4.1 所示。

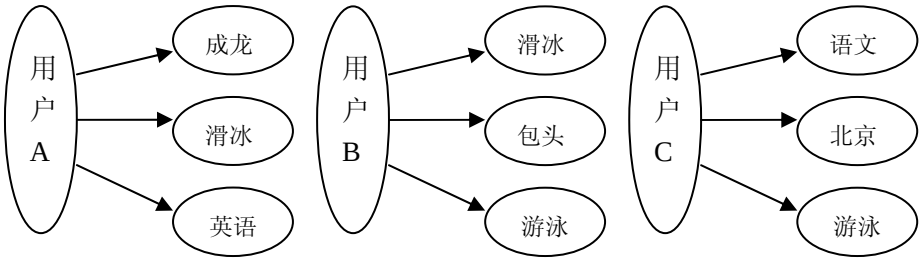

图 4.1　协同过滤推荐

从用户 *B* 和用户 *C* 中推荐一个用户给用户 *A*，假设用户 *A* 有成龙、滑冰、英语三个项目；用户 *B* 有滑冰、包头、游泳三个项目；用户 *C* 有语文、北京、游泳三个项目，因为用户 *A* 和用户 *B* 有相同的项目滑冰，用户 *B* 和用户 *C* 有相同的项目游泳，假设用户 *A* 和用户 *B* 是最相似的，用户 *B* 最喜欢的项目是游泳，那么就把项目游泳推荐给用户 *A*。在这种方法中，它是基于邻居用户的兴趣爱好预测目标用户的兴趣偏

中国知网 https://www.cnki.net

好，它使用统计技术找到和目标用户有相同的评分项目的所有用户，然后把用户集合 **U**={$U_1,U_2,U_3,.....,U_m$}，项目集合 T={$T_1,T_2,T_3,.....,T_n$}组成一个 M 维空间的矩阵，其内容为用户对项目的评分，如图 4.2 所示[24]。

用户	项目				
	I_1	I_1	…	I_{n-1}	I_n
U_1	4	3	…	2	0
U_2	3	1	…	2	2
…	…	…	…	…	…
U_{m-1}	2	5	…	1	3
U_m	2	3	…	1	3

图 4.2　用户-项目矩阵

在协同过滤算法中，对相似性值的计算主要有：基于余弦相似性算法、修正的余弦相似性算法和相关相似性算法。

4.2.1 余弦相似性

把用户对项目进行的评分结果看作是 n 维空间上的向量值，如果用户没有对该项目进行评分，那么向量值设为 0，通过向量夹角的余弦值来度量用户间的相似性。用户 i 和用户 j 在 n 维项目空间上的评分分别用向量 $\vec{i}$ 和 $\vec{j}$ 来表示，则用户 i 和用户 j 之间的相似性 sim(i, j)计算公式如下[25]：

$$sim(i,j)=\cos(\vec{i},\vec{j})=\frac{\vec{i}\cdot\vec{j}}{\|\vec{i}\|\|\vec{j}\|} \qquad \text{(式 4.5)}$$

4.2.2 修正的余弦相似性

在前边描述的余弦相似性中，没有考虑不同用户的评分尺度，因为每个用户的评分尺度不同，对于整个分值会有很大的差别，就会直接影响到最终值的确定，所以在修正的余弦相似性中进行了改进，其方法是减去用户对项目的平均评分，设项目 I_{ij} 表示为经用户 i 和用户 j 共同评分的项目集合，用户 i 和用户 j 的评分的项目集合分别表示为 I_i 和 I_j，那么用户 i 和用户 j 的相似性可表示为[25]：

$$sim=\frac{\sum_{c\in I_{i,j}}(R_{i,c}-\overline{R_i})(R_{j,c}-\overline{R_j})}{\sqrt{\sum_{c\in I_i}(R_{i,c}-\overline{R_i})^2}\sqrt{\sum_{c\in I_j}(R_{j,c}-\overline{R_j})^2}} \qquad \text{(式 4.6)}$$

中国知网　https://www.cnki.net

其中，$R_{i,c}$ 表示为用户 i 对项目 c 的评分，$\overline{R_i}$ 表示用户 i 对项目的平均评分，$\overline{R_j}$ 表示用户 j 对项目的平均评分。

4.2.3 相关相似性

设用 $I_{i,j}$ 来表示经用户 i 和 j 共同的评分项目集合，那么用户 i 和 j 的相似性 sim(i,j) 可用 Pearson 相关系数表示为：

$$sim = \frac{\sum_{c \in I_{i,j}} (R_{i,c} - \overline{R_i})(R_{j,c} - \overline{R_j})}{\sqrt{\sum_{c \in I_{i,j}} (R_{i,c} - \overline{R_i})^2} \sqrt{\sum_{c \in I_{i,j}} (R_{j,c} - \overline{R_j})^2}} \qquad \text{(式 4.7)}$$

其中，$R_{i,c}$ 表示为用户 i 对项目 c 的评分，$R_{j,c}$ 表示用户 j 对项目 c 的评分，$\overline{R_i}$ 表示用户 i 对项目的平均评分，$\overline{R_j}$ 表示为用户 j 对项目的平均评分[19]。

基于余弦相似性的方法中，把用户对项目的评分看成一个向量，用向量夹角的余弦值来计算相似性，它没有考虑不同的用户对项目的评分标准是不同的；修正的余弦相似性对余弦相似性进行了改进，减去了用户的平均评分，但是这种方法更多的是体现两者之间的相关性，而不是相似性；在相关相似性中，如果用户的所有评分项目都是共同的评分项目，那么它和修正的余弦相似性是一样，由于用户的评分项目少，加之共同的评分项目也就更少了，所为这种方法在实际应用中也是有缺点的[19]。

协同过滤的方法中需要不同用户对相同的项目有评分，以此来建立不同用户之间的联系，但是在现实的博客中用户是不可能对博文进行评分的，而且这种方法需要大量的运算，因此这种方法在博客推荐系统中是不可取的[26,28]。

4.3 混合推荐算法

混合推荐算法是把基于内容的推荐算法和协同过滤的推荐算法进行结合的一种算法，有效地弥补了两种方法的缺陷，能够得到比单独使用一种方法更好的效果，混合推荐算法一共有四种方式[19,35]：

(1) 分别使用基于内容推荐算法和协同过滤推荐算法，结合他们的推荐结果，找到一种最合适的推荐结果。一般采用线性结合的方法找到最佳的值。

(2) 把基于内容推荐算法的特点结合协同过滤算法。基于内容的特点主要是指结合用户的特点来计算相似性，以便找到更相似的用户。

(3) 把协同过滤推荐算法的特点结合基于内容推荐的算法。

(4) 用基于内容的推荐算法和协同过滤推荐算法构建一个模型用来推荐。

中国知网 https://www.cnki.net

4.4 小结

由于博文的特点，使得在现有的推荐算法中，无论是哪一种方法应用在博客推荐系统中都是不可取的。在基于内容的算法中对内容的提取是不可行的，对内容的提取是根据关键字的方法进行提取，只限于文本类博文，但是博文样式多种多样，还有很多的是图片、音频等，对此类博文内容的提取是不可行的；协同过滤算法也是不可取的，它要求用户有评分项目，而在博客中，没有提供对博文进行评分的功能，只有对喜欢的博文进行评论和转载的功能，我们无法根据评论对博文进行评分，这种方法也是不可取的。因此目前的这些算法在博客推荐系统中都是不可取的，所以必须根据博客的特点来设计新的算法。

中国知网 https://www.cnki.net

5 基于相似性博客推荐算法研究

目前无论是在工业还是学术界领域，应用最多的是协同过滤技术，但是应用于博客推荐系统中显得不那么恰当，因为这种方法要求用户之间有共同的评分项目，显然在博客系统中这是不现实的，因为博客系统没有提供评分功能，对于感兴趣的博文用户只能是评论或转载；对于基于内容的计算方法，由于博客的内容丰富多彩，不只只是文本类，内容的提取是比较困难的，所以这些方法都是不可行的，因此本文根据博客自身的特点，提出了基于相似性的博客推荐算法[43]。

5.1 相关概念

1、博主社会信息：博主即博客用户(Blogger)，也就是博客用户在现实社会生活中所具有的各种有关的信息特征[47]，如年龄、性别、教育程度、职业、家庭等，博主的信息在博客中的表示如图 5.1 所示。

图 5.1　用户信息

在本算法中，我们主要研究以下的用户社会信息：性别、职业、居住地、家乡、年龄。

2、博主社会信息相似度：指博客用户社会信息相似的程度。

如果两个博主的社会信息相似度越高，那么他们对同一事物喜爱的程度也就越相似。以电影推荐为例，如果两个用户都是警察，那么他们可能都喜欢看警匪片；如果两个用户都是年龄较小的用户，那么他们可能都喜欢看动画片；同样如果两个用户都是老年人，那么他们可能都更加关注老年人健康与生活问题。

在博客系统中，有的博客用户在注册的时候对自己的个人信息输入的比较少，虽然这些信息比较少，但对于分析博主的相似性是非常重要的。由于每个用户输入的社

中国知网　https://www.cnki.net

会信息比较少，我们可以根据具体情况为每个社会信息分配一定的权重，在进行总的相似度计算的时候，再结合其它的信息，为博主的社会信息总值分配一个相对较小的权重。

3、博文：博文是指用户发的文章，又称为帖子，这些帖子的内容和目的有非常大的不同，从对其他网站的评论、链接，到有关公司、个人的新闻，再到日记、照片、散文、诗歌等，甚至科幻小说的链接和发表都有。许多博文有的只是记录着个人所见、所想、所闻，还有一些博文而是一群人基于某个特定的主题或者是共同利益领域的集体创作[9]。博客系统中对博文的转载功能在很大程度上方便了博文的发表，用户只需点一下鼠标就可以拥用该博文。

每个用户在发表博文的时候都可以根据内容命名一个标题，并且可以为其添加一个或多个标签，这个标签的名字不一定是在文中出现过的内容，只要是作者感觉这个标签和博文相关，或是方便寻找即可，这正体现了标签的灵活性。每一篇博文又都属于其中的某一个分类[32,37]。

4、博客的博文相似性：这里的相似性指的是在两个博客中相同领域博文的多少，因为每个用户自己发表的博文内容和其它用户发表的不可能完全一样，只能是描述的领域相同或相关，只有当转载别人博文的时候这两篇博文才会相同，也只有当用户对这篇博文感兴趣的时候才会对其转载，因此我们可以说在两个用户发表或转载的博文当中，如果相同领域的博文越多，则说明他们越相似[34]。

在博客系统中，每篇博文都会有标签，我们可以根据标签和标题很好的对博文进行分类。在使用标签时，如果有两个标签是完全一样的我们就说这两篇博文是相同领域的。在两个博客中，如果属于相同领域的博文越多（包括发表的和转载的博文），则说明他们对这个领域的话题就越感兴趣，因此，我们说如果两个用户相同领域的博文越多，则说明他们越相似。

5.2 博主社会信息相似度计算

博主的社会信息有很多，但是从程序处理的过程来看，概括起来主要分为两种类型：字符型和数值型[47]。字符型数据在程序处理的过程中一般是以布尔值或字符串的形式来表示。因此字符型的数据在程序处理时只存在相同或者不相同两种情况，如果两个社会信息相同，我们设值为 1，不相同我们设值为 0，则对特征值 K 的相似性计算公式为：

$$sim_k(u_a, u_b) = \begin{cases} 1, & f_k(u_a) = f_k(u_b) \\ 0, & f_k(u_a) \neq f_k(u_b) \end{cases} \qquad \text{（式 5.1）}$$

中国知网 https://www.cnki.net

其中，$f_k(u)_a$ 表示博主 A 的特征值 K 的社会信息取值。

根据前面的介绍，在博客中，我们考虑的社会信息中字符型的为：性别、职业、现居住地、家乡。例如有两个博客用户 A 和 B，其中用户 A 的社会信息依次为：男、教师、北京、北京；用户 B 的社会信息依次为：男、自由职业、北京、河北，用公式 5.1 计算相似性的结果依次为：1、0、1、0。每个社会信息对用户的相似程度影响是不同的，我们为每个社会信息加一个权重，其权重总和为 1。对于每个权重的大小，采用线性结合法，设置一个初始大小，经过反复的实验验证，我们得出其权重大小分别为：0.20、0.22、0.19、0.18（此值相加不为 1，另一个权重为后面的数值型社会信息的权重）。那么上例中的用户 A 和用户 B 的社会信息相似度为 0.39。

数值型的特征值在程序处理中通常以整形或浮点型的形式来表示，取值大小分布在一定的范围内，对于特征值 K 的相似性计算为：

$$\mathrm{sim}_k(u_a, u_b) = \frac{window}{window + \left| f_k(u_a) - f_k(u_b) \right|} \qquad \text{（式 5.2）}$$

其中 *window* 表示的是一个可以调节大小的窗口常量，其大小要根据具体情况动态的调节。以年龄为例，如果 *window* 的大小设为 5，那么就表示 5 岁为一个年龄段，$f_k(u_a) - f_k(u_b)$ 表示两个数值的差，如果差越小，则表示两个用户的数值型社会信息越相似。

在博客中，我们考虑的数值型社会信息为年龄，年龄在总的社会信息中的权重为 0.21。以上面用户 A 和 B 为例，设两个用户的年龄分别为 45 和 20，*window* 大小设为 5，那么用户 A 和 B 的数值型社会信息相似度为 0.04。

综合用户社会信息的多个特征，可得一个用户的社会信息相似度计算公式表示为：

$$sim_social(u_a, u_b) = \sum_{i=1}^{k} w_i \cdot sim_i(u_a, u_b), \sum_{i=1}^{k} w_i = 1, w_i > 0 \qquad \text{（式 5.3）}$$

其中 K 是考虑的用户社会信息特征的总个数，W_i 是社会信息特征的相似度的权重，权重之和为 1。W_i 的大小直接影响着该社会信息所占的比重，最终也就会影响推荐系统的效果。W_i 的具体大小需要根据各个社会信息特征与应用领域的相关程度来设定，并且根据最终的相关结果进行调整。

那么上面例中用户 A 和用户 B 最终的社会信息相似度，经公式 5.3 计算为 0.43。

中国知网 https://www.cnki.net

5.3 余弦相似性计算博客的博文相似度

在前面的概念介绍中，我们知道博主虽然不能对博文进行评分，但是他们对自己感兴趣的博文会转载或评论，也会发表自己感兴趣的博文，而且如果两个用户拥用共同领域的博文越多，则说明他们的兴趣越相似，因此用统计的方法找到用户共同领域的博文，认为共同领域博文多的用户即为相似用户[48-50]，如图 5.2 所示。最后可以用协同过滤计算方法中的余弦相似性公式计算两个用户的相似度。

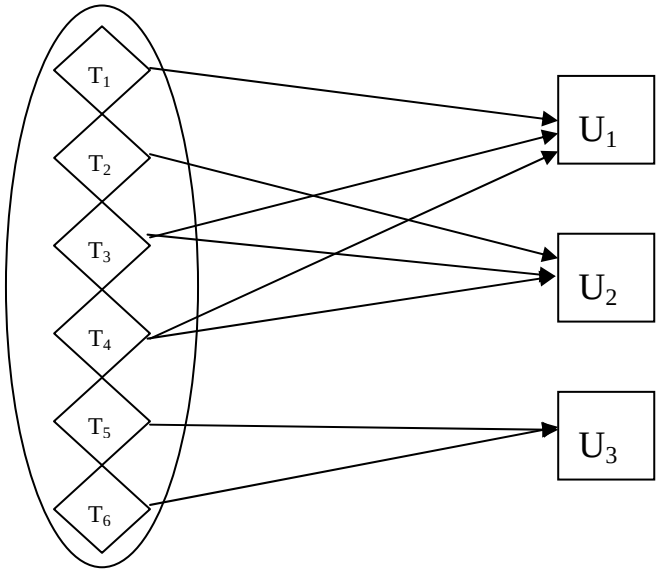

图 5.2　用户—项目图

从图中我们可以看出，博客用户 U_1 有 T_1、T_3、T_4 三篇博文，用户 U_2 有 T_2、T_3、T_4 三篇博文，用户 U_3 有 T_5、T_6 两篇博文，因为用户 U_1 和用户 U_2 有共同的博文 T_3、T_4，所以认为用户 U_1 和 U_2 是相似用户，把 U_2 推荐给 U_1。

在博文分类中，我们根据中科院的中文分词系统，把博文分为以下九类：IT、财经、健康、军事、旅游、体育、文化、招聘、教育。统计每个用户的博文数目，并根据标题及标签分类，然后统计每个用户相关领域的博文数目。例如博客用户 *A* 的各个领域的博文数目依次为：35、8、3、5、20、10、7、2、1，用户 *B* 的各个领域的博文数目依次为：32、6、5、3、15、12、10、8、2，那么博客用户 *A* 和 *B* 的兴趣曲线如图 5.3 所示。

中国知网　https://www.cnki.net

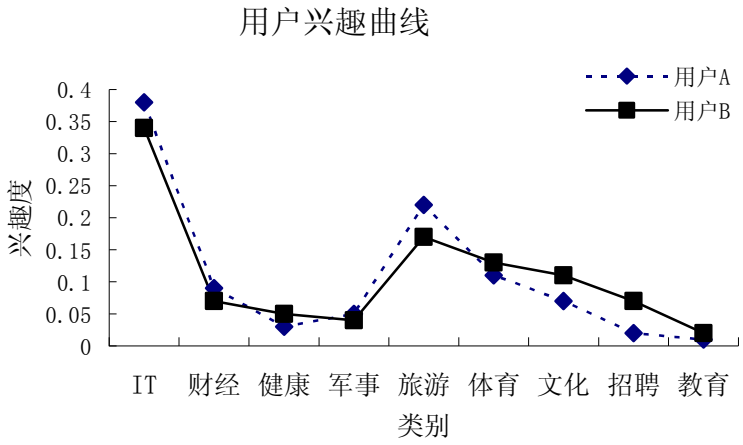

图 5.3　用户兴趣度曲线

图中虚线部分为用户 *A* 的兴趣曲线，实线为用户 *B* 的兴趣曲线，从图中我们可以看出，用户 *A* 和用户 *B* 都对 IT 类的博文最感兴趣，对教育类的博文最不感兴趣，但是同时也共同拥有其它相同领域的博文[31]。

采用协同过滤相似性计算方法中的余弦相似性计算公式 4.5 计算两个博客的博文相似性，把博客用户的每个领域的博文数表示为向量，那么博客 *A* 的博文数用向量表示为：$\vec{A}$=（35，8，3，5，20，10，7，2，1），B 的博文数用向量表示为：$\vec{B}$=（32，6，5，3，15，12，10，8，2），经最后计算，两个博客的博文相似度为：sim(A,B)=cos($\vec{A}$，$\vec{B}$)=0.82。

5.4 博客相似度计算

虽然博客的博文相似度计算不需要用户对项目进行评分，而且也不用计算每个用户的相似度，提高了计算速度，也解决了所谓的冷启动问题，但是如果对于一个新的用户来说，他没有任何博文，这种方法就不能用来进行推荐了，因此必须对其进行改进。

在用博文进行推荐的时候结合用户的社会信息，博主的社会信息相似度和博客的博文相似度都是从不同的角度去挖掘博客之间的相似度，各有优势，因此我们应该将两个相似度用一定的权重因子结合起来，同时考虑两种信息的相似性度量，计算思路如图 5.4 所示。

中国知网　https://www.cnki.net

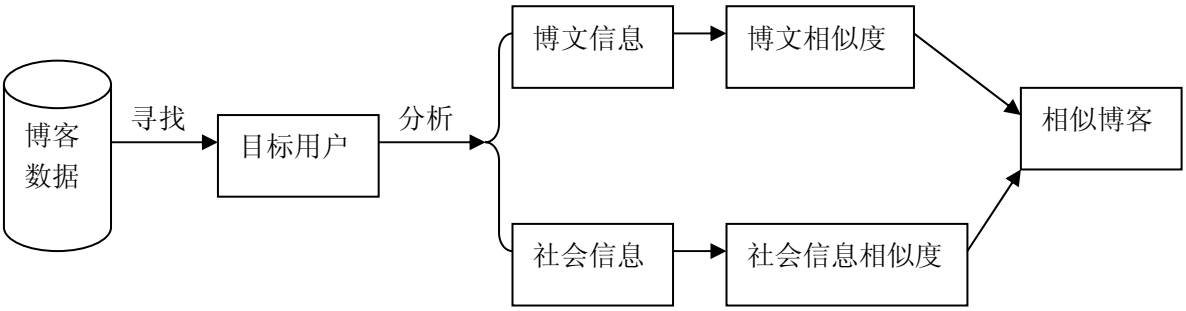

图 5.4　设计思路

根据上面的设计思路图，我们得知在计算博客相似度的时候，我们要同时考虑博客的博文相似度和博主的社会信息相似度，将两者用一个权重因子结合起来，因此计算公式为：

$$sim(u_a,u_b)=a\times sim\text{-}social(u_a,u_b)+(1\text{-a})sim\text{-blog}(u_a,u_b),(0<\text{a}<1)$$

（式 5.4）

通过选择合适的 *a* 值可以将两种方法的优点结合起来，从而进一步提高推荐算法的准确率，提高推荐效果。

对于 *a* 值大小的计算我们采用线性结合法，由于用户在注册的时候输入的社会信息比较少，所以在刚开始计算的时候，我们对其分配一个较小的权重，设置 *a* 初始值为 0.2，然后加 0.01 变为 0.21，再对 0.2 减 0.01 变为 0.19，查看 *a* 值应该是向变大的方向还是向变小的方向发展更为恰当，如果结果不明显，再继续加或减 0.01，一直重复进行这样的运算直到明显为止，最后经过我们多次的运算确定 *a* 的大小为 0.27 最为合适。

博客相似性的计算过程：

1、数据处理。对博客数据进行抓取，并按要求进行解析处理，从中提取出博客的博文信息和社会信息，按照我们预定的分类方法对博文进行分类，最后按照字段要求放到数据库中。

2、寻找目标用户。我们的用户是在博客数据库中已存在的用户，找到目标用户，查看目标用户的社会信息和博文分类信息，如果该用户没有任何博文和社会信息，那么只能更换其它用户。

3、计算用户的社会信息相似度。在后选队列的数据中，分别根据公式 5.1 和公式 5.2 计算与目标用户的字符型和数值型社会信息相似度，最后用公式 5.3 计算最终的与目标用户的社会信息相似度。

4、计算博客的博文相似性。在后选队列中的数据，根据用户的每个领域的博文

中国知网　https://www.cnki.net

数目，转换为相应的向量，用协同过滤相似性计算方法中的余弦相似性公式 4.5 计算与目标博客的博文相似性。

5、计算推荐的博客。在以上步骤的基础上，用公式 5.4 计算最终的博客相似度，为目标用户推荐出相似度最高的博客。

经过上面的计算过程，我们得知前面例子中用户 A 和用户 B 最后的博客相似度为 0.72。

5.5 小结

我们在总结了现有的技术基础之上，根据博客的特点设计了基于相似性的博客推荐算法，该算法结合了博主的社会信息相似度和博客的博文相似度，两者是从不同的角度去分析博客的相似性，该方法减少了计算的复杂度，提高了效率，而且能够解决稀疏性等问题，并能够进行较为准确、客观的博客推荐。这里我们考虑的是用户发表过博文，并有一定的社会信息，如果是一个新用户，没有发表任何的博文，而且也没有任何社会信息[30]，也就不能适用于本算法，那么只能对该用户推荐当前的热点话题或者是名人博客。

中国知网 https://www.cnki.net

6 实验设计与分析

6.1 数据的抓取及处理

6.1.1 数据抓取

实验所采用的数据为用 Heritrix 从新浪网上爬取回来的博客，Heritrix 是一个纯由 Java 开发的、开源的 Web 爬虫工具，之所以选择 Heritrix 是因为它的灵活性及可扩展性，用户可以根据自己的需求，使用它从网络上抓取想要资源，数据抓取的流程如图 6.1 所示。

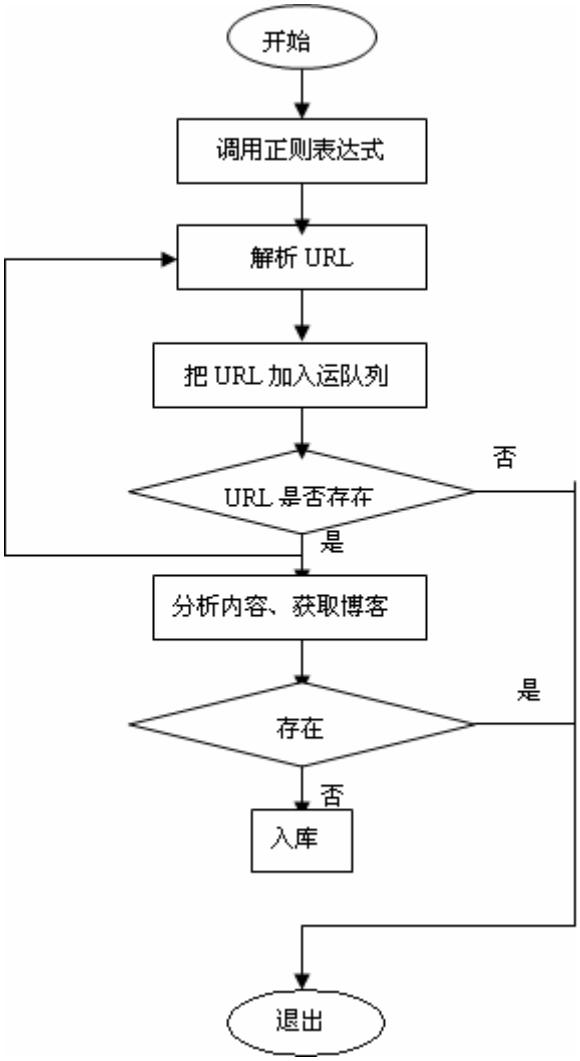

图 6.1　抓取流程图

中国知网　https://www.cnki.net

我们从网上下载源代码，在 Eclipse 中新建一个工程，将下载的源代码放到这个工程中，在配置过程中出现的错误可以通过查找资料进行改正，配置好的工程如图 6.2 所示：

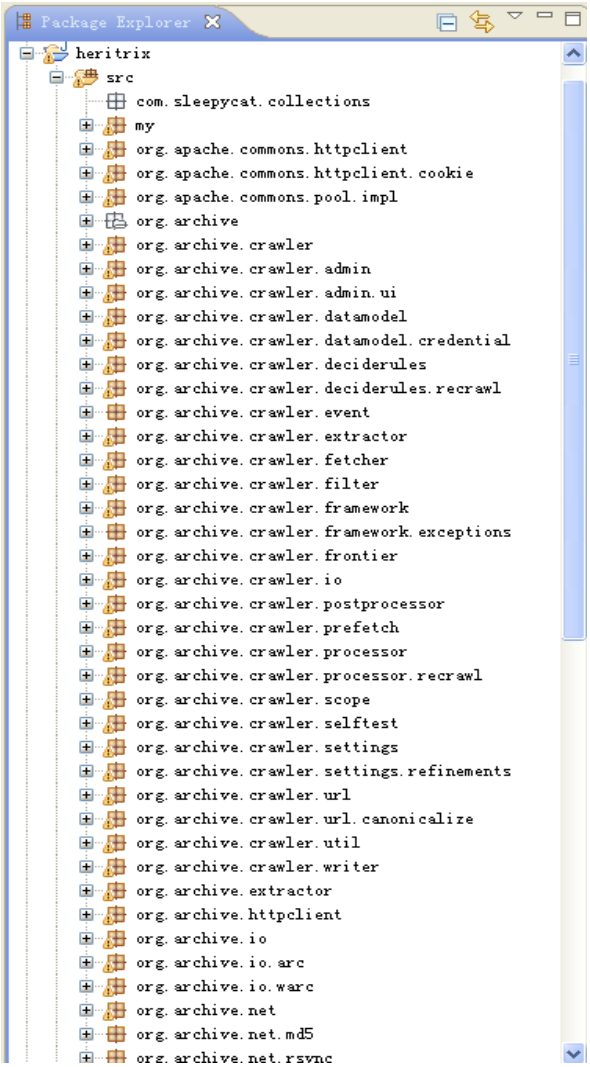

图 6.2　Heritrix 工程包

在配置过程中，改正完所有的错误后，我们就可以运行该代码了，如果显示图 6.3 所示的信息则表示我们配置成功了，其中显示的是一些版本和服务器等信息。这时候我们就可以进行抓取任务了。

中国知网　https://www.cnki.net

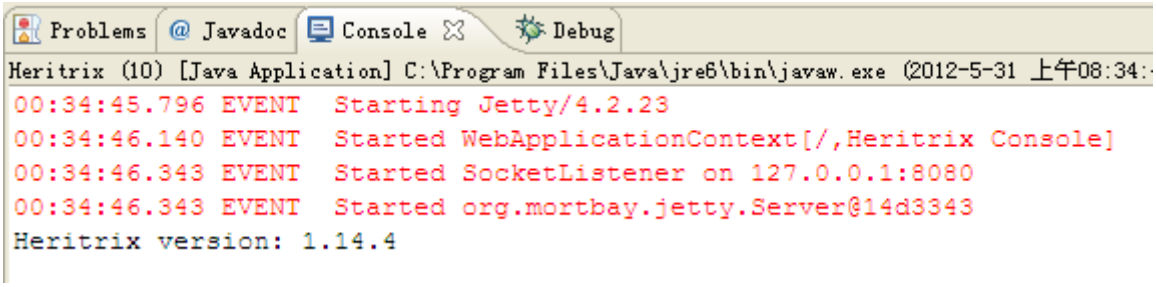

图 6.3　Heritrix 配置成功显示图

在进行配置的时候，我们设置登录的用户名和密码分别为 admin，运行之后的登录界面如图 6.4 所示。

图 6.4　登录界面

登录系统以后，就可以实现一个简单的抓取工作，抓取的基本界面如下图 6.5 所示。

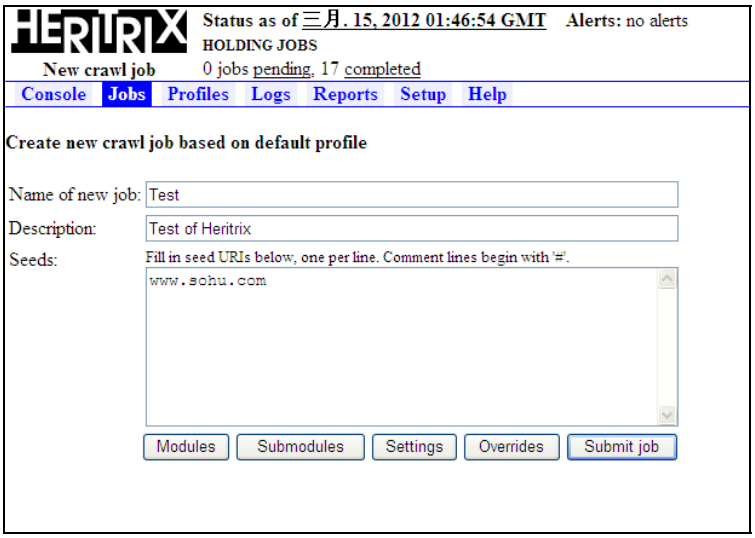

图 6.5　系统界面

中国知网　https://www.cnki.net

在新建任务的名称上，填入“Test”，表示该任务是用来测试的，Description 中填入对本抓取工作的描述性内容，在这里写的是 Test of Heritrix，最后在 Seeds 框中，填入要抓取网页的起始网址。本文在这里解释一下 Seeds 的含义，它是指每次抓取任务的起点。任务开始抓取的时候总是要有一个开始的起点，通过分析这个开始的起点，得出新的抓取队列，再对其进行新的抓取，重复循环这个抓取过程，一直抓取到最后的一个链接[52]。

这只是一个简单的抓取，并不能够满足本课题的需求。但是，Heritrix 的最出色之处在于它的可扩展性，用户可以根据自己的需求来扩展它的各个组件以实现自己的需求。在本实验中我们自己添加一个了爬取类 preftch.Preselector，用它来爬取博客，在这个类中，根据新浪博客地址的特点来写出一个正则表达式，正则表达式如下所示[50]：

blog.sina.cn/[\\d]+/u[\\d]+.shtml"；

将它放在preftch.Preselector类中收藏，以待抓取，在抓取的过程中，只要是链接符合这个正则表达式，就认为它是目标网页。抓取类的主要代码如下：

定义一个公共的静态字符串：

PATTREN_SINA_BLOG="http://blog.sina.cn/[\\d]+/u[\\d]+.shtml";

//第一个正则式，用于匹配Sina博客的格式

定义一个公共的静态字符串：

PATTERN _HREF="<a\\s+href\\s*=\\s*(\"([^\"]*)\"|[^\\s>]\\s*)>";

//第二个正则式，用于匹配所有的<a href="xxx">

protected void extract(CrawlURI curi) //调用该类主要用于当前链接的返回字符串，以便对内容进行分析。

在运行抓取任务的时候，单击添加控件，添加preftch.Preselector类即可，如图6.6所示。

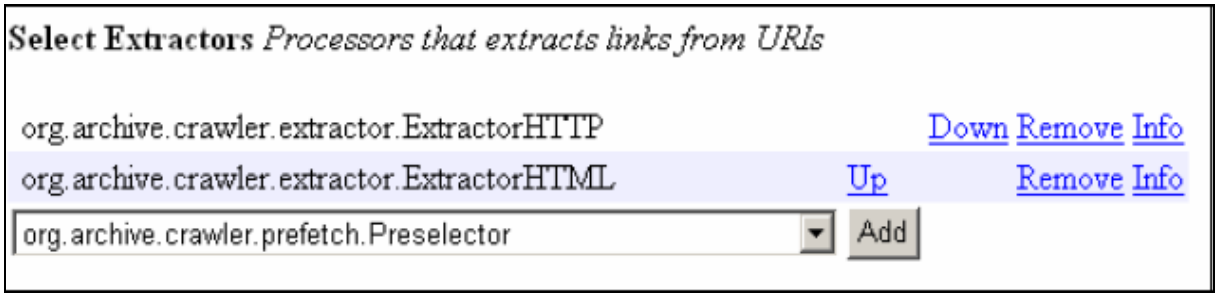

图 6.6　添加类图

在 Heritrix 中，我们可以看到它有很多的设置，这里介绍一下主要用到的几个设

中国知网 https://www.cnki.net

置：

CrawlScope：用来设置抓取网页链接的范围。其中，BroadScope 是指当前抓取的范围不受限制，但是 HostScope 正好相反，它是指只能在 Host 内进行抓取。在这里我们选择 HostScope。

Max-toe-threads：它是指在执行该抓取任务的时候，为每个执行任务分配的线程个数，这里我们设置为 50 个就足够用了。

max-path-depth：表示种子抓取的最大深度，这里设置为 5。

Max-bytes-download：表示抓取器能下载的最大字节数，当下载的字节数超过这个数时就停止抓取，如果把它设置为 0，则表示没有限制，在这里我们设置为 0。其它的一些参数在这里就不一一介绍了，参数设置如图 6.7 所示。

图 6.7　参数设置

设置完所有的参数以后，就可以按照我们设置的参数和链接的种子来进行抓取，抓取界面如图 6.8 所示，其中红色的状态栏表示正在运行的任务，左侧显示的是该任务所有的时间和速度，右侧显示的是抓取任务所占的内存。

中国知网　https://www.cnki.net

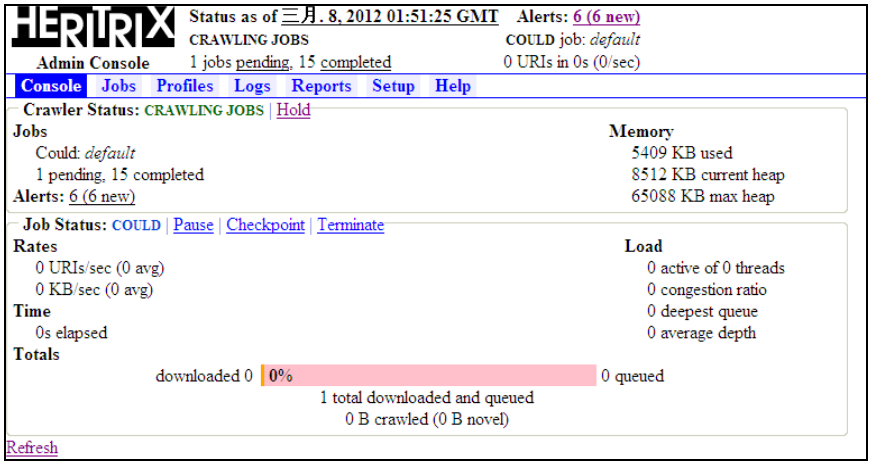

图 6.8　抓取过程

找到 Eclipse 下的 workspace 目录，进入抓取任务的工程里面找到 jobs 目录，打开后，可以看到一个以 job 命名的文件夹，这里边的内容，就是该抓取任务在运行时实时生成的文件，如图 6.9 所示。

图 6.9　抓取的博客

6.1.2 数据处理

本次抓取下载了 256 个博客，通过对网页的解析，我们得知总的博文数量为 7029 篇，通过进一步数据分析得知，其中有 54 个用户没有写满 20 篇文章，因为如果用户的文章数目太少，不利于对用户的特点进行分析，所以我们去除这些用户以及该用户的博文，还剩下 202 个博客和 6057 篇博文，平均每个博客的文章数量为 29.98 篇[58]。

我们以标题和标签作为博文分类依据的关键字，采用 K 最近邻(k-Nearest Neighbor，KNN)分类算法，该算法的思想是如果某个样本在特征空间中的 K 个最相似（即特征空间中最邻近）的样本中的大多数属于某一个类别，则该样本也属于这个

中国知网 https://www.cnki.net

类别[52]，如图 6.10 所示。

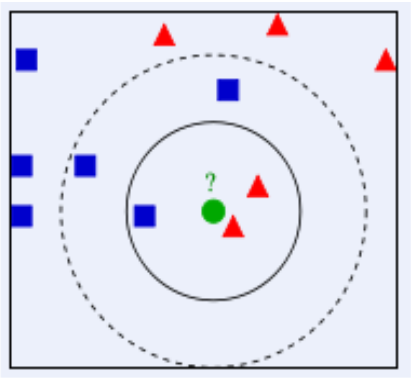

图 6.10　KNN 示意图

在上图中，圆形要被决定赋予哪个类，是三角形还是四方形？如果 K=3，由于三角形所占比例为 2/3，圆形将被赋予三角形那个类，如果 K=5，由于四方形比例为 3/5，因此圆形被赋予四方形类。KNN 算法是模式识别领域中非常著名的统计算法，具有良好的文本分类效果。

我们根据中科院的分类体系，本实验将用户的博文分为以下 9 个大类[8]：IT、财经、健康、军事、旅游、体育、文化、招聘、教育。所有的博文经分类后，数目如表 6.1 所示。

表 6.1　博文分类表

类别	IT	财经	健康	军事	旅游	体育	文化	招聘	教育
数量	672	363	371	320	855	380	497	462	592

对网页解析的同时，得到用户的社会信息主要包括姓名、性别、职业、现居住地、家乡、年龄。

利用 SQL Server 2005 对这些数据进行存储，我们设计了三个表，分别是博客基本信息表、用户社会信息表、用户博文信息表，表结构的设计分别如图 6.11、6.12、6.13 所示。

中国知网　https://www.cnki.net

表 - dbo.User

列名	数据类型	允许空
ID	int	☐
Blogger	nvarchar(MAX)	☑
Count	int	☑
		☐

图 6.11　博客基本信息表结构

表 - dbo.U-Social

列名	数据类型	允许空
ID	int	☐
Sex	nchar(10)	☑
Occupation	nchar(10)	☑
Residence	nvarchar(MAX)	☑
Hometown	nvarchar(MAX)	☑
Age	int	☑

图 6.12　用户社会信息表结构

表 - dbo.U-blog* 表 - dbo.U-blog

列名	数据类型	允许空
ID	int	☐
CIT	int	☑
CFI	int	☑
CHE	int	☑
CMI	int	☑
CTR	int	☑
CSP	int	☑
CCU	int	☑
CEM	int	☑
CED	int	☑

图 6.13　用户博文信息表结构

博客基本信息表、用户社会信息表、用户博文信息表中各个字段的含义如下表 6.2、6.3、6.4 所示。

中国知网　https://www.cnki.net

表 6.2　博客基本信息表字段含意

ID	博客编号
Blogger	博客名称
Count	博文数量

表 6.3　用户社会信息表字段含意

ID	博客编号
Sex	性别
Occupation	职业
Residence	居住地
Hometown	家乡
Age	年龄

表 6.4　用户博文信息表字段含意

ID	博客编号
CIT	IT 类数量
CFI	财经类数量
CHE	健康类数量
CMI	军事类数量
CTR	旅游类数量
CSP	体育类数量
CCU	文化类数量
CEM	招聘类数量
CEU	教育类数量

三个表在数据库中的数据存储截图如图 6.14、6.15、6.16 所示。

表 - dbo.User

ID	Blogger	Count
1	张凡	87
2	高达	92
3	白少爷	85
4	宫晓风	40
5	平凡的人	117
6	丹青	122
7	宫晓风	107
8	李强	84
9	双双飞	96
10	罗秀婷	98

图 6.14　博客基本信息表

中国知网　https://www.cnki.net

表 - dbo.U-blog

ID	CIT	CFI	CHE	CMI	CTR	CSP	CCU	CEM	CED
1	5	18	7	31	6	2	7	10	1
2	5	9	19	15	8	3	8	18	7
3	15	8	30	8	4	4	8	1	7
4	11	5	4	15	0	0	0	5	0
5	11	27	19	5	15	5	13	18	9
6	23	8	11	25	28	19	5	1	2
7	7	31	25	8	19	6	4	5	2
8	4	10	20	9	11	8	12	8	2
9	10	9	11	17	9	10	18	12	0
10	8	18	2	24	6	15	16	0	9

图 6.15 用户博文信息表

表 - dbo.U-Social

ID	Sex	Occupation	Residence	Hometown	Age
1	男	教育	海外	海外	45
2	男	NULL	上海	NULL	NULL
3	女	演员	北京	北京	15
4	女	NULL	河北	河北	32
5	男	学生	吉林	黑龙江	25
6	女	学生	北京	NULL	26
7	男	NULL	吉林	吉林	17
8	男	学生	吉林	北京	54
9	女	学生	湖南	黑龙江	36
10	女	无	北京	北京	20

图 6.16 用户社会信息表

6.2 实验系统

6.2.1 实验环境

操作系统：Windows XP；处理器：Intel Pentium Dual CUP 2.00Hz；内存：1GB：硬盘：140G；数据库：SQL Server 2005。

6.2.2 系统概述

该系统要求界面简洁、操作简单，满足验证算法目的即可。我们在 Eclipse 平台下用 java 语言开发了一个推荐系统，系统要求连接数据库以后可以显示所有的博客名称，在文本框中输入用户的编号以后，则通过计算能够查看到所有相似的博客，并能够推荐出与该用户最相似的十个博客；如果数据库中没有该用户，则提示没有该用户，可以重新输入用户编号，系统流程图如图 6.17 所示[35,53]。

中国知网 https://www.cnki.net

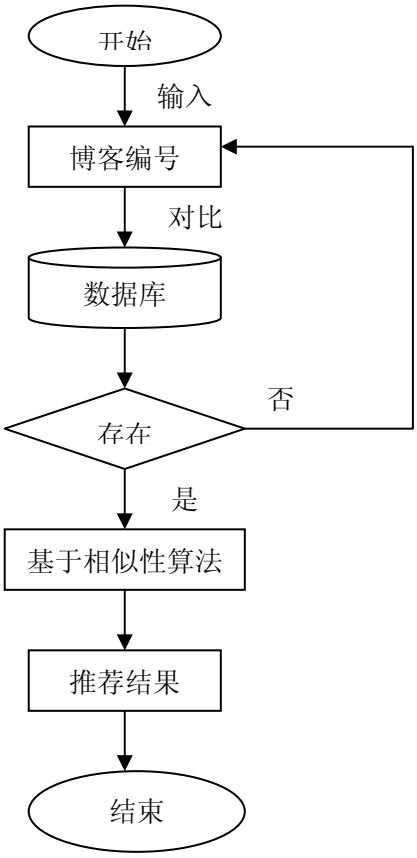

图 6.17　流程图

6.2.3 实验过程

1、用户设置

我们这里考虑的用户是数据库中已存在的用户数据，不考虑新添加用户，如果加入新的用户必需从数据库中加入。我们在文本框中输入博客编号，通过连接数据库查找该博客，在 Eclipse 中连接数据库，需要到微软网站下载 Microsoft SQL Server 2005 JDBC Driver 2.0，装好之后加载到 Eclipse 中，并设置好 ClassPath 和服务器，连接数据库的主要代码如下：

定义字符串：driverName = "com.microsoft.sqlserver.jdbc. SQLServerDriver";

//加载 JDBC 驱动

定义字符串：dbURL = "jdbc:sqlserver://localhost:1433; DatabaseName=Blog";

//连接服务器和数据库 Blog

字符串：UA="wangjb";　　//数据库用户名

字符串：UPD="19841214";　　//数据库密码

Connection dbConn;　　//连接数据库

中国知网　https://www.cnki.net

连接数据库以后，可以在下拉框中显示所有的博客名称，系统界面如图 6.18 所示。

图 6.18　系统界面

2、相似博客

通过连接数据库，在文本框中输入一个编号以后，先从数据库中进行查找，看有没有这个博客，如果没有，可以重新输入或退出；如果有，则通过我们算法计算出所有的相似博客，并在文本框中显示，例如我们在博客编号文本框中输入 5，从数据库中找到该博客的社会信息为：男、学生、吉林、龙江、25；博文信息为：11、27、19、5、15、5、13、18、9，那么经过计算显示该博客所有相似的博客名称，如图 6.19 所示。

中国知网　https://www.cnki.net

图 6.19　相似博客

3、结果推荐

现在我们给编号为 5 的博客推荐最相似的十个博客。根据我们算法，找到和它最相似的十个博客，并在下边的空白框中输出，如图 6.20 所示。

图 6.20　推荐结果

中国知网　https://www.cnki.net

在计算两个博客的博文相似度的时候，要调用余弦类，用类之间的相互调用主要体现了程序的灵活性，同时也方便修改，余弦类的相关代码如下所示：

```
公共类  double CosSim ( ) //定义余弦类，用类去调用其它类
{
    双精度型变量  Result = 0;//定义初始结果为0
        Result = DianMulti(Vector1, Vector2) / SqrtMulti(Vector1, Vector2);
            //调用DianMulti类和SqrtMulti类
            return Result;     //返回结果
  }
  私有类  double SqrtMulti(  整型变量  Vector1,  整型变量  Vector2)     //定义
  SqrtMulti类实现向量的乘积
  {
        双精度型变量  Result = 0;
        Result = Squares(Vector1) * Squares(Vector2); //调用Squares类
        Result = Math.sqrt(Result); //对结果开方
        return Result;
  }
  私有类  double Squares(整型变量  Vector) //用Squares类实现向量的模计算
  {
        双精度型变量  Result = 0;
        for (int i = 0; i < Vector1.size(); i++) //只要向量不为空就进行循环计算
        {
            Result += Vector * Vector;   //向量内部数相乘
        }
                return Result;
  }
        私有类  double DianMulti(整型变量  Vector1,  整型变量  Vector2)
        //用DianMulti类实现向量的点积
    {
        双精度型变量  Result = 0;
        for (int i = 0; i < Vector1.size(); i++)
        {
          Result += Vector1.get(i) * Vector2.get(i); //向量与向量之间对应数相乘
```


中国知网 https://www.cnki.net

```
        }
            return Result;
    }
```

6.2.4 结果分析

从实验中我们得知推荐的十博客，从数据库中找到目标博客和这十个博客的用户社会信息和博文信息，用本文中的方法计算出这十个博客与目标博客的相似度，相似度大小曲线如图6.21所示。

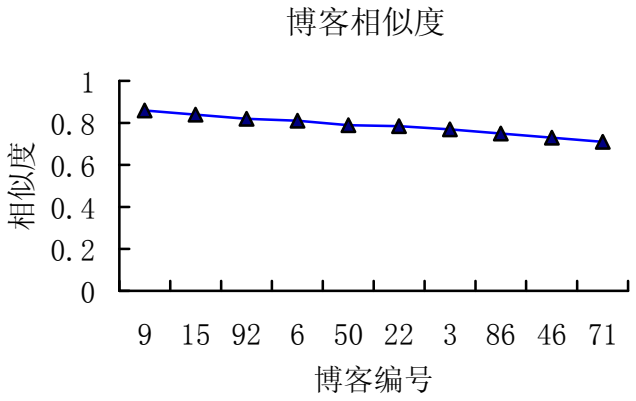

图 6.21　博客相似度曲线

从图中我们可以看出，推荐的这十个博客，相似度都是比较大的，经过人为的查看、分析博客，也可以得知这十个博客与目标博客是比较相似的，因此说本算法能够推荐出相似的博客。

6.3 算法比较

实验是以博主的社会信息和博文信息为推荐依据，因此我们和基于文本内容的算法进行比较。对于博客推荐的评价，没有一个规定的标准，大多是采用人工方式，因此我们也采用人工的方法[60]。通过计算推荐博客的准确率(P)来检测我们的推荐结果，准确率(P)的定义如下[54,56]：

$$p = \frac{M}{N} \qquad \text{（式 6.1）}$$

其中 M=推荐博客与目标博客的匹配数；N=推荐给目标博客的总数。

目前博客推荐中应用最多是基于文本内容的算法，因此本文和基于文本算法进行

中国知网 https://www.cnki.net

比较，文本算法主要是根据博文的内容进行推荐。从数据库中随即抽取出一个博客为目标博客，为了推荐的客观性让实验室的其它同学对其推荐，分别选择 20、50、80、100 个博客为推荐数据，分别对目标博客推荐十个最相似的博客，然后对其进行对照，如表 6.5 所示。

表 6.5　相似度比较表

目标博客	数据集个数（K）	相似性算法准确度	文本算法准确度
赵大帅	20	0.92	0.92
赵大帅	50	0.9	0.87
赵大帅	80	0.87	0.82
赵大帅	100	0.83	0.75
平均准确度		0.88	0.83

我们以测试中的赵大帅为例，在 20 个后选数据的时候，他们的推荐结果是一样的，但是在 50 个数据的时候，其中王利强的社会信息为：男、学生、天津、北京、22；博文信息为：5、5、12、18、11、6、9、18、7；赵大帅的社会信息为：男、学生、天津、黑龙江、23；博文信息为：11、5、7、11、19、8、5、21、15。通过对他们博文信息和社会信息进行分析我们得知，虽然他们相同领域的博客数目有一定的差距，但是由于他们的社会信息很相似，而且从相同的博文描述中可以看出他们都关注一些相同的领域，所以由于社会信息比较相似，导致他们兴趣也是比较相似的。在使用相似性算法时对其进行了推荐，但是文本算法却没有推荐出来。

我们根据上边的准确度的数据，进行分析、总结规律并转换成准确度变化曲线图，如图 6.22 所示。

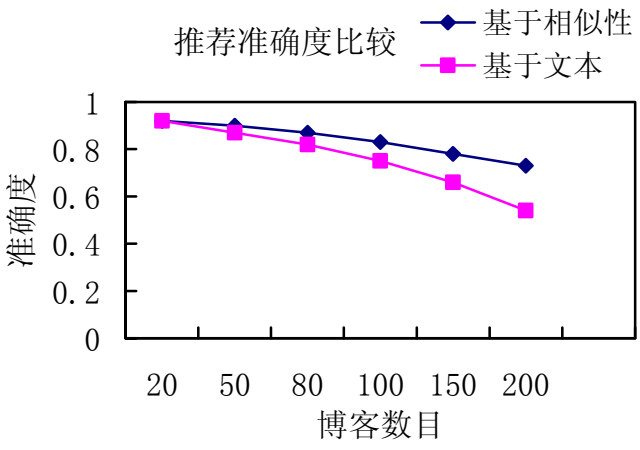

图 6.22　准确度变化曲线

中国知网 https://www.cnki.net

从图中我们可以看出，在数目比较少的情况下，两种方法的准确度相差并不是很大，但是随着博客数目的增多，基于相似性算法的准确度仍然比较高，但是基于内容的算法准确度却下降加快，而且两者之间的差距越来越明显，因此说我们的算法是有效的。

6.4 小结

本章成功配置并修改了 Heritrix 作为数据的抓取工具，以从新浪博客上抓取的数据为实验数据，对抓取回来的数据进行处理和分析，从中提取出博主的社会信息和博文信息，然后对博文进行分类，并把相关的信息存入到数据库中。然后设计并实现了一个推荐系统，用来对本论文中的推荐算法进行验证，系统能够推荐出相似的博客和十个最相似的博客，通过对结果的分析，我们得知推荐的十个博客都是比较相似的，最后和基于本文的推荐方法进行比较，通过一定数量的对比得知本文中设计的算法是有效的。

中国知网 https://www.cnki.net

结　　论

本文通过分析目前几种常用的推荐技术以及博客的特点，设计了一种基于相似性的推荐算法，以新浪博客数据为例，搭建了一个推荐系统，通过实验验证，得知该算法能够为用户推荐他感兴趣的博客，能够在以后的实际中得到很好的应用。

本课题的主要工作：

第一、对博客进行分析。本文系统的介绍了博客的特点及应用，而且对发展趋势进行了总结。

第二、对常用算法进行分析。详细介绍了三种常用的推荐算法，并介绍了这三种算法的优缺点，以及对为什么该算法不能应用在本课题中做了说明。

第三、博客数据的抓取及分析。本课题搭建了一个数据爬取平台，根据新浪博客地址的特点进行抓取，然后对抓取回来的数据进行分析，对数据分类，并从中提取出用户的社会信息，最后存入数据库中。

第四、算法的设计。本课题结合了目前常用的算法思想和博客自身的特点，设计了基于相似性的算法，这里的相似性包括博客的博文相似性和博主的社会信息相似性，通过将这两种相似性按一定权重的结合，可以计算出和目标用户最相似的博客。

第五、推荐系统的建立。本课题在 Eclipse 环境下，用 Java 语言开发了一个推荐系统用来验证该算法，通过系统的验证，得知我们的算法是有效的。

通过对本课题的学习和研究，不但实现了预期的目的、提高了专业技能，而且使我懂得了对待科研的态度，学会了科研的方法，使我有信心在以后的科研的道路上能够走的更远。

中国知网　https://www.cnki.net

参 考 文 献

[1] 刘艳红．Web2.0 时代博客现状与问题[D]．郑州：郑州大学，2007．

[2] 韩冰．Web2.0 时代博客传播分析[D]．长春：吉林大学，2008．

[3] 黄晔．基于 Web2.0 社会性标签与统计推荐系统的设计与实现[D]．重庆：重庆大学，2006．

[4] 陈莉．基于用户兴趣的分布式协同过滤推荐[D]．大连：大连理工大学，2009．

[5] 刘建国，周涛，汪秉宏．个性化推荐系统的研究进展[J]．自然科学进展，2009，19（1）：1-15．

[6] 朱丹霞．中国博客的发展与商业价值研究[D]．长沙：湖南大学，2009．

[7] 寇功杰．我国博客及其传播效果研究[D]．上海：华东师范大学，2009．

[8] 张同刚．博客发展趋势浅见[J]．传媒观察，2007，9：14-15．

[9] 冯结兰．博客及其传播意义探析[D]．南宁：广西大学，2006．

[10] 田莹颖．基于社会化标签系统的个性化信息推荐探讨[J]．图书情报工作，2010，54（1）：50-54．

[11] 严涛．基于 TAG 的网格系统信息服务的研究[D]．南京：南京大学，2008.

[12] 刘双林．LUCENE 实现的基于 RSS 的博客搜索[D]．哈尔滨：哈尔滨工程大学，2009．

[13] 严曙瑾．基于本体的博客搜索引擎关键技术研究与实现[D]．上海：华东师范大学，2009．

[14] 刑东山，沈均毅，宋擒豹．从 Web 日志中挖掘用户浏览偏爱路径[J]．计算机学报，2003，26（11）：1518-1523．

[15] 唐远洋，黄尔嘉．知识挖掘技术与网络教育资源的组织[J]．电化教育研究，2003，6：53-55．

[16] 李晓明，朱家稷，闫宏飞．互联网上主题信息的一种收集与处理模型及其应用[J]．计算机研究与发展，2003，40（12）：1667-1671．

[17] 韩家烯，孟小峰，王静等．Web 挖掘研究[J]．计算机研究与发展，2001，38（4）：405-414．

[18] 王诚，张王景．基于语义的 Web 信息检索[J]．计算机应用研究，2005，8（3）：111-112.

[19] 马宏伟，张光卫．协同过滤推荐算法综述[J]．小型微型计算机系统，2009，30（7）：1282-1287．

中国知网 https://www.cnki.net

[20] 项武．基于评分区间相似性的协同过滤推荐算法[J]．微电子学与计算机，2010，27（7）：125-132．

[21] 杨杰．个性化推荐系统应用及研究[D]．安徽：中国科技大学，2009．

[22] 黄文荣，周长征．基于内容和协作的推荐系统的研究[J]．计算机时代，2009，2：5-7．

[23] 蔡登，卢增祥，李衍达．信息协同过滤[J]．计算机科学，2002，29（6）：1-4．

[24] 颜端武，罗胜阳，成晓．协同推荐中基于用户-文档矩阵的用户聚类研究[J]．现在图书情报技术，2007，148（3）：38-42．

[25] 曾艳，麦永浩．基于内容预测和项目评分的协同过滤推荐[J]．计算机应用，2004，24（1）：111-114．

[26] 综述协同过滤推荐中存在的常见问题及解决方法[EB/OL]．http://apps.hi.baidu.com/share/detail/17900752．

[27] 谌颃．一种基于语义的标签推荐系统框架[J]．网络安全技术与应用，2010，7：40-42．

[28] 胡昌平，丁威．协作过滤中的用户偏好分析与服务推进[J]．情报杂志，2008，9：3-5．

[29] 胡炜．协同过滤算法在推荐系统中的应用[J]．计算机时代，2009，1：16-20．

[30] 吴克文．基于内容挖掘的博客推荐系统的设计与实现[J]．科技情报开发与经济，2008，18（25）：136-138．

[31] Aixin Sun, Ying Liu. Blog Classification Using Tags: An Empirical Study [C]. International Conference on Asian Digital Libraries, 2007, 307-316.

[32] 杨丹，曹俊．基于 Web2.0 的社会性标签推荐系统[J]．重庆工学院学报，2008，22（7）：51-54．

[33] B.Sarwar, G.Karypis, J.Konstan. Item-Based collaborative filtering recommendation algorithms [C]. Proceedings of the 10th International World Wide Web Conference, Horgliorg, 2001, 285-295．

[34] H.Conor, A.Paolo, B.Uldis. An Analysis of Bloggers, Topics and Tags for a Blog Recommender System [C]. Workshop on Web Mining, 2006, 1–20．

[35] G.Adomavicius, A.Tuzhilin. Toward the next generation of recommender system: A survey of the state-of-the–art and possible extensions [J]. IEEE Transactions on Knowledge and Data Engineering, 2005, 17(6):734-749．

[36] T.Bogers, A.V.D.Bosch. Recommending scientific articles using Citeulike [C]. Proceedings of the ACM conference on Recommender systems, 2008, 23-28．

中国知网 https://www.cnki.net

[37] 赵广利．社会网络分析技术在博客媒体信任度中的研究与应用[D]．包头：内蒙古科技大学，2011．

[38] 张玥，朱庆华．Web2.0 环境下学术交流的社会网络分析—以博客为例[J]．理论与探索，2009，32（8）：28-32．

[39] M.D.Gemmis, P.Lops, G.Semeraro, P.Basile. Integratingtags in a semantic content-based recommender [C]. Proceedings of the 2008 ACM conference on Recommender systems, 2008, 154-161．

[40] 于洪，李转运．基于遗忘曲线的协同过滤推荐算法[J]．南京大学学报，2010，45（5）：520-526．

[41] Ren Liu, Pei-Yun. Personalized recommendation of popular blog articles for mobile applications [J]. Information Sciences, 2011, 181(9):540–547．

[42] R.Cooley, B.Mobasher, J.Srivastava. Data preparation for mining world wide Web browsing patterns [J]. Knowledge and Information Systems, 1999,1(5)：230-241．

[43] 李峰，李军怀，王瑞林．基于商品特征的个性化推荐算法[J]．计算机工程与应用，2007，43（17）：94-197．

[44] J.Ham, D.Lee, L.Saul. Semi supervised alignment of manifolds [C]. Proceedings of the Annual Conference on Uncertainty in Artificial Intelligence, 2005, 120–127．

[45] P.Heymann, D.Ramage, H.Garcia-Molina. Social tag prediction [C]. Proceedings of the 31st annual international ACM SIGIR conference, 2008, 275-281．

[46] 崔金国．基于蚁群算法的主题爬虫技术研究与应用[D]．成都：成都理工大学，2010．

[47] 陈春明，徐义峰．协同过滤算法中一种改进的相似性计算方法[J]．桂林电子科技大学报，2009，29（3）：234-237．

[48] Ziyu Guan, Jiajun Bu, Qiaozhu Mei, Chun Chen, Can Wang. Personalized Tag Recommendation Using Graph-based Ranking on Multi-type Interrelated Objects [C]. Proceedings of the 9st annual international ACM SIGIR conference, 2009, 540-546.

[49] Ziyu Guan, Jiajun Bu, Qiaozhu Mei, Chun Chen. Document Recommendation in Social Tagging Services [C]. WWW, 2010, 391-400.

[50] Shivani Agarwal. Ranking on Graph Data[C]. International Conference on Machine Learning, Pittsburgh, page, 2006, 23-28.

[51] 王庆林，薛惠锋，林波．基于图聚类的协同标记系统资源个性推荐[J]．计算机工程与应用，2010，46（11）：10-13．

[52] 李文泽．个性化垂直搜索引擎研究[D]．开封：河南大学，2007．

中国知网 https://www.cnki.net

[53] 赵立江，何钦铭．一种个性化 Web 推荐系统的研究与实现[J]．武汉理工大学学报(交通科学与工程版)，2004，28（5）：682-684．

[54] 宋洪鑫，李蕾，刘冬雪．中文博客标签调查分析及标签推荐模型的研究[C]．第五届全国青年计算语言学研讨会，2010：310-316．

[55] 余强，张海盛．个性化 Web 信息服务技术研究[J]．计算机应用研究，2006，15（2）：198-200．

[56] 许海玲，吴潇，李晓东，阎保平．互联网推荐系统比较研究[J]．软件学报，2009，20（2）：350-362．

[57] 秦国，杜小勇．基于用户层次信息的协同推荐算法[J]．计算机科学，2004，31（10）： 138-140．

[58] X.Li, S.Lin, S.Yan, D.Xu. Discriminate locally linear embedding with high-order tensor data [J]. IEEE Transactions on Systems, 2008, 38(2):342–352．

[59] W.Min, K.Lu, X.He. Locality pursuit embedding [J]. Pattern Recognition, 2004,37(4):781–788．

[60] 牛庆鹏．博客朋友推荐技术的研究[D]．沈阳：东北大学，2009．

[61] G.Karypis. Evaluation of item-based top-n recommendation algorithms [C]. Proc-eedings 10th international conference on Information and knowledge management,2001,247–254．

[62] Tag-站长百科[EB/OL]．http://www.zzbaike.com/wiki/Tag．

中国知网 https://www.cnki.net

在学研究成果

一、在学期间取得的科研成果

在学期间了解了博客搜索引擎的原理及技术，深入研究了推荐系统中常用的推荐技术，在此基础之上设计了基于相似性的博客推荐技术，并开发了一个推荐系统，通过系统实现了算法的验证。

二、发表论文：

[1] Hu Wen-jiang, Wang Jian-bin, Gao Yong-bing, Hao Bin. Research of Blog Recommendation for Collaborative Filtering based on Graphic [C]. The 3rd International Conference on Internet Technology and Applications, Wu Han, 2012.

中国知网 https://www.cnki.net

致　　谢

从 2009 年 9 月到现在，我在内蒙古科技大学信息工程学院渡过了我将近三年的生活。在这段时间里，无论是学习还是生活许多人给予了我很多的帮助，现在我要向所有帮助过我的人表示忠心的感谢。

首先最要感谢的是我的导师胡文江教授。胡老师不仅知识渊博，而且教学严谨，为人和蔼，不只是在学业上对我精心指导，而且在生活上给了我很多的帮助，在生活遇到艰难选择的时候，胡老师总是能帮我分析并给出见意，在此向胡老师致以最忠心的谢意!

其次要感谢我的指导老师高永兵副教授。在研究课题的过程中，高老师以极其认真负责的态度指导我的研究工作，在我课题遇到问题的时候总是能够给我指明方向和研究思路，无论是在程序还是论文上给了我很多宝贵的意见。向高老师表示由衷的感谢！

还要感谢实验室的郝斌老师，在程序编写方面，郝老师给了我很多指导性的意见，并且从宏观上进行把握，使我的程序能够编写的更加顺利。

同时还要感谢张晓琳、谭跃生、柏建普、邢东旭等各位老师，他们对我的课题提出了很多宝贵的意见，为课题能够顺利进展提出了很多见解！

另外，还要感谢实验室的其他同学。三年来，大家相处的十分融洽与和睦。为我提供了一个良好的学习环境，在写论文的编写过程中也给予了很大的帮助。

最后感谢各位专家和老师在百忙之中抽出宝贵时间来评阅本论文。

中国知网　https://www.cnki.net